جامعة مولاي إسماعيل
UNIVERSITÉ MOULAY ISMAÏL

المدرسة الوطنية العليا للفنون و المهن
ÉCOLE NATIONALE SUPÉRIEURE D'ARTS ET MÉTIERS

UM6P | AIM International Artificial Intelligence Center of Morocco | unesco

SOUTENANCE · PROJET DE FIN D'ANNÉE · IATD-SI

Génération et compréhension du mouvement humain 3D à partir de descriptions textuelles multilingues

Étude contrôlée de MotionCLIP en sept langues : bruit, alignement et partage de capacité

Mohammed Amine Hssaine
ENSAM Meknès · Université Moulay Ismaïl

Encadrants : **Naima Outberdout, Ph.D.** · **Ismail Chihab**
AI Movement, UM6P · Stage de 10 semaines · Année universitaire 2025–2026

PLAN

Déroulé de la présentation

1. **Le contexte**
   AI Movement (UM6P), le verrou anglophone, la question de recherche

2. **Les bases**
   Représentation HumanML3D, MotionCLIP, pipeline M-CLIP, fonction de coût, évaluation

3. **Quatre découvertes**
   Échantillonnage vs KL · mesure d'alignement · discrimination vs génération · amplitude

4. **La réponse à la question**
   Comparaison contrôlée EN / Latines / Éloignées / Toutes, et la perte combinée

5. **Limites et suite**
   Menaces à la validité, et proposition : latents séquentiels discrets (MoMask)

PARTIE 1 / 5

01

Le contexte

AI Movement (UM6P), le verrou anglophone, la question de recherche

AI Movement, le centre international d'IA de l'UM6P

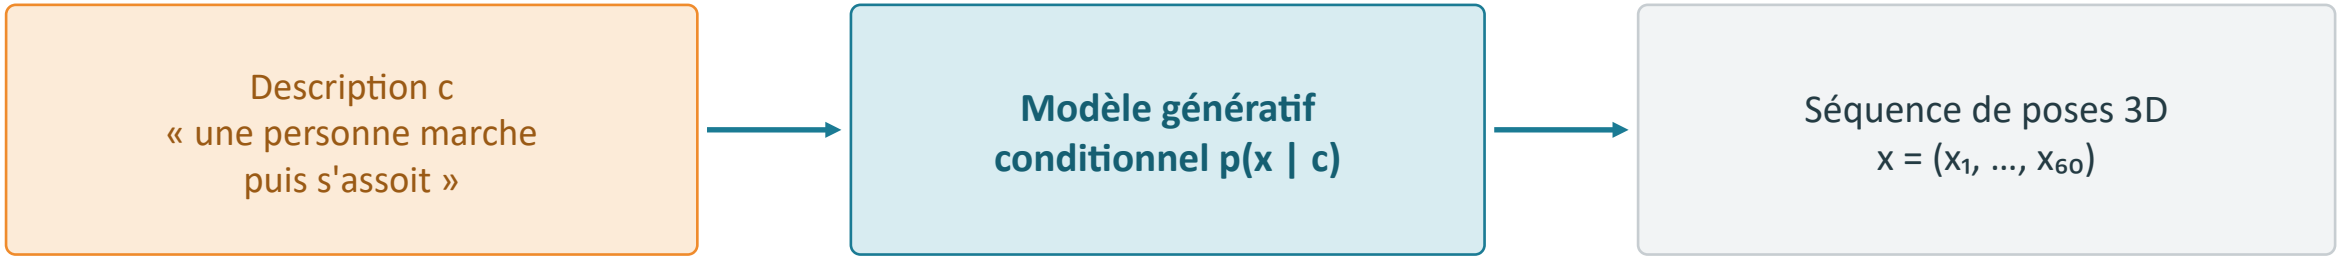


Campus UM6P, Benguérir (photo : Le360, Wikimedia Commons, CC BY 3.0)

- **Centre international d'IA du Maroc**
- UM6P, sous l'égide de l'UNESCO
- Vision par ordinateur, TAL, apprentissage profond, IA incarnée
- **Cadre du stage**
- 10 semaines, GPU NVIDIA RTX 5090 (32 Go)
- Étude contrôlée : une variable modifiée à la fois
- Livrables : outils d'évaluation, index des expériences, dépôt documenté

10	7	30+
semaines	langues	entraînements

Générer un mouvement 3D à partir d'une description



$$x = (x_1, \ldots, x_T) \sim p_\theta(x \mid c), \qquad x_t \in \mathbb{R}^{263}, \quad T = 60$$

- Applications : animation, jeu vidéo, robotique, rééducation
- **Benchmark de référence HumanML3D : légendes exclusivement anglaises**
- Modèles de l'état de l'art (MDM, MoMask) entraînés et évalués en anglais seulement

Objectif : étendre le conditionnement à 7 langues, et mesurer son effet à capacité et calcul appariés.

LA QUESTION DE RECHERCHE

Le conditionnement multilingue enrichit-il la représentation du mouvement, ou divise-t-il un budget de capacité fixe ?

Hypothèse A · supervision enrichie

Les langues encodent différemment manière, trajectoire et aspect (typologie de Talmy) : signal complémentaire sur le mouvement.

Hypothèse B · espace partagé appauvri

À capacité fixe, les langues se partagent les mêmes paramètres (« malédiction du multilinguisme »).

Protocole : même architecture, même nombre de pas de gradient, même jeu de test. Seul l'ensemble de langues varie.

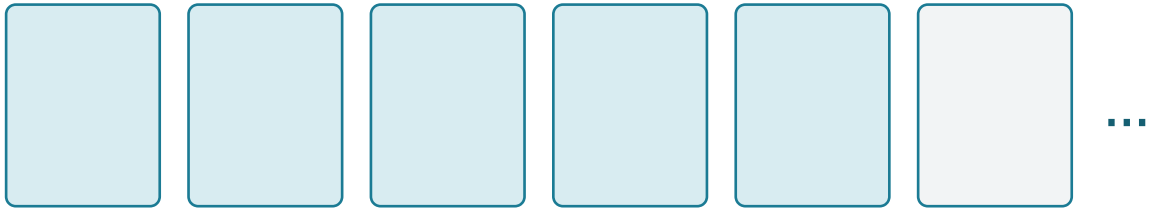
PARTIE 2 / 5

02

Les bases

Représentation HumanML3D, MotionCLIP, pipeline M-CLIP, fonction de coût, évaluation

La représentation HumanML3D : 263 valeurs par image



T = 60 images (3 s à 20 images/s), longueur fixe

22 326
clips d'entraînement

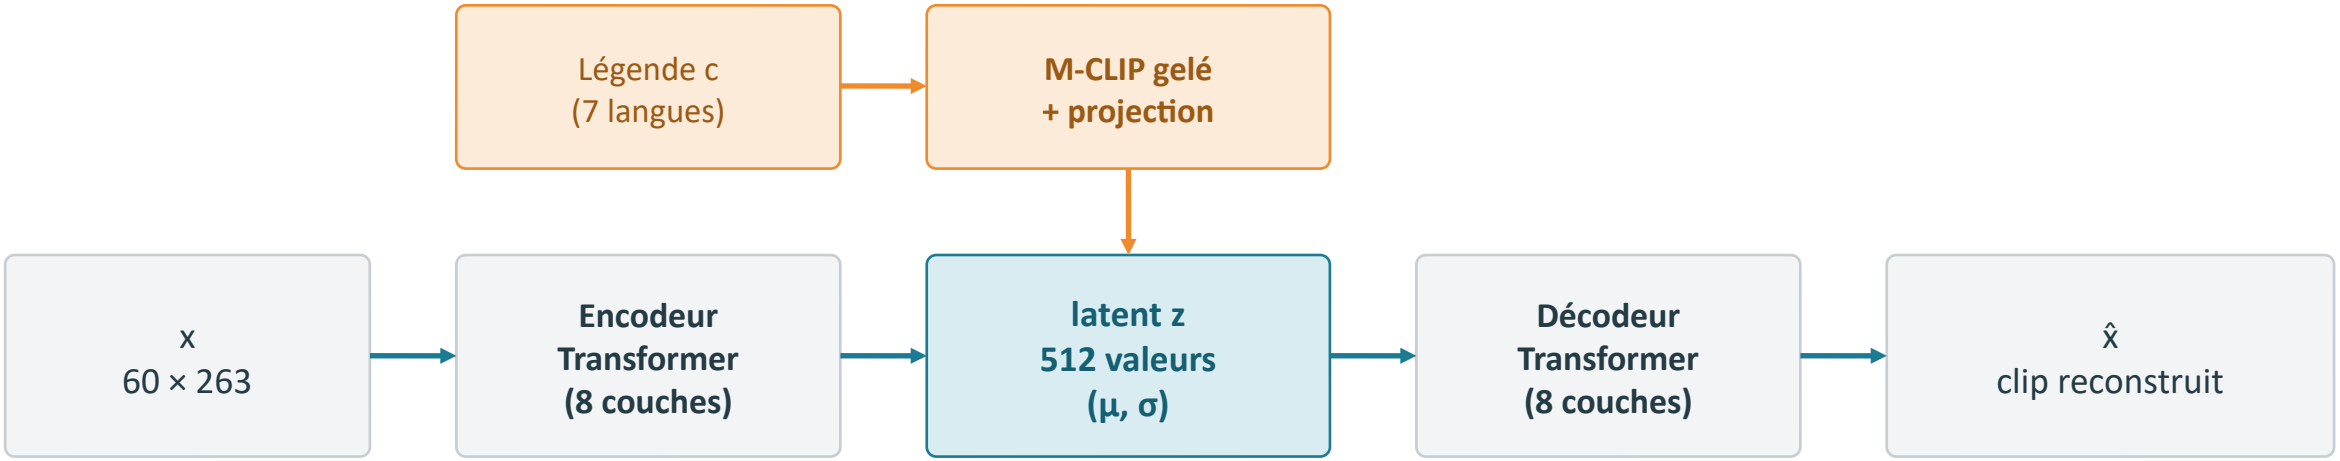
1 400
clips de validation

- Vecteur redondant dérivé de SMPL (forme + pose)
- Rotations en représentation continue 6D
- Standardisation par composante (statistiques du corpus)

Bloc	Détail	Dim.
Racine	vitesse angulaire, vitesses x, z, hauteur	4
Positions locales	21 articulations × 3	63
Rotations 6D	21 articulations × 6	126
Vitesses locales	22 articulations × 3	66
Contacts au sol	indicateurs binaires des pieds	4
Total		**263**

Un clip = 60 × 263 = 15 780 valeurs, à compresser en un latent de 512 valeurs (≈ 30×).

MotionCLIP : un autoencodeur transformeur à latent unique



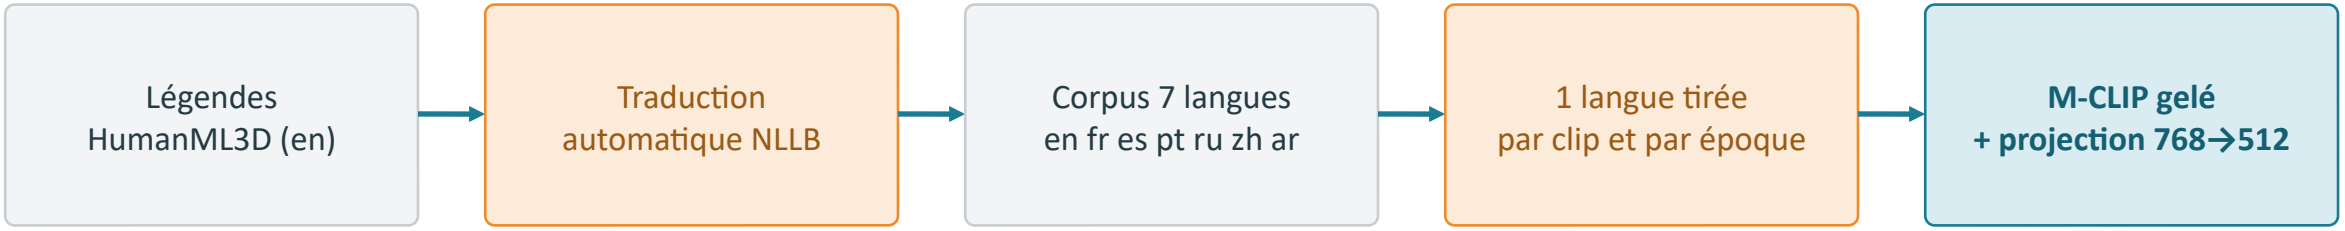
- **Un jeton de requête appris agrège tout le clip en un seul vecteur**
- Entraînement : on aligne e_texte sur μ
- Génération : on décode D(e_texte), substitution jamais optimisée par la perte de base

Erreur de reconstruction minimisée :

$$\mathcal{L}_{\mathrm{rc}} = \left\| \hat{x} - x \right\|^2$$

Tout le clip transite par un point unique : c'est la clé de presque tous mes résultats.

De l'anglais à sept langues



- **M-CLIP (XLM-RoBERTa Large) : traductions déjà proches de l'embedding anglais**
- Encodeur gelé : toute différence provient du latent de mouvement entraîné
- Exposition ≈ 1/N par langue sous N langues (calcul apparié, exposition non)
- **Variante : banc de 7 BERT monolingues**
- CamemBERT, BETO, BERTimbau, RuBERT, AraBERT… : 854 M gelés, 2,76 M entraînés

0,39 M

paramètres texte entraînés (projection M-CLIP)

Limite assumée dès maintenant : les six traductions sont automatiques.

Cinq termes, deux familles d'objectifs

$$\mathcal{L} = 100\,\mathcal{L}_{\text{rc}} + 100\,\mathcal{L}_{\text{vel}} + \lambda_{\text{cos}}\,\mathcal{L}_{\text{cos}} + \lambda_{\text{CE}}\,\mathcal{L}_{\text{CE}} + \lambda_{\text{KL}}\,\text{KL}$$

Terme	Définition	Rôle	Poids
Reconstruction (rc)	MSE positionnelle $\|\hat{x} - x\|^2$	fidélité du clip	100
Vitesse (vel)	MSE sur $x_{t+1} - x_t$	lissage temporel	100
Cosinus (cos)	moyenne de 1 − cos(e_texte, μ)	alignement, paires appariées	variable
Contrastif (CE)	InfoNCE, négatifs intra-lot	alignement par classement	variable
KL	KL(q(z|x) ‖ N(0, I))	régularité du latent	10^{-3}

Pondération 100 : 1 héritée de MotionCLIP et non modifiée, afin que les comparaisons restent équitables.

Protocole : génération, récupération et alignement

FID ↓

Distance de Fréchet entre caractéristiques générées et réelles

R@k ↑

La bonne légende figure-t-elle parmi les k plus proches ?

Écart ↑

cos apparié − cos non apparié, sur 500 clips parallèles

$$\mathrm{FID} = \underbrace{\|\mu_r - \mu_g\|^2}_{\text{moyennes}} + \underbrace{\mathrm{Tr}\left(\Sigma_r + \Sigma_g - 2\left(\Sigma_r \Sigma_g\right)^{1/2}\right)}_{\text{dispersions}}$$

Deux évaluateurs : A (split officiel, FID ≈ 16) pour la baseline ; B (1 400 clips, FID ≈ 56–120) pour les VAE. Jamais comparés entre eux. 20 réplications par mesure ; R-précision anglophone par construction.

PARTIE 3 / 5

03

Quatre découvertes

Échantillonnage vs KL · mesure d'alignement · discrimination vs génération · amplitude

Baseline : le multilingue semble d'abord aider

Modèle	FID ↓	Diversité	R@1 ↑	R@3 ↑	MM-Dist ↓
Vérité terrain	0,010	9,465	0,527	0,813	2,924
M-CLIP, anglais seul	18,013	7,215	0,128	0,327	6,002
M-CLIP, Latines (en fr es pt)	**16,140**	6,697	**0,136**	**0,344**	**5,757**
M-CLIP, Éloignées (en ru zh ar)	18,046	7,002	0,111	0,304	6,003
M-CLIP, les 7 langues	17,829	7,092	0,119	0,310	6,057

Évaluateur A, split officiel HumanML3D, 20 réplications

- Latines : meilleur FID (16,14) et meilleure récupération, devant l'anglais seul
- **Mais mesuré sous l'objectif cosinus : effet réel, ou artefact de la mesure ?**

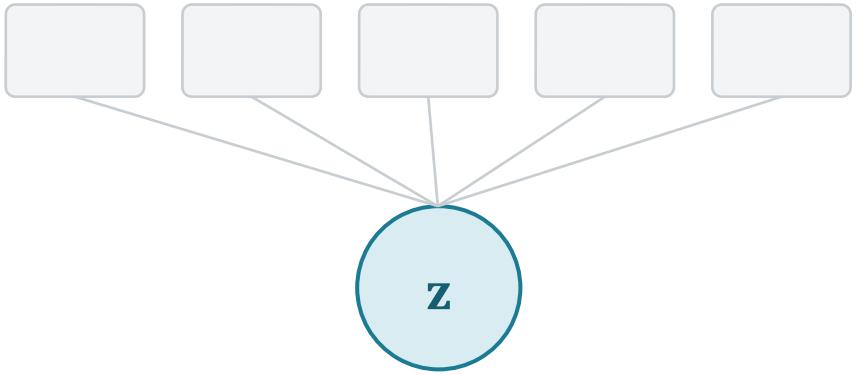
Ce résultat encourageant a déclenché l'enquête qui suit.

L'échantillonnage, et non le KL, casse la reconstruction

Configuration	rc ↓
Autoencodeur déterministe (sans échantillonnage)	**0,083**
VAE, $\lambda KL = 10^{-5}$	0,524
VAE, $\lambda KL = 10^{-3}$ (100× plus fort)	0,526
VAE sans terme cosinus (type ACTOR)	0,524
VAE, λKL recuit sur 30 époques	0,525

4 interventions, 2 ordres de grandeur de λKL : écart total de 0,002

Diagnostic



Avec $z = \mu + \sigma \odot \varepsilon$, le même bruit atteint les 60 images à la fois.

Le poids KL n'est pas le levier : la présence même de l'échantillonnage est la contrainte liante.

Pourquoi le bruit coûte si cher : un argument au premier ordre

① Reparamétrisation du VAE

$$z = \mu + \sigma \odot \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, I)$$

② Jacobiens par image

$$J_t = \frac{\partial \hat{x}_t}{\partial z} \quad (\text{même } z \text{ pour les 60 images})$$

③ Développement de Taylor de l'erreur espérée (démonstration en annexe du rapport)

$$\mathbb{E}_\varepsilon \, \|\hat{x} - x\|^2 \approx \underbrace{\|\hat{x}(\mu) - x\|^2}_{\text{erreur sans bruit}} + \underbrace{\sum_{t=1}^{60} \mathrm{Tr}\left(J_t \, \Sigma \, J_t^\top\right)}_{\text{coût du bruit, payé 60 fois}}$$

- **Le terme de bruit est sommé sur T = 60 images. Avec K latents à segments disjoints, il devient bloc-diagonal : coût ÷ K.**

Entraînement déterministe, puis stochastique

Échantillonnage dès l'initialisation

0,52

la reconstruction s'effondre

→

300 époques déterministes (z = μ)

0,093

reconstruction fidèle

→

+ 10 époques avec échantillonnage

0,086

le bruit ne détruit plus le modèle

Erreur de reconstruction rc (plus bas = mieux)

Banc KL (Évaluateur B)	λKL = 0	λKL = 10^{-3}	+ recuit 30 ép.	+ recuit 5 ép.
FID ↓	97,6	**55,9**	105,7	100,9

Rigueur : deux variables ont changé ensemble (échantillonnage + 10 époques) : on conclut « le bruit ne détruit plus », pas « il améliore ». Le recuit était biaisé : l'échantillonnage s'activait dès λKL ≠ 0.

Résultat : un VAE fonctionnel, et le KL améliore bien la génération (FID 97,6 → 55,9).

Robustesse au bruit : un gain réel qui ne se transfère pas

β	0	0,1	0,25	0,5	1,0
rc sous z = μ + βε	0,081	0,092	0,162	0,386	0,653

La reconstruction se dégrade régulièrement avec l'amplitude du bruit β

Modèle	R@1 ↑	R@3 ↑	FID ↓	MM-Dist ↓
Original	**0,062**	**0,104**	**57,3**	**7,27**
Affiné à β = 0,10	0,031	0,073	86,8	9,17

Effet en aval sur la génération (Évaluateur B)

+25,5 %

gain de reconstruction sous bruit : 92 % des clips améliorés, IC bootstrap 95 % [0,227 ; 0,373]

57,3 → 86,8

mais la FID se dégrade ; distillation et gel de l'encodeur n'y changent rien

Un gain statistiquement solide sur une métrique auxiliaire peut nuire à la génération : branche fermée.

La moyenne cosinus est un diagnostic trompeur

Objectif	cos apparié	cos non apparié	Écart	R@1
Cosinus, λ = 1	0,728	0,728	0,0002	0,008
Cosinus, λ = 100	0,978	0,977	0,0007	0,012
Contrastif (InfoNCE)	0,046	0,027	**0,0186**	**0,068**

500 clips, mouvements identiques, légendes parallèles. Hasard pour R@1 : 0,002

$$\text{écart} = \overline{\cos}\,(\text{paires appariées}) - \overline{\cos}\,(\text{paires non appariées})$$

- Cosinus : écart ≈ 0, R@1 au niveau du hasard ; λ × 100 aggrave (écart-type par clip 0,073 → 0,005)
- **Contrastif : moyenne cosinus 0,978 → 0,046, mais R@1 multipliée par ≈ 6 : la moyenne ment**

On ne mesure un alignement qu'en le comparant aux négatifs : l'écart remplace la moyenne cosinus.

Pourquoi le cosinus n'aligne rien

Cosinus (MotionCLIP)

$$\mathcal{L}_{\cos} = \frac{1}{B}\sum_{i=1}^{B}\left(1 - \cos(e_i, \mu_i)\right)$$

Somme de termes indépendants, paires appariées seulement : aucun négatif.

Contrastif (InfoNCE)

$$\mathcal{L}_{\mathrm{CE}} = -\frac{1}{B}\sum_{i=1}^{B}\log\frac{e^{S_{ii}/\tau}}{\sum_{j=1}^{B} e^{S_{ij}/\tau}}$$

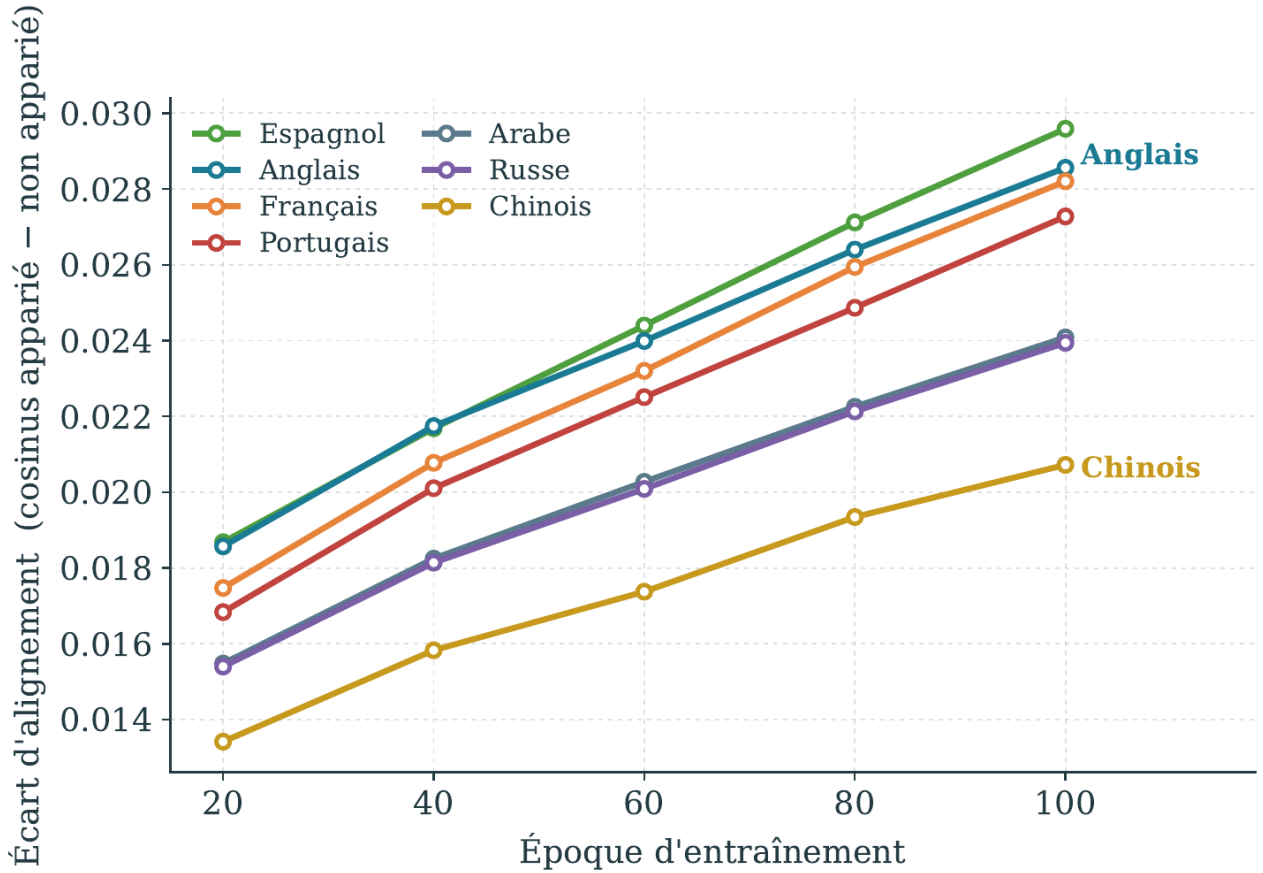
Classement du bon texte contre B − 1 négatifs ; borne inférieure de l'information mutuelle.

Proposition (optimum trivial) : si les e_i sont concentrés, une solution dégénérée minimise déjà la perte

$$\mu_i = \bar{e}\ \ \forall i \quad \Longrightarrow \quad \cos(e_i, \mu_i) \approx \cos(e_j, \mu_i) \quad \Longrightarrow \quad \text{écart} \approx 0$$

- **Aucun poids ne remplace un terme manquant : aligner exige des négatifs.**

Sous InfoNCE, les sept langues s'alignent



- **Écart croissant et monotone dans les 7 langues**
- Époque 100 : es 0,0296 · en 0,0286 · zh 0,0207 (−28 %)
- **Ordre identique à chaque point de contrôle :**
- **es ≈ en > fr > pt > ar ≈ ru > zh**
- Aucun plateau à 300 époques : le budget d'entraînement limite encore
- 300 ép. : R@1 0,068 · R@3 0,174 · R@10 0,340 (hasard 0,002 / 0,006 / 0,020)

Alignement réel, structuré et deux ordres de grandeur au-dessus du hasard.

Discrimination et génération se dissocient

Objectif	Écart (en) ↑	R@10 ↑	FID ↓	Diversité
Cosinus	0,0002	0,024	**55,9**	–
Contrastif, 300 ép.	**0,0286**	**0,340**	72,9	0,92
Mouvement réel	–	–	0,0	9,68

Évaluateur B

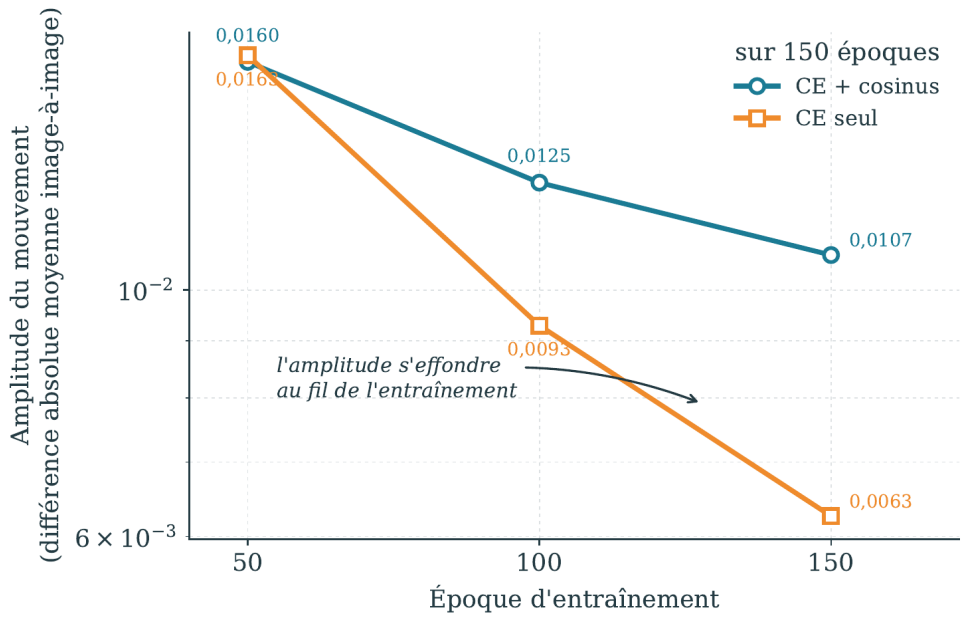
Intuition

Reconnaître un visage dans une foule n'implique pas de savoir le dessiner.

- **InfoNCE ne contraint que le classement, de façon invariante à l'échelle**
- Le latent doit être distinguable, pas décodable : rien n'impose de garder l'information de reconstruction
- Pas un problème d'échelle : normaliser e_texte (‖·‖ 20,4 vs 9,2) ne change la FID que de 2,1

Une représentation peut être très discriminante et mal décodable à la fois.

Effondrement de l'amplitude : le mouvement s'éteint



$$A = \frac{1}{T-1} \sum_{t=1}^{T-1} \|x_{t+1} - x_t\|_1$$



- **Amplitude 0,077 (20 ép.) → 0,004 (330 ép.)**
- Optimum de la MSE :

$$\hat{x}^\star = \mathbb{E}\left[\, x \mid \text{texte} \,\right]$$

- Moyenne de phases décalées = pose statique
- Écartés : rendu, échelle, poids de vitesse
- Encodeur sain : cos mouvement–mouvement 0,31–0,98

Le décodeur régresse vers E[x | texte] : une « photo » de l'action au lieu d'une « vidéo ».

Entraîner le chemin réellement utilisé à la génération

Terme ajouté : $\mathcal{L}_{\text{text-rc}} = \left\| D(e_{\text{texte}}) - x \right\|^2$ *(le décodeur est enfin entraîné sur e_texte)*

Entraînement (150 ép.)	text-rc	Encodeur	Amplitude	Marche / saut	Ratio
ce150-combined	non	M-CLIP	0,0108	0,041	3,8
wk-textrc	oui	M-CLIP	0,0042	**0,246**	**58**
wk-textrc-rc20	oui	M-CLIP	0,0030	**0,293**	**99**
wk-perlang	non	banc 7 BERT	**0,0174**	0,093	5,4

- Conditionnement textuel × 6 à 7 (0,041 → 0,293), mais l'amplitude baisse : un seul vecteur fixe la pose, pas la trajectoire
- **Banc par langue : amplitude × 2 à 3 face à M-CLIP, ce qui inverse le verdict initial mesuré sous cosinus**

Le conditionnement progresse, pas la trajectoire : la limite est bien le latent unique.

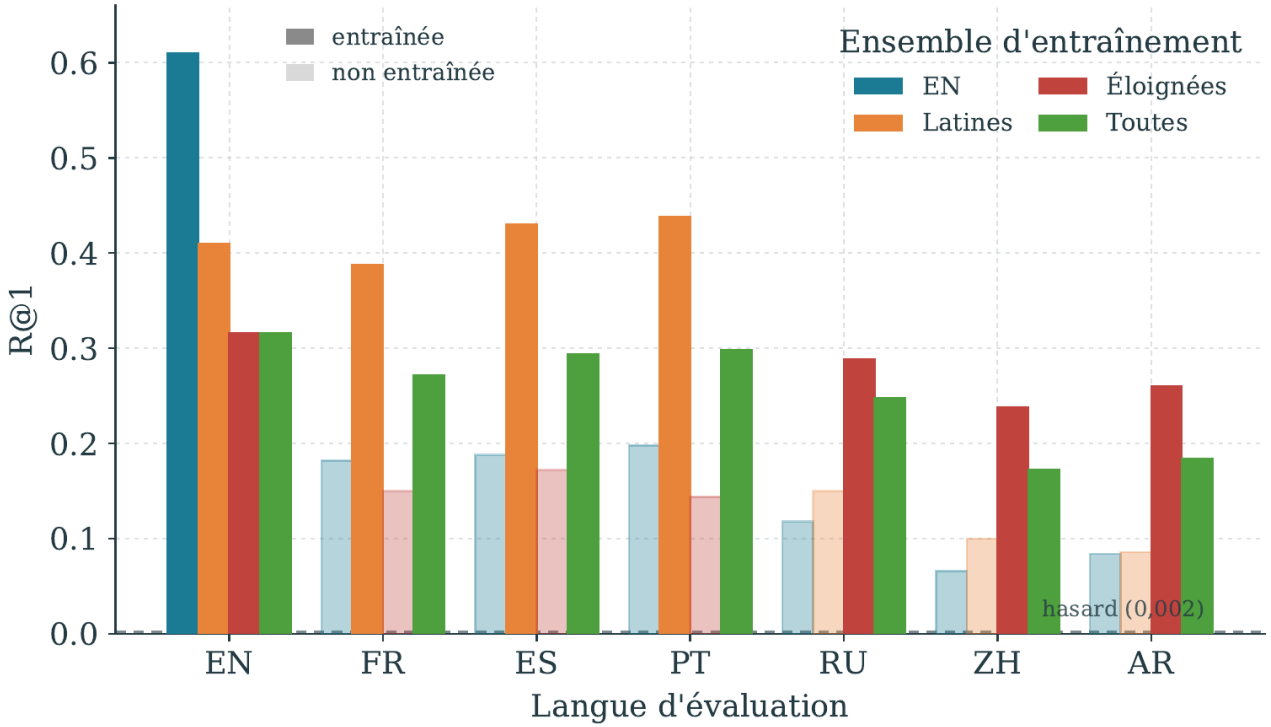
PARTIE 4 / 5

04

La réponse à la question

Comparaison contrôlée EN / Latines / Éloignées / Toutes, et la perte combinée

Comparaison contrôlée : les langues divisent la capacité



- **Anglais : R@1 0,610 → 0,410 → 0,316**
- Diversité 1,80 (EN) → 0,67–0,83 (multilingue)
- **Chaque condition domine sur ses langues**
- Latines : R@1 0,42 en fr/es/pt ; Éloignées : 0,26 en ru/zh/ar
- Transfert zéro-shot : 0,100 en chinois sans données chinoises (50× le hasard)
- Éloignées : meilleure FID (63,9) malgré un alignement plus faible

150 époques, lot 128, InfoNCE, $\lambda KL = 10^{-3}$: seul l'ensemble de langues change

Hypothèse B : la capacité est partagée, non enrichie. Facteur de confusion : exposition ≈ 1/N par langue.

La perte combinée InfoNCE + cosinus restaure la diversité

InfoNCE seul

0,73–0,83

diversité

→

InfoNCE + cosinus

1,459

diversité (≈ × 2)

FID

≈ égale

74,5 contre 74,0

- **Complémentarité : InfoNCE sépare les échantillons, le cosinus fixe une contrainte absolue**
- Similarité moyenne ≈ 0,10 → 0,55, tout en conservant un écart réel
- Dispersion inter-lingue la plus faible de toutes les conditions : 0,0066
- Coût modéré : R@1 anglais 0,316 → 0,266

Configuration recommandée : diversité ≈ × 2 à FID constante, couverture multilingue la plus uniforme.

PARTIE 5 / 5

05

Limites et suite

Menaces à la validité, et proposition : latents séquentiels discrets (MoMask)

Menaces à la validité, énoncées explicitement

Légendes traduites automatiquement
artefacts de traduction mêlés à la variation typologique

Exposition par langue non appariée
calcul apparié, mais chaque langue vue ≈ 1/N du temps

R-précision anglophone
tour GloVe BiGRU : qualité par langue jugée par la FID seule

FID ≈ 100× l'état de l'art
modèle de base faible : comparaisons relatives, non absolues

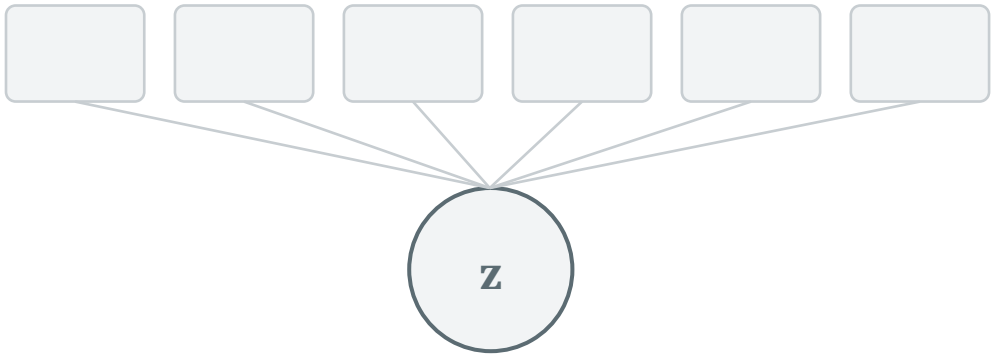
λKL comparé à 0, non balayé
et courbes d'alignement non convergées

Affinage à deux variables
contrôle de 10 époques déterministes encore à mener

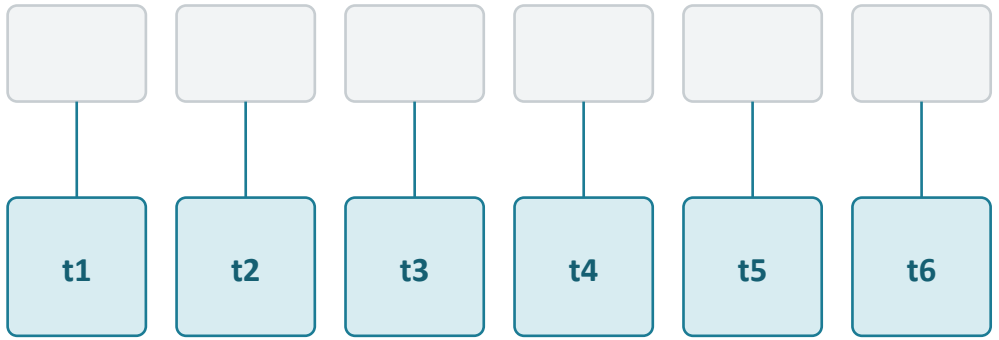
Nommer ces limites délimite précisément ce que les conclusions affirment, et ce qu'elles n'affirment pas.

Remplacer le latent unique par une séquence de tokens discrets

Aujourd'hui : un latent continu



Proposé : tokens discrets par segment (RVQ)



- Bruit local : terme jacobien bloc-diagonal, coût divisé par ≈ K
- Quantification : choix dans un dictionnaire, donc pas de régression vers E[x | c]
- Texte conditionnant chaque segment : la trajectoire devient représentable
- **Expérience proposée : MoMask conditionné par M-CLIP, comparaison EN / multilingue à exposition appariée**

Prédiction falsifiable : avec des tokens discrets, l'amplitude ne s'effondre plus.

CONCLUSION

1

L'échantillonnage, et non le KL

Un latent unique paie le bruit sur 60 images ; l'entraînement déterministe puis stochastique restaure le VAE.

2

Mesurer l'alignement avec des négatifs

La moyenne cosinus est trompeuse ; l'écart apparié − non apparié et InfoNCE révèlent l'alignement réel.

3

Les langues divisent la capacité

Chaque langue gagne sur ce qu'elle voit, l'anglais recule (R@1 0,61 → 0,32) : hypothèse B.

4

Une recette et une piste

InfoNCE + cosinus : diversité ≈ × 2 à FID égale. Suite : tokens discrets (MoMask + M-CLIP).

Merci pour votre attention. Je suis à votre disposition pour vos questions.