École Nationale Supérieure d'Arts et Métiers – Meknès

AI Movement – UM6P
Rabat / Salé Al Jadida

Rapport de Projet de Fin d'Année

Génération et compréhension du mouvement humain 3D à partir de descriptions textuelles multilingues

Étude contrôlée de MotionCLIP en sept langues : bruit, alignement et partage de capacité

Filière : Intelligence Artificielle et Technologies des Données (IATD-SI)

Réalisé par : Mohammed Amine Hssaine

Encadrants :

Naima Outberdout, Ph.D. • Ismail Chihab

AI Movement, Centre International d'Intelligence Artificielle du Maroc – UM6P

Année universitaire : 2025 – 2026

Remerciements

Je tiens à exprimer mes sincères remerciements à l'École Nationale Supérieure d'Arts et Métiers de Meknès (ENSAM Meknès) et à l'Université Moulay Ismaïl pour la qualité de la formation dispensée tout au long de mon parcours au sein de la filière Intelligence Artificielle et Technologies des Données.

J'adresse ma profonde gratitude à mes encadrants, **Naima Outberdout** et **Ismail Chihab**, pour la confiance qu'ils m'ont accordée en me confiant un problème de recherche ouvert et exigeant, et pour leur accompagnement constant. Ce que je retiendrai le plus de ce stage, ce sont nos échanges : ceux où un résultat dont j'étais fier était démonté en cinq minutes, et ceux où une question posée en passant se révélait être le cœur même du projet. Ils m'ont appris à me méfier d'une courbe de perte flatteuse et à aller chercher le chiffre qui tranche réellement le débat.

Je remercie chaleureusement l'ensemble des équipes d'**AI Movement** et de l'**UM6P** pour leur accueil, pour leurs questions dans les couloirs et pour m'avoir donné l'occasion de mener un véritable travail de recherche sur des ressources de calcul réelles. C'est la première fois que j'ai ressenti de l'intérieur ce qu'est une équipe de recherche, et c'est la raison pour laquelle je souhaite en vivre davantage.

Enfin, je remercie ma famille et mes amis, qui ont écouté mes histoires de squelettes refusant de bouger en faisant semblant de les trouver passionnantes : merci pour la patience et pour m'avoir gardé l'esprit clair.

Mohammed Amine Hssaine

Résumé

La génération de mouvement humain à partir de texte (*text-to-motion*) est aujourd'hui presque exclusivement pilotée par l'anglais. Ce projet de fin d'année, réalisé en dix semaines au sein du centre **AI Movement** (UM6P), étudie l'extension de *MotionCLIP*, un autoencodeur transformeur qui compresse un clip de mouvement de 60 images en un unique vecteur latent de dimension 512, afin de le conditionner sur du texte en **sept langues** (anglais, français, espagnol, portugais, russe, chinois, arabe). L'encodeur de texte CLIP, gelé, est remplacé par le modèle multilingue M-CLIP puis, en variante, par un banc de sept encodeurs BERT monolingues, le modèle étant entraîné sous un objectif variationnel.

Quatre résultats structurent ce travail. **Premièrement**, dans un VAE de mouvement à latent unique, c'est *l'échantillonnage*, et non la force de la pénalité de Kullback–Leibler, qui détruit la reconstruction : quatre interventions couvrant deux ordres de grandeur de λ_{KL} ne déplacent l'erreur de reconstruction que de 0,002. Un argument au premier ordre explique pourquoi un latent unique ne peut absorber le bruit injecté, et une stratégie d'entraînement *déterministe-puis-stochastique* restaure un modèle variationnel fonctionnel. **Deuxièmement**, l'objectif cosinus hérité de MotionCLIP ne produit *aucun* alignement texte–mouvement par échantillon, quel que soit son poids ; un objectif contrastif produit, lui, un écart d'alignement réel et croissant dans les sept langues. **Troisièmement**, la qualité d'alignement et la qualité de génération se *dissocient* : une représentation peut être très discriminante et mal décodable à la fois. **Quatrièmement**, l'amplitude du mouvement généré décroît de façon monotone au cours de l'entraînement, la reconstruction par erreur quadratique poussant le décodeur vers une pose moyenne quasi statique. Une comparaison contrôlée (anglais / latines / éloignées / toutes) montre que les langues ajoutées *divisent* un budget représentationnel fixe plutôt que d'y apporter une information complémentaire, et qu'une perte combinée contrastif + cosinus restaure la diversité de génération à FID essentiellement inchangé.

La limite principale, et la proposition prospective du rapport, est architecturale : un latent unique est un mauvais conteneur pour une séquence de mouvement conditionnée de façon multilingue. Nous plaidons pour une séquence de latents (discrets), avec MoMask conditionné par M-CLIP comme prochaine expérience naturelle.

Mots-clés : Génération de mouvement 3D, Text-to-Motion, MotionCLIP, Autoencodeur variationnel (VAE), Apprentissage contrastif, CLIP multilingue (M-CLIP), Alignement vision–langage, HumanML3D, FID, Multilinguisme.

Abstract

Text-to-motion generation is almost exclusively driven by English. This report, carried out at the **AI Movement** centre (UM6P), studies the extension of *MotionCLIP*, a transformer autoencoder that compresses a 60-frame human motion clip into a single 512-dimensional latent, to condition on text in seven languages (English, French, Spanish, Portuguese, Russian, Chinese, Arabic). We replace the frozen CLIP text tower with multilingual M-CLIP and, as an alternative, with a bank of seven monolingual BERT encoders, training the model under a variational objective. Four findings structure the work. First, in a single-latent motion VAE it is *sampling*, not KL strength, that collapses reconstruction. Second, the cosine objective produces no per-sample alignment at any weight, whereas a contrastive objective does, across all seven languages. Third, alignment quality and generation quality *dissociate*. Fourth, generation amplitude decays monotonically under mean-squared reconstruction. A controlled comparison shows that added languages divide a fixed representational budget rather than enriching it, and that a combined contrastive-plus-cosine loss restores generation diversity at unchanged FID. The overarching limitation, and the forward proposal, is architectural : a single latent is the wrong container for a multilingually conditioned motion sequence ; we argue for a sequence of discrete latents (MoMask with M-CLIP conditioning).

Keywords : 3D Motion Generation, Text-to-Motion, MotionCLIP, Variational Autoencoder, Contrastive Learning, Multilingual CLIP, Vision–Language Alignment, HumanML3D, FID, Multilinguality.

Liste des abréviations

AE	Autoencodeur (*Autoencoder*)
AraBERT	Modèle BERT pré-entraîné pour l'arabe
ACTOR	*Action-Conditioned Transformer VAE*
BERT	*Bidirectional Encoder Representations from Transformers*
CE	*Cross-Entropy* ; ici la perte contrastive InfoNCE
CLIP	*Contrastive Language–Image Pre-training*
ELBO	*Evidence Lower Bound* (borne inférieure de la vraisemblance)
FID	*Fréchet Inception Distance* (version mouvement)
GELU	*Gaussian Error Linear Unit* (fonction d'activation)
GPU	*Graphics Processing Unit* (processeur graphique)
HPC	*High-Performance Computing* (calcul haute performance)
IA	Intelligence Artificielle
IATD	Intelligence Artificielle et Technologies des Données
InfoNCE	*Information Noise-Contrastive Estimation*
KL	Divergence de Kullback–Leibler
M-CLIP	CLIP multilingue (XLM-RoBERTa-Large / ViT-B-32)
MDM	*Motion Diffusion Model*
MM-Dist	*Multimodal Distance* (distance texte–mouvement généré)
MoMask	Modèle masqué à quantification vectorielle résiduelle
MSE	Erreur quadratique moyenne (*Mean Squared Error*)
NLLB	*No Language Left Behind* (traduction automatique)
NLP	Traitement automatique du langage (*Natural Language Processing*)
R@k	Précision de récupération au rang k (R-précision)
RVQ	Quantification Vectorielle Résiduelle (*Residual VQ*)
SMPL	*Skinned Multi-Person Linear model*
UM6P	Université Mohammed VI Polytechnique
VAE	Autoencodeur variationnel (*Variational Autoencoder*)
ViT	*Vision Transformer*
VLM	Modèle Vision-Langage (*Vision-Language Model*)
XLM-R	*Cross-lingual Language Model – RoBERTa*

Table des matières

Remerciements i

Résumé ii

Abstract iii

Liste des abréviations iv

Introduction générale 1
Contexte et problématique . . . 1
Objectifs du projet . . . 1
Contributions . . . 2
Organisation du rapport . . . 2

1 Présentation de l'organisme d'accueil et contexte du projet 4
1.1 Présentation de l'organisme d'accueil . . . 4
1.1.1 L'Université Mohammed VI Polytechnique (UM6P) . . . 4
1.1.2 Le centre AI Movement . . . 5
1.1.3 L'environnement de calcul . . . 6
1.1.4 Missions et domaines d'expertise . . . 6
1.1.5 Une dimension africaine, responsable et inclusive . . . 8
1.2 Contexte du projet et problématique . . . 8
1.2.1 L'essor de la génération de mouvement à partir de texte . . . 8
1.2.2 État de l'art de la génération texte → mouvement . . . 9
1.2.3 Le multilinguisme en traitement automatique du langage . . . 10
1.2.4 Le verrou du multilinguisme . . . 10
1.2.5 Question de recherche et positionnement . . . 11

2 Cadre théorique et fondements mathématiques 12
2.1 Rappels d'apprentissage profond . . . 12
2.1.1 Du perceptron au réseau multicouche . . . 12
2.1.2 Apprentissage par descente de gradient . . . 12
2.1.3 Généralisation et régularisation . . . 13
2.2 Représentation du mouvement humain tridimensionnel . . . 13
2.2.1 Du modèle corporel SMPL au squelette . . . 13
2.2.2 La représentation HumanML3D à 263 dimensions . . . 13
2.2.3 Le modèle paramétrique SMPL . . . 14
2.2.4 Arbre cinématique et cinématique directe . . . 14
2.2.5 Rotations continues et normalisation des données . . . 15
2.3 Le Transformer et le mécanisme d'attention . . . 15

2.3.1 Les modèles de séquence avant le Transformer . . . 15
2.3.2 Le mécanisme d'attention . . . 16
2.3.3 Normalisation par $\sqrt{d_k}$ et propriétés du softmax . . . 16
2.3.4 Attention multi-têtes . . . 17
2.3.5 Encodage de position . . . 17
2.3.6 Bloc Transformer, encodeur et décodeur . . . 17
2.3.7 Complexité et motivation des latents séquentiels . . . 17
2.4 Autoencodeurs et autoencodeurs variationnels . . . 18
2.4.1 Autoencodeur déterministe . . . 18
2.4.2 Autoencodeur variationnel (VAE) . . . 19
2.4.3 Dérivation de la borne ELBO . . . 19
2.4.4 L'astuce de reparamétrisation . . . 19
2.4.5 Pondération de la régularisation : le β-VAE . . . 20
2.4.6 Effondrement postérieur et précédent ACTOR . . . 20
2.5 Quantification vectorielle : VQ-VAE et RVQ . . . 20
2.5.1 Le VQ-VAE . . . 20
2.5.2 Pourquoi la quantification change tout pour le mouvement . . . 21
2.5.3 Quantification résiduelle (RVQ) . . . 21
2.6 Apprentissage contrastif et alignement vision–langage . . . 21
2.6.1 CLIP et l'objectif contrastif . . . 22
2.6.2 Interprétation : information mutuelle, température et géométrie . . . 22
2.6.3 Cosinus contre contrastif : le rôle des négatifs . . . 23
2.7 Représentations multilingues . . . 23
2.7.1 XLM-R et M-CLIP . . . 23
2.7.2 Tokenisation en sous-mots . . . 24
2.7.3 Pourquoi le multilinguisme pourrait aider : la typologie . . . 24
2.7.4 Génération du corpus multilingue par traduction automatique . . . 24
2.8 Apprentissage par transfert et modèles gelés . . . 25
2.8.1 Principe du transfert . . . 25
2.8.2 Pourquoi geler l'encodeur de texte . . . 25
2.8.3 Conséquence : le transfert inter-lingue « gratuit » . . . 25
2.9 Métriques d'évaluation génératives . . . 26
2.10 Analyse du goulot d'étranglement latent . . . 27

3 Conception et modélisation de l'architecture 29
3.1 Architecture globale . . . 29
3.1.1 Le jeton de requête et la compression . . . 30
3.2 Prétraitement et normalisation des données . . . 30
3.3 Le pipeline multilingue . . . 31
3.3.1 Substitution de l'encodeur de texte . . . 31
3.3.2 Traduction des légendes . . . 31
3.3.3 Banc d'encodeurs par langue . . . 31
3.4 Formulation variationnelle et fonction de coût . . . 31
3.4.1 Justification des poids de la perte . . . 32
3.5 Les deux objectifs d'alignement . . . 33
3.5.1 Similarité cosinus . . . 33
3.5.2 Entropie croisée contrastive . . . 33

3.6 Justification des choix de conception . . . 33
3.7 Protocole d'évaluation . . . 33
3.7.1 Métriques de génération . . . 34
3.7.2 Mesure de l'alignement latent . . . 34
3.7.3 Amplitude du mouvement . . . 34
3.8 Principe de la comparaison contrôlée . . . 34

4 Implémentation 36
4.1 Environnement matériel et configuration d'entraînement . . . 36
4.2 Réalisation du pipeline multilingue . . . 36
4.3 Chargement et échantillonnage des données . . . 37
4.4 Boucle d'entraînement . . . 37
4.5 Coût computationnel . . . 37
4.6 Outils réutilisables développés . . . 38
4.7 Bogues et pièges connus . . . 38

5 Expériences et résultats 40
5.1 Baseline multilingue . . . 40
5.2 Encodeurs par langue, première tentative . . . 41
5.3 La série KL : l'échantillonnage, pas la régularisation . . . 41
5.4 Reconstruction déterministe et VAE fonctionnel . . . 42
5.5 Robustesse au bruit : une branche délibérément fermée . . . 43
5.6 L'alignement n'est pas ce que mesure la moyenne cosinus . . . 43
5.7 Alignement contrastif à travers les langues . . . 44
5.8 Le compromis génération–discrimination . . . 45
5.9 L'effondrement de l'amplitude du mouvement . . . 46
5.10 Reconstruction conditionnée par le texte . . . 47
5.11 Comparaison contrôlée : EN / Latines / Éloignées / Toutes . . . 48
5.12 Analyse qualitative et des erreurs . . . 49
5.13 Robustesse et reproductibilité . . . 50

6 Discussion, limites et perspectives 53
6.1 Ce que les mesures établissent . . . 53
6.2 Menaces à la validité . . . 53
6.3 Explications alternatives écartées . . . 54
6.4 Comparaison avec la littérature . . . 54
6.5 Vers une séquence de latents . . . 54
6.5.1 Feuille de route technique . . . 55
6.6 Synthèse des résultats . . . 55

Conclusion générale et perspectives 57

A Détails d'implémentation et reproduction 58
A.1 Matériel et configuration . . . 58
A.2 Commandes de reproduction . . . 58
A.3 Fils ouverts . . . 58

B Index des expériences 59

C Tableaux et figures supplémentaires **60**

D Compléments mathématiques **62**
D.1 Forme close de la divergence KL gaussienne 62
D.2 Distance de Fréchet entre deux gaussiennes 62
D.3 InfoNCE comme borne de l'information mutuelle 63
D.4 Variance du gradient reparamétré 63

E Configuration expérimentale complète **64**
E.1 Hyperparamètres 64
E.2 Environnement logiciel et matériel 64
E.3 Détails du jeu de données 65

F Résultats détaillés par langue **66**
F.1 Écart d'alignement par langue et par époque 66
F.2 Lecture croisée R@1 et écart d'alignement 66
F.3 Couverture par famille de langues 66

G Notes de transmission et déroulé du stage **68**
G.1 Déroulé chronologique 68
G.2 Enseignements pratiques 68
G.3 Pour démarrer la suite 69

H Glossaire des termes techniques **70**

Bibliographie **73**

Table des figures

1.1 Le campus principal de l'UM6P à Benguérir, au sein de la Ville Verte Mohammed VI, reconnaissable à sa canopée centrale. *(Source : Le360, Wikimedia Commons, licence CC BY 3.0.)* 5
1.2 Logos institutionnels de l'UM6P, du centre AI Movement et de l'UNESCO, sous l'égide de laquelle le centre a été établi. 5
1.3 Le mont Toubkal (Haut Atlas), point culminant de l'Afrique du Nord, dont le supercalculateur de l'UM6P tire son nom. *(Source : Yasminaou01, Wikimedia Commons, licence CC BY-SA 4.0.)* 6
1.4 La tâche de génération texte→mouvement : un modèle conditionnel transforme une description en langage naturel en une séquence de poses corporelles tridimensionnelles. 8

2.1 Représentation squelettique du corps humain : chaque articulation est un point 3D, relié à ses voisines par des segments. La racine (bassin) porte le repère global par rapport auquel les positions locales sont exprimées. . . . 13
2.2 Le mécanisme d'attention de l'équation (2.5) : les similarités requête–clé, normalisées par un softmax, pondèrent les valeurs pour produire chaque vecteur de sortie. 16
2.3 Structure d'un bloc Transformer : chaque sous-couche (attention multi-têtes, puis réseau feed-forward) est suivie d'une addition résiduelle (+, l'entrée de la sous-couche est réinjectée) et d'une normalisation de couche. 18
2.4 Autoencodeur variationnel avec reparamétrisation (équation (2.15)) : l'encodeur produit (μ, σ), le latent est tiré en injectant un bruit externe ε, puis décodé en $\hat{x}$. 20
2.5 Quantification résiduelle (RVQ) : chaque niveau $q^{(\ell)}$ quantifie le résidu laissé par le niveau précédent, affinant progressivement l'approximation du vecteur continu z_e. 21
2.6 Matrice de similarités d'un lot contrastif. L'objectif InfoNCE (équation (2.20)) élève la diagonale (paires appariées) au-dessus du reste de chaque ligne et de chaque colonne. Les *négatifs* hors-diagonale sont le mécanisme absent de la simple similarité cosinus. 22
2.7 Pourquoi un latent unique ne peut absorber le bruit d'échantillonnage. À gauche, les 60 images dépendent d'un seul z : le bruit injecté dégrade le clip entier (la somme de l'équation (2.23) porte sur toutes les images). À droite, avec un latent par segment, la plupart des blocs jacobiens s'annulent et la pénalité par latent chute d'un facteur $\approx K$. 28

3.1 Architecture du système. Un clip de 60 images est compressé par l'encodeur en un latent unique de dimension 512, puis reconstruit par le décodeur. Un encodeur de texte multilingue gelé produit e_{texte}, aligné sur le latent μ. **À la génération**, le décodeur reçoit e_{texte} à la place de μ : une substitution que la perte de base n'optimise jamais (section 5.10). 29
3.2 Chaîne de traitement multilingue : les légendes anglaises sont traduites par NLLB en six langues, une langue est échantillonnée par clip et par époque, encodée par M-CLIP gelé puis projetée, et enfin alignée sur le latent de mouvement. 31

5.1 Écart d'alignement (cosinus apparié − non apparié) en fonction de l'époque, une courbe par langue, CE contrastif. L'écart croît de façon monotone dans chaque langue, sans plateau. L'ordre es ≈ en > fr > pt > ar ≈ ru > zh est *identique à chaque point de contrôle* : c'est une structure, et non du bruit. Le chinois accuse un retard de 28 % sur l'anglais à l'époque 100. 45
5.2 Amplitude du mouvement en fonction de l'époque pour deux entraînements (axe y logarithmique). L'amplitude décroît de façon monotone à mesure que l'entraînement progresse. Le modèle « meilleur » à 20 époques du tableau 5.11 est simplement *moins convergé* : sa forte amplitude est de la variance sous-entraînée, non un mouvement supérieur. 47
5.3 Squelettes générés, cinq *prompts* (lignes) échantillonnés à cinq instants (colonnes) depuis un modèle entraîné, caméra et cadrage fixes. Au sein de chaque ligne, la pose change à peine sur les 60 images, et d'une ligne à l'autre les poses sont quasi identiques : l'effondrement de l'amplitude rendu visible. 51
5.4 R@1 par langue selon les quatre conditions de langues. Latines rehausse fr/es/pt ; Éloignées rehausse ru/zh/ar ; Toutes donne la couverture la plus uniforme. Chaque groupe de barres culmine sur les langues de sa condition : un compromis couverture/qualité, et non une dégradation. Ligne pointillée : hasard (0,002). 52

C.1 Écart d'alignement en fonction de l'époque sur l'entraînement long de 300 époques, une courbe par langue. Aucun plateau à 300 époques ; l'ordre inter-lingue est le même qu'en figure 5.1. C'est la preuve de la limite « courbes non convergées » de la section 6.2. 60
C.2 Courbes d'entraînement (rc, vel, KL, cosinus-texte) pour les VAE anglais et multilingue. La reconstruction, la vitesse et le KL suivent des trajectoires proches ; les deux ne divergent que sur le cosinus-texte, une différence que la section 5.6 montre non informative sur l'alignement par échantillon. . . . 61
C.3 Reconstruction de validation sous bruit injecté $z = \mu + \beta\varepsilon$ pour la branche de robustesse au bruit de la section 5.5. L'affinage à $\beta = 0{,}10$ améliore la reconstruction sous bruit (les +25,5 % rapportés) mais dégrade la génération (tableau 5.6). 61

Liste des tableaux

1.1 Positionnement comparatif des principales familles de génération texte→mouvement. 10

2.1 Complexité par couche selon le type de réseau séquentiel (N : longueur de séquence, d : dimension du modèle). 18

3.1 Dimensions principales du modèle. 30
3.2 Termes de la fonction de coût de l'équation (3.1). Poids par défaut : $\lambda_{\text{rc}} = \lambda_{\text{vel}} = 100$, $\lambda_{\text{KL}} = 10^{-3}$; $\lambda_{\cos}$ et λ_{CE} varient selon l'expérience. 32
3.3 Principaux choix de conception, justification et compromis. 33
3.4 Les deux évaluateurs et leurs domaines d'emploi. Leurs FID ne sont pas comparables car ils reposent sur des jeux de test et des extracteurs distincts. 34

4.1 Ordres de grandeur du coût de calcul (GPU RTX 5090, lot 128). 38

5.1 Baseline multilingue. **Évaluateur A**, split officiel HumanML3D, 20 réplications. Meilleure valeur de modèle par colonne en gras. 40
5.2 La série KL (échantillonnage actif). Perte de reconstruction sous quatre interventions. Écart total : 0,002. 41
5.3 Banc KL. **Évaluateur B**, pool de validation de 1 400 clips, 20 réplications. Le KL aide ; le recuit nuit. 42
5.4 Entraînement déterministe-puis-stochastique. L'échantillonnage n'est activé qu'après 300 époques déterministes. 42
5.5 Reconstruction sous bruit injecté $z = \mu + \beta\varepsilon$. 43
5.6 Effet en aval de l'affinage à $\beta = 0{,}10$. **Évaluateur B**. Le gain auxiliaire ne se transfère pas. 43
5.7 FID par langue, pool multilingue (**Évaluateur B**, pas le split officiel). Uniforme d'une langue à l'autre. 43
5.8 Cosinus apparié contre non apparié, 500 clips, légendes parallèles (anglais). C'est l'écart, et non la moyenne, qui reflète l'alignement. 44
5.9 Écart d'alignement par langue sous CE contrastif, au cours de l'entraînement. Monotone dans chaque langue ; ordre identique à chaque point de contrôle. 44
5.10 Le compromis génération–discrimination. **Évaluateur B**. Le CE contrastif achète l'alignement et la récupération au prix du FID. 46
5.11 Amplitude du mouvement (différence absolue moyenne image-à-image) et différence entre *prompts* (marche contre saut). Les modèles mieux entraînés bougent moins. 46
5.12 Reconstruction conditionnée par le texte et choix de l'encodeur, 150 époques. « marche/saut » est la différence entre *prompts* (force du conditionnement). 48

5.13 Comparaison contrôlée. Toutes les conditions identiques sauf l'ensemble de langues. R@1 anglais, écart anglais, dispersion inter-lingue et génération. Meilleure valeur par colonne en gras. 48
5.14 R@1 par langue selon la condition d'entraînement. Chaque condition est la meilleure sur ses propres langues ; « Toutes » achète la couverture la plus uniforme au prix de la performance de pointe. Meilleure valeur par langue en gras. 49

6.1 Bilan synthétique des résultats et de leur cause mécanistique. 56

C.1 Écart d'alignement par langue selon la condition d'entraînement (500 clips, légendes parallèles), complément du tableau 5.14. 60
C.2 Perte combinée (CE + cosinus), cosinus apparié/non apparié et écart par langue. Le terme cosinus élève la similarité absolue à ∼0,55 tout en préservant un écart réel. 61

E.1 Hyperparamètres par défaut. 64

F.1 Écart d'alignement par langue et par époque (CE contrastif), valeurs détaillées. 66
F.2 Lecture croisée en anglais : R@1 et écart d'alignement par condition. . . . 67
F.3 R@1 moyenne par famille de langues (hors anglais), selon la condition. . . 67

Introduction générale

Contexte et problématique

L'intelligence artificielle générative traverse une phase de transformation majeure. Après les grands modèles de langage, puis les modèles de génération d'images, un champ plus récent s'attaque à une modalité intrinsèquement *temporelle* et *tridimensionnelle* : la **génération de mouvement humain** à partir de texte. L'objectif est de synthétiser, à partir d'une phrase en langage naturel telle que *« une personne marche puis s'assoit »*, une séquence plausible de poses corporelles en trois dimensions. Les applications sont nombreuses, animation, jeu vidéo, réalité virtuelle, robotique, avatars, rééducation, et le domaine a progressé très rapidement ces dernières années.

Ce progrès souffre toutefois d'un biais fondamental : il s'est construit *presque exclusivement en anglais*. Le jeu de données de référence, HumanML3D [1], ne contient que des légendes anglaises, et les modèles les plus performants [2, 3] sont entraînés et évalués uniquement sur ce corpus. Un utilisateur qui décrit un mouvement en français, en russe ou en arabe se trouve, en pratique, exclu de ces systèmes.

Rendre ces systèmes multilingues soulève une question qui n'est pas seulement d'ingénierie. Les langues humaines encodent différemment la *manière* dont un mouvement est effectué, sa *trajectoire* et son *aspect* temporel. Si un modèle multilingue savait exploiter ces différences, les langues supplémentaires pourraient apporter un *signal complémentaire* sur le mouvement lui-même. Si, au contraire, les langues ne font que se disputer un budget représentationnel fixe, les ajouter dégraderait l'espace partagé. Déterminer lequel de ces deux régimes se produit est une question **empirique**, qui n'avait pas été tranchée dans des conditions contrôlées.

Objectifs du projet

La question concrète posée par les encadrants, et à laquelle ce stage s'est attaché à répondre, est la suivante :

> *Des projections de texte par langue, entraînées indépendamment, amènent-elles plusieurs langues dans un espace latent de mouvement commun ? Et le conditionnement multilingue aide-t-il ou nuit-il à la représentation du mouvement sous-jacente, une fois la capacité du modèle et le budget de calcul appariés ?*

Répondre à cette question a imposé trois objectifs opérationnels :

1. **Construire un pipeline multilingue** sur la base de MotionCLIP, en remplaçant l'encodeur de texte par un encodeur multilingue (M-CLIP) et par un banc d'encodeurs monolingues, et en générant un corpus multilingue par traduction automatique.

2. **Mener une comparaison contrôlée** anglais seul contre multilingue, *à capacité et à nombre de pas de gradient appariés*, évaluée sur un même jeu de test afin que les chiffres soient comparables.
3. **Localiser l'origine** de toute dégradation inter-lingue, dans l'encodeur de texte gelé, ou dans le latent de mouvement entraîné, en mesurant séparément l'alignement dans l'espace textuel et dans l'espace latent. Un fil conducteur du rapport est que cette seconde mesure, effectuée sans précaution, donne exactement la mauvaise réponse.

Contributions

Les principales contributions de ce travail sont les suivantes.

1. **Un diagnostic contre-intuitif du VAE de mouvement à latent unique :** nous montrons, par quatre interventions couvrant deux ordres de grandeur du poids KL, que c'est l'*échantillonnage*, et non la force de la régularisation, qui détruit la reconstruction (déplacement de seulement 0,002), et nous en donnons un argument théorique au premier ordre (proposition du goulot latent).
2. **Un modèle variationnel fonctionnel** obtenu par entraînement déterministe-puis-stochastique, qui rétablit la reconstruction avec l'échantillonnage actif.
3. **Une correction de la mesure d'alignement :** nous démontrons que la moyenne cosinus texte–mouvement est un diagnostic trompeur (optimum trivial), et proposons l'écart apparié–non-apparié, qui prédit correctement la récupération.
4. **Une mise en évidence de la dissociation** entre qualité d'alignement et qualité de génération, et de l'*effondrement de l'amplitude* sous reconstruction MSE.
5. **La première comparaison contrôlée**, à capacité et calcul appariés, entre conditionnement anglais et multilingue, concluant que les langues divisent un budget représentationnel fixe plutôt qu'elles ne l'enrichissent.
6. **Un résultat de conception positif :** la perte combinée contrastif + cosinus, qui restaure la diversité à FID inchangé et offre la couverture inter-lingue la plus uniforme.
7. **Deux résultats négatifs rapportés en entier** (robustesse au bruit ; première comparaison des encodeurs par langue sous un objectif ultérieurement invalidé), informatifs pour la suite.
8. **Une proposition architecturale falsifiable** (séquence de latents discrets, MoMask conditionné par M-CLIP) et une feuille de route expérimentale.

Organisation du rapport

Le présent rapport est organisé en six chapitres. Le **chapitre 1** présente l'organisme d'accueil, l'UM6P et le centre AI Movement, puis précise le contexte scientifique et la problématique du projet. Le **chapitre 2** constitue le cadre théorique et les fondements mathématiques du travail : représentation du mouvement 3D, architecture Transformer et mécanisme d'attention, autoencodeurs variationnels, apprentissage contrastif et alignement vision–langage, représentations multilingues, métriques d'évaluation, et analyse du goulot d'étranglement latent. Le **chapitre 3** décrit la conception et la modélisation

de l'architecture, le pipeline multilingue, la fonction de coût et le protocole d'évaluation. Le **chapitre 4** détaille l'implémentation. Le **chapitre 5** présente les expériences et les résultats, dans l'ordre narratif où chaque résultat a motivé le suivant. Le **chapitre 6** discute les menaces à la validité et développe la proposition prospective. Une conclusion générale et des perspectives closent le document.

Chapitre 1

Présentation de l'organisme d'accueil et contexte du projet

Ce chapitre présente le cadre institutionnel dans lequel ce projet de fin d'année a été réalisé, puis situe scientifiquement la problématique abordée. La première partie décrit l'organisme d'accueil, l'Université Mohammed VI Polytechnique et son centre de recherche AI Movement, ainsi que ses missions et son environnement de calcul. La seconde partie introduit le domaine de la génération de mouvement à partir de texte, met en évidence le verrou du multilinguisme et formule la question de recherche traitée dans la suite du document.

1.1 Présentation de l'organisme d'accueil

1.1.1 L'Université Mohammed VI Polytechnique (UM6P)

L'Université Mohammed VI Polytechnique (UM6P) est une université marocaine à vocation internationale, orientée vers la recherche scientifique, l'innovation, la formation d'excellence et le développement de solutions répondant aux enjeux économiques, technologiques, environnementaux et sociaux du Maroc et du continent africain. Fondée sous l'impulsion du Groupe OCP, l'UM6P s'inscrit dans une démarche visant à rapprocher la formation académique, la recherche scientifique, le monde industriel et l'entrepreneuriat.

Son positionnement repose notamment sur une approche expérimentale de l'apprentissage et de la recherche, ainsi que sur le développement de partenariats avec des institutions académiques, industrielles et publiques aux niveaux national et international. L'université développe ainsi un modèle fortement orienté vers la production de connaissances et leur transformation en applications concrètes, avec une importance particulière accordée aux sciences et technologies, à l'intelligence artificielle, à la science des données, à l'agriculture, à l'énergie, à la santé et aux sciences des matériaux. Son campus principal se situe à Benguérir, au sein de la Ville Verte Mohammed VI (figure 1.1), tandis que d'autres implantations universitaires et scientifiques se trouvent notamment à Rabat.

L'université s'organise autour de plusieurs écoles et centres de recherche couvrant un large spectre disciplinaire : sciences et ingénierie, sciences des matériaux, agriculture et sécurité alimentaire, sciences économiques et sociales, énergie, et, de façon transverse, sciences des données et intelligence artificielle. Cette structuration vise explicitement à décloisonner la recherche fondamentale, l'expérimentation et l'application industrielle. L'intelligence artificielle y occupe une place stratégique, à la fois comme domaine de recherche à part entière et comme levier transversal au service des autres disciplines ; c'est dans cette dynamique que s'inscrit le centre AI Movement.



Figure 1.1. Le campus principal de l'UM6P à Benguérir, au sein de la Ville Verte Mohammed VI, reconnaissable à sa canopée centrale. *(Source : Le360, Wikimedia Commons, licence CC BY 3.0.)*

Figure 1.2. Logos institutionnels de l'UM6P, du centre AI Movement et de l'UNESCO, sous l'égide de laquelle le centre a été établi.

1.1.2 Le centre AI Movement

Le Centre International d'Intelligence Artificielle du Maroc, connu sous le nom d'*AI Movement*, constitue un centre d'excellence consacré à l'intelligence artificielle et aux sciences des données au sein de l'écosystème de l'UM6P, établi sous l'égide de l'UNESCO. Sa création répond à une volonté de développer une capacité nationale et africaine en matière d'intelligence artificielle, tout en favorisant l'ouverture du Maroc sur les réseaux scientifiques et technologiques internationaux.

AI Movement se positionne comme un pôle dédié à la recherche, à l'innovation et à la transformation par l'intelligence artificielle. Sa vocation ne se limite pas au développement de modèles ou d'outils : le centre cherche également à favoriser l'émergence d'un écosystème réunissant chercheurs, étudiants, industriels, institutions publiques et partenaires internationaux. Le projet a notamment été porté par la Professeure Amal El Fallah Seghrouchni, spécialiste de l'intelligence artificielle distribuée et des systèmes multi-agents, qui assure la direction du centre. Sous son impulsion, AI Movement développe des activités combinant recherche scientifique, formation, innovation technologique, transfert industriel et réflexion sur les impacts de l'intelligence artificielle.

Le centre conduit des travaux dans plusieurs domaines complémentaires : la vision par ordinateur, le traitement automatique du langage naturel, l'apprentissage automatique et profond, les systèmes multi-agents et l'IA incarnée. Le travail présenté dans ce rapport se situe précisément à l'intersection des deux premiers axes : la *génération de mouvement humain tridimensionnel à partir de descriptions en langage naturel*, avec un accent mis sur les langues autres que l'anglais.

1.1.3 L'environnement de calcul

Le développement de travaux de recherche en intelligence artificielle, en particulier l'entraînement de modèles d'apprentissage profond, nécessite des capacités de calcul importantes. L'écosystème de l'UM6P dispose à ce titre du supercalculateur *Toubkal*, infrastructure de calcul haute performance (*High-Performance Computing*, HPC) hébergée à Benguérir et nommée d'après le point culminant du Maroc dans le Haut Atlas (figure 1.3). Son déploiement constitue une étape importante dans le développement des capacités nationales et africaines de calcul intensif ; il illustre la convergence croissante entre le HPC et l'intelligence artificielle, les architectures modernes d'apprentissage profond reposant largement sur des accélérateurs matériels, en particulier des processeurs graphiques (GPU) permettant d'exécuter efficacement un grand nombre d'opérations matricielles en parallèle.



Figure 1.3. Le mont Toubkal (Haut Atlas), point culminant de l'Afrique du Nord, dont le supercalculateur de l'UM6P tire son nom. *(Source : Yasminaou01, Wikimedia Commons, licence CC BY-SA 4.0.)*

Il convient de distinguer le *centre* AI Movement de l'*infrastructure* Toubkal : cette dernière est une ressource de calcul mutualisée de l'UM6P, susceptible de soutenir des travaux de recherche très variés, et non un équipement propre au centre. Elle n'en reste pas moins emblématique de l'ambition de doter l'écosystème marocain et africain de moyens de calcul à la hauteur des besoins de l'apprentissage profond moderne.

Le stage s'est déroulé sur une durée de **dix semaines**. Les expériences décrites dans ce rapport ont été menées sur une station de travail équipée d'un GPU **NVIDIA RTX 5090** (32 Go de mémoire), partagée au sein de l'équipe. Si cette ressource est modeste au regard d'une grappe de calcul complète, elle s'est révélée suffisante pour une démarche de recherche fondée sur des *expériences contrôlées* de petite à moyenne échelle, où la rigueur méthodologique prime sur le volume brut de calcul.

1.1.4 Missions et domaines d'expertise

La mission d'AI Movement dépasse le cadre strict de la recherche académique. Le centre vise à structurer un écosystème capable de réunir les compétences nationales

et internationales en intelligence artificielle, notamment par l'attraction d'experts, la création de partenariats scientifiques et le développement de collaborations entre chercheurs marocains et étrangers. Ses missions s'articulent autour de plusieurs axes :

— **Recherche scientifique et développement technologique** : associer recherche théorique, recherche appliquée, développement technologique, innovation et transfert industriel, en rapprochant les laboratoires de recherche des problématiques concrètes rencontrées par les acteurs économiques et sociaux.

— **Formation et développement des compétences** : favoriser l'appropriation des technologies d'IA par différentes catégories de public, des étudiants et jeunes chercheurs jusqu'aux professionnels, à travers des activités de formation, d'encadrement scientifique, de séminaires et de conférences.

— **Transfert technologique et entrepreneuriat** : transformer les résultats scientifiques en technologies et produits à forte valeur ajoutée et encourager l'entrepreneuriat technologique.

— **IA responsable et éthique** : porter une attention particulière à la transparence, à l'équité, à la protection des données, à la robustesse et à l'explicabilité des modèles. Cette dimension revêt une importance particulière dans le contexte africain, où les modèles entraînés majoritairement sur des données provenant d'autres régions du monde peuvent présenter des performances variables lorsqu'ils sont appliqués à des populations, des langues ou des contextes culturels différents.

Ce dernier point, l'inclusion linguistique et culturelle, rejoint directement la motivation du présent projet. L'ambition africaine et internationale du centre, qui cherche à contribuer à un écosystème de compétences dépassant le cadre strictement national, trouve un prolongement naturel dans l'étude de modèles capables de traiter des descriptions de mouvement dans plusieurs langues, et non uniquement en anglais.

Diversité des axes de recherche. Les travaux menés au sein de l'écosystème AI Movement couvrent un éventail large : apprentissage automatique et profond, vision par ordinateur, traitement automatique du langage naturel, systèmes multi-agents, agents intelligents, IA hybride, systèmes autonomes et IA explicable. Cette diversité permet d'aborder des problématiques nécessitant le traitement de données hétérogènes et favorise les interactions entre disciplines. Le projet présenté ici, à la croisée de la vision et du langage, illustre précisément cette transversalité.

IA hybride et systèmes intelligents. Une caractéristique de l'approche défendue par le centre réside dans la complémentarité entre différents paradigmes. L'IA hybride cherche à associer, selon les besoins, des approches fondées sur l'apprentissage et des approches symboliques ou à base de connaissances, ouvrant la voie à des systèmes plus interprétables, plus adaptables et mieux intégrés à leur environnement. Les systèmes multi-agents, historiquement liés aux travaux de la direction du centre, en sont un exemple : plusieurs agents autonomes y perçoivent, communiquent, coopèrent ou négocient afin d'atteindre des objectifs individuels ou collectifs.

Formation et transfert. Le centre participe à des activités de formation, d'encadrement scientifique, de séminaires et de conférences, et accorde une attention à la sensibilisation

aux transformations induites par l'IA. Il cherche aussi à transformer les résultats de la recherche en technologies et produits à forte valeur ajoutée, en développant des relations étroites avec le monde industriel et en encourageant l'entrepreneuriat technologique. Les domaines d'application visés incluent l'énergie, l'industrie, la santé, l'agriculture, la finance et les services numériques.

1.1.5 Une dimension africaine, responsable et inclusive

L'une des spécificités d'AI Movement réside dans son ambition de contribuer au développement de l'intelligence artificielle à l'échelle africaine. Le centre ne se limite pas à une mission nationale : il cherche à participer à la constitution d'un écosystème continental de recherche, de formation et d'innovation. Cette ambition s'accompagne d'une attention soutenue à l'*IA responsable* : transparence, équité, protection des données et, surtout pour ce qui nous concerne, *inclusion*.

Les systèmes d'intelligence artificielle reproduisent et amplifient les biais présents dans leurs données d'entraînement. Un modèle de génération de mouvement entraîné exclusivement sur des légendes anglaises encode implicitement une conception anglophone de la description du geste ; appliqué à des utilisateurs s'exprimant dans d'autres langues, il peut se révéler moins performant, voire inutilisable. Étudier *si* et *comment* de tels modèles peuvent devenir multilingues n'est donc pas qu'un exercice technique : c'est une contribution directe à l'objectif d'inclusion porté par le centre. C'est dans cette double perspective, scientifique et sociétale, que s'inscrit le présent projet.

1.2 Contexte du projet et problématique

1.2.1 L'essor de la génération de mouvement à partir de texte

La génération de mouvement humain à partir de texte s'inscrit dans l'essor plus large des modèles *multimodaux*, capables de mettre en correspondance des modalités de nature différente, ici le langage et le mouvement tridimensionnel. Formellement, il s'agit, à partir d'une description textuelle c, de produire une séquence de poses $x = (x_1, \ldots, x_T)$ où chaque x_t décrit la configuration du corps à l'instant t. La figure 1.4 illustre schématiquement cette tâche.

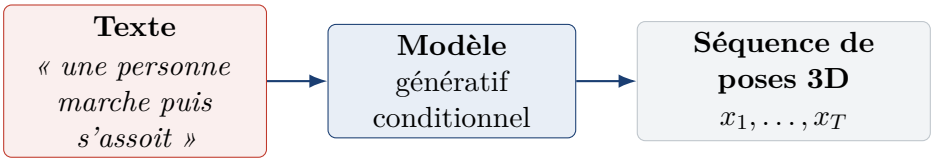


Figure 1.4. La tâche de génération texte→mouvement : un modèle conditionnel transforme une description en langage naturel en une séquence de poses corporelles tridimensionnelles.

Trois familles de modèles encadrent le travail présenté ici. *MotionCLIP* [4] est un autoencodeur transformeur qui aligne un unique latent de mouvement sur l'espace d'embedding figé de CLIP ; c'est un générateur relativement faible, mais d'une simplicité et d'une transparence inhabituelles, ce qui en fait un modèle de base idéal pour une étude contrôlée. *MDM* [2] est un modèle de diffusion opérant directement sur la séquence de

mouvement, et *MoMask* [3] est un transformeur masqué à quantification vectorielle résiduelle qui produit une *séquence de tokens discrets*. MDM et MoMask sont des générateurs nettement plus puissants ; la conception de MoMask en séquence de tokens est précisément l'architecture vers laquelle pointe l'argument final de ce rapport (chapitre 6).

> **Un repère à garder à l'esprit.** Le FID publié sur HumanML3D pour les modèles performants se situe dans la plage 0,05–0,5 [3]. Tous les FID rapportés dans ce travail sont un à deux ordres de grandeur plus élevés. MotionCLIP est un générateur *faible*, et les comparaisons menées ici sont *relatives*, et non absolues.

1.2.2 État de l'art de la génération texte → mouvement

La génération de mouvement à partir de texte a connu trois grandes familles d'approches, qu'il est utile de situer pour comprendre le positionnement de ce travail.

Approches par espace latent aligné (MotionCLIP). **MotionCLIP** [4] aligne un latent de mouvement sur l'espace d'embedding figé de CLIP [5]. L'idée séduisante est d'hériter « gratuitement » de la richesse sémantique de CLIP : comme le texte et l'image y sont déjà alignés, aligner le mouvement sur le texte revient à l'ancrer dans un espace sémantique vaste. En contrepartie, MotionCLIP est un générateur faible, car il comprime tout un clip en un unique vecteur et s'appuie sur une simple similarité cosinus. C'est précisément cette simplicité qui en fait un banc d'essai idéal pour une étude contrôlée des mécanismes d'alignement et de régularisation.

Approches par diffusion (MDM). **MDM** [2] applique un modèle de diffusion directement sur la séquence de poses : un processus apprend à débruiter progressivement un mouvement initialement aléatoire, conditionné par le texte. Cette approche produit des mouvements nettement plus réalistes et diversifiés, au prix d'un échantillonnage itératif coûteux. Elle démontre que conserver la *dimension temporelle* (plutôt que de la comprimer) est déterminant pour la qualité.

Approches par tokens discrets (MoMask). **MoMask** [3] représente un mouvement comme une *séquence de tokens discrets* obtenus par quantification vectorielle résiduelle (RVQ), qu'un transformeur masqué génère ensuite de façon itérative. C'est l'état de l'art en qualité de génération. Son architecture en séquence de latents discrets est exactement celle vers laquelle pointe la proposition prospective de ce rapport (chapitre 6) : elle contourne structurellement les trois défaillances que nous mettons en évidence sur le latent unique.

Le banc d'essai HumanML3D et ses extensions. L'ensemble de ces modèles est évalué sur HumanML3D [1], devenu le standard de fait. Les travaux récents en multilinguisme, notamment **BiHumanML3D** [6], proposent une ré-annotation bilingue de HumanML3D assortie d'un module d'alignement inter-lingue projetant le texte non anglais dans l'espace de mouvement entraîné en anglais. L'hypothèse communément admise y est que le signal multilingue est, au pire, *neutre* pour la représentation du mouvement. C'est cette hypothèse que le présent travail soumet à un test contrôlé.

Le tableau 1.1 résume le positionnement de ces familles selon trois axes : la nature de la représentation du mouvement, le type de conditionnement textuel et la qualité de génération.

Tableau 1.1. Positionnement comparatif des principales familles de génération texte→mouvement.

Modèle	Représentation	Conditionnement	Génération
MotionCLIP	latent unique continu	CLIP (cosinus)	faible
T2M [1]	latent variationnel	texte + VAE	moyenne
MDM	séquence continue	diffusion	forte
MoMask	séquence de tokens (RVQ)	transformeur masqué	état de l'art
Ce travail	latent unique + multilingue	M-CLIP (cosinus/CE)	faible (étude contrôlée)

On observe une corrélation nette : les approches qui *préservent la dimension temporelle* (MDM, MoMask) génèrent nettement mieux que celles qui la *compriment* en un point (MotionCLIP). Ce constat, dressé ici au niveau de l'état de l'art, sera retrouvé de l'intérieur par l'analyse expérimentale : c'est la compression en un latent unique qui limite MotionCLIP, et non le conditionnement textuel en lui-même.

1.2.3 Le multilinguisme en traitement automatique du langage

Le multilinguisme n'est pas propre au mouvement : il est étudié depuis longtemps en traitement automatique du langage. Deux constats issus de ce domaine éclairent directement notre question. *D'une part*, les modèles massivement multilingues comme XLM-R [7] montrent un *transfert inter-lingue* remarquable : un modèle affiné sur une langue fonctionne souvent, sans données supplémentaires, sur des langues qu'il n'a vues qu'au pré-entraînement. *D'autre part*, ces mêmes travaux décrivent une *malédiction du multilinguisme* : à capacité fixe, ajouter des langues finit par dégrader la performance de chacune, parce que toutes se partagent les mêmes paramètres. Les auteurs de XLM-R observent ainsi que, au-delà d'un certain nombre de langues, il faut augmenter la taille du modèle pour maintenir la qualité.

Ces deux phénomènes correspondent exactement aux deux hypothèses de notre étude : le transfert inter-lingue rejoint l'hypothèse de la supervision enrichie, et la malédiction du multilinguisme celle de l'espace partagé appauvri. Notre contribution est de mesurer lequel domine pour le *mouvement*, sur un modèle dont la capacité est volontairement fixe. La section 5.11 montre que nous observons les deux à la fois : un transfert réel vers des langues jamais vues, et une division du budget sur les langues entraînées.

1.2.4 Le verrou du multilinguisme

Comme indiqué en introduction, l'ensemble de cet écosystème s'est développé sur un corpus exclusivement anglais, HumanML3D [1]. Cette mono-langue n'est pas qu'une

limitation pratique ; elle soulève une question scientifique précise. On distingue deux hypothèses concurrentes :

— **Hypothèse de la supervision enrichie.** Les langues encodant différemment la manière, la trajectoire et l'aspect d'un mouvement, un modèle multilingue pourrait disposer d'un signal *complémentaire* et apprendre une représentation du mouvement plus riche que son homologue monolingue.

— **Hypothèse de l'espace partagé appauvri.** À capacité fixe, les langues se partagent un budget représentationnel borné ; les ajouter reviendrait alors à *diviser* ce budget, dégradant la qualité de l'espace latent plutôt que de l'enrichir.

Les travaux récents sur le multilinguisme en génération de mouvement, notamment le banc d'essai BiHumanML3D [6], supposent le plus souvent que le signal multilingue est, au pire, neutre pour la représentation du mouvement sous-jacente. Ce rapport teste cette hypothèse directement, dans des conditions contrôlées.

1.2.5 Question de recherche et positionnement

La question centrale, déjà énoncée en introduction, peut être reformulée en deux sous-questions mesurables :

RQ1. Des projections de texte entraînées *indépendamment* pour chaque langue placent-elles plusieurs langues dans un espace latent de mouvement *commun* ? (Question d'*alignement*.)

RQ2. À capacité et à budget de calcul appariés, le conditionnement multilingue *aide-t-il ou nuit-il* à la représentation du mouvement, mesurée sur un jeu de test commun ? (Question de *qualité*.)

Répondre à ces questions suppose une comparaison qui, à notre connaissance, n'avait pas été menée : anglais seul contre multilingue, *appariés en capacité de modèle et en nombre de pas de gradient*, évalués sur un même jeu de test afin que les chiffres soient directement comparables. Elle suppose aussi de *localiser* l'origine de toute dégradation, dans l'encodeur de texte figé, ou dans le latent de mouvement entraîné. Comme on le verra, cette seconde mesure, effectuée sans précaution méthodologique, conduit à une conclusion erronée : une part importante de ce rapport consiste précisément à construire la bonne mesure d'alignement.

Chapitre 2

Cadre théorique et fondements mathématiques

Ce chapitre rassemble les fondements théoriques nécessaires à la compréhension du travail. Après quelques rappels d'apprentissage profond (section 2.1), il décrit la manière dont un mouvement humain est représenté numériquement (section 2.2), introduit l'architecture Transformer et le mécanisme d'attention qui sous-tendent le modèle (section 2.3), puis développe la théorie des autoencodeurs variationnels (section 2.4) et de la quantification vectorielle (section 2.5), celle de l'apprentissage contrastif et de l'alignement vision–langage (section 2.6), les représentations multilingues (section 2.7) et l'apprentissage par transfert (section 2.8). Il présente ensuite les métriques d'évaluation génératives (section 2.9) et se clôt par une analyse mathématique du goulot d'étranglement latent (section 2.10), qui fournit l'armature théorique de plusieurs résultats du chapitre 5.

2.1 Rappels d'apprentissage profond

Avant d'aborder les architectures spécifiques, on rappelle brièvement les notions d'apprentissage profond mobilisées dans tout le rapport.

2.1.1 Du perceptron au réseau multicouche

L'unité de base est le *neurone artificiel*, qui calcule une combinaison linéaire de ses entrées suivie d'une non-linéarité : $y = \varphi(w^\top x + b)$, où w est un vecteur de poids, b un biais et φ une fonction d'activation. Un *réseau multicouche* (MLP) empile de telles unités en couches successives, de sorte que la sortie d'une couche alimente la suivante. La fonction d'activation employée ici est la **GELU** [8] (*Gaussian Error Linear Unit*), $\varphi(x) = x\,\Phi(x)$ où Φ est la fonction de répartition de la loi normale ; elle est lisse et différentiable partout, ce qui facilite l'optimisation. Le théorème d'approximation universelle garantit qu'un MLP suffisamment large peut approcher n'importe quelle fonction continue ; en pratique, c'est la *profondeur* et les *structures spécialisées* (attention, convolutions) qui rendent l'apprentissage efficace.

2.1.2 Apprentissage par descente de gradient

L'entraînement consiste à minimiser une fonction de coût $\mathcal{L}(\theta)$ par rapport aux paramètres θ du réseau, au moyen de la *descente de gradient stochastique* : $\theta \leftarrow \theta - \eta\,\nabla_\theta \mathcal{L}$, où η est le taux d'apprentissage. Le gradient $\nabla_\theta \mathcal{L}$ est calculé par *rétropropagation*, application de la règle de dérivation en chaîne qui propage l'erreur de la sortie vers l'entrée, couche par

couche. En pratique, on utilise des optimiseurs adaptatifs (de type Adam [9]) qui ajustent le pas par paramètre à partir des moments du gradient, et l'on traite les données par *lots* (*mini-batches*) pour estimer le gradient de façon efficace ; la taille de lot (ici 128) influe sur la stabilité et, dans le cas contrastif, sur le nombre de négatifs disponibles (section 2.6).

2.1.3 Généralisation et régularisation

Un modèle doit *généraliser* au-delà des données d'entraînement. Un modèle trop flexible *surapprend* (il mémorise le bruit) ; un modèle trop contraint *sous-apprend*. Plusieurs mécanismes régularisent l'apprentissage : la normalisation de couche (stabilisation des activations), les connexions résiduelles (facilitation du flux de gradient), et, dans le cas d'un VAE, le terme KL qui régularise l'espace latent (section 2.4). Un thème récurrent de ce rapport est que la régularisation *apparente* (par exemple la force du terme KL) peut être trompeuse : ce qui gouverne réellement le comportement du modèle est parfois une autre variable (ici l'échantillonnage, section 5.3).

2.2 Représentation du mouvement humain tridimensionnel

2.2.1 Du modèle corporel SMPL au squelette

La génération de mouvement suppose d'abord une représentation numérique du corps humain. Le modèle de référence est **SMPL** [10] (*Skinned Multi-Person Linear model*), un modèle paramétrique qui décrit le corps par un petit nombre de paramètres de *forme* (morphologie) et de *pose* (orientation des articulations). À partir de ces paramètres, SMPL produit un maillage tridimensionnel complet. Pour la génération de mouvement, on travaille le plus souvent sur une version simplifiée : un *squelette* de quelques dizaines d'articulations reliées par des segments rigides, chaque articulation étant repérée par ses coordonnées 3D (figure 2.1).

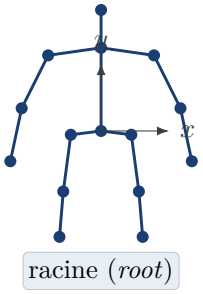


Figure 2.1. Représentation squelettique du corps humain : chaque articulation est un point 3D, relié à ses voisines par des segments. La racine (bassin) porte le repère global par rapport auquel les positions locales sont exprimées.

2.2.2 La représentation HumanML3D à 263 dimensions

Le jeu de données utilisé est **HumanML3D** [1], qui apparie des mouvements humains 3D à des légendes en anglais. Chaque mouvement est une séquence d'images (*frames*), et

chaque image est encodée par un vecteur de pose *redondant* de **263 dimensions**, dérivé du modèle SMPL. Cette redondance est volontaire : elle fournit au réseau plusieurs vues cohérentes de la même pose, ce qui facilite l'apprentissage. La décomposition des 263 composantes est la suivante :

Bloc	**Dim.**	**Contenu**
Racine	4	vitesse angulaire, vitesses linéaires x, z, hauteur y
Positions locales	63	coordonnées 3D de 21 articulations (21×3)
Rotations locales	126	rotations *continues* 6D de 21 articulations (21×6)
Vitesses locales	66	vitesses 3D de 22 articulations (22×3)
Contacts au sol	4	indicateurs binaires de contact des pieds
Total	**263**	

Ce travail manipule des clips de **longueur fixe de 60 images** ; un clip est donc un tenseur de $60 \times 263 = 15\,780$ nombres. Après filtrage, le corpus fournit **22 326** clips d'entraînement (966 écartés car trop courts, 92 car trop longs) et **1 400** clips de validation. Cette contrainte de longueur fixe, combinée à la compression en un latent unique étudiée plus loin, est au cœur des phénomènes analysés dans ce rapport.

2.2.3 Le modèle paramétrique SMPL

Le modèle SMPL [10] formalise le corps humain comme une fonction différentiable $M(\beta, \theta)$ qui produit un maillage de $N = 6890$ sommets à partir de deux groupes de paramètres : un vecteur de *forme* $\beta \in \mathbb{R}^{10}$ (les dix premières composantes principales de la morphologie, apprises sur des milliers de scans 3D) et un vecteur de *pose* $\theta \in \mathbb{R}^{3\times 24}$ (les rotations axe-angle des 24 articulations du squelette). Le maillage se calcule en trois étapes :

$$M(\beta, \theta) = W\Big(T_P(\beta, \theta),\, J(\beta),\, \theta,\, \mathcal{W}\Big), \quad T_P(\beta, \theta) = \bar{T} + B_S(\beta) + B_P(\theta), \tag{2.1}$$

où $\bar{T}$ est un gabarit moyen, $B_S(\beta)$ et $B_P(\theta)$ sont des *blend shapes* linéaires corrigeant respectivement la morphologie et les déformations dépendant de la pose, $J(\beta)$ régresse la position des articulations, et $W(\cdot)$ est l'opérateur de *linear blend skinning* qui déforme le gabarit selon les rotations θ et les poids d'attache $\mathcal{W}$. La différentiabilité de l'équation (2.1) est essentielle : elle permet de rétropropager un gradient depuis une perte définie sur les articulations jusqu'aux paramètres. Pour la génération de mouvement, on ne manipule pas le maillage complet mais une abstraction squelettique (les positions et rotations articulaires), bien plus légère et suffisante pour décrire le geste.

2.2.4 Arbre cinématique et cinématique directe

Le squelette est organisé en *arbre cinématique* : chaque articulation j possède un parent $\pi(j)$, la racine (le bassin) n'en ayant pas. La position d'une articulation se déduit de celle

de son parent, de la rotation locale et de la longueur du segment qui les relie. En notant R_j la rotation locale de l'articulation j et o_j le décalage fixe (l'os) vers son parent, la transformation globale se calcule récursivement depuis la racine :

$$G_j = G_{\pi(j)} \begin{pmatrix} R_j & o_j \\ 0 & 1 \end{pmatrix}, \qquad p_j = G_j \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \end{pmatrix}, \tag{2.2}$$

où G_j est une matrice homogène 4×4 et p_j la position globale. C'est la *cinématique directe*. Cette structure explique une propriété du mouvement importante pour la suite : une petite erreur de rotation sur une articulation proche de la racine (hanche, épaule) se *propage* à toute la chaîne qui en dépend (genou, cheville ; coude, poignet). C'est l'une des raisons pour lesquelles HumanML3D fournit à la fois des positions et des rotations : la redondance limite l'accumulation d'erreurs le long de l'arbre.

2.2.5 Rotations continues et normalisation des données

Un détail technique important de la représentation HumanML3D concerne le codage des *rotations*. Les paramétrisations classiques (angles d'Euler, quaternions) souffrent de discontinuités ou d'ambiguïtés (q et $-q$ codent la même rotation) qui nuisent à l'apprentissage par réseau de neurones. HumanML3D adopte donc la représentation *continue à 6 dimensions* [11] : une rotation $R \in SO(3)$ est codée par ses deux premières colonnes $(\mathbf{a}_1, \mathbf{a}_2) \in \mathbb{R}^6$, la troisième étant reconstruite par produit vectoriel après orthonormalisation de Gram–Schmidt :

$$\mathbf{b}_1 = \frac{\mathbf{a}_1}{\|\mathbf{a}_1\|}, \quad \mathbf{b}_2 = \frac{\mathbf{a}_2 - (\mathbf{b}_1 \cdot \mathbf{a}_2)\mathbf{b}_1}{\|\mathbf{a}_2 - (\mathbf{b}_1 \cdot \mathbf{a}_2)\mathbf{b}_1\|}, \quad \mathbf{b}_3 = \mathbf{b}_1 \times \mathbf{b}_2. \tag{2.3}$$

Cette application $\mathbb{R}^6 \to SO(3)$ est *continue et surjective*, ce qui élimine les discontinuités et explique le bloc de 126 dimensions (21×6) de la représentation. Enfin, chaque composante du vecteur de 263 dimensions est *standardisée* (retrait de la moyenne et division par l'écart-type calculés sur le corpus d'entraînement) avant d'entrer dans le réseau ; c'est pourquoi une erreur de reconstruction rc de l'ordre de 0,08 correspond à une reconstruction visuellement fidèle, tandis qu'une valeur de 0,5 traduit un effondrement (section 5.3).

2.3 Le Transformer et le mécanisme d'attention

L'architecture retenue par MotionCLIP est un **Transformer**, introduit par Vaswani *et al.* [12]. Contrairement aux réseaux récurrents, le Transformer traite une séquence entière en parallèle et met en relation toutes ses positions grâce au mécanisme d'*auto-attention*.

2.3.1 Les modèles de séquence avant le Transformer

Historiquement, les séquences étaient traitées par des *réseaux récurrents* (RNN) et leurs variantes à portes (LSTM, GRU), qui maintiennent un état caché mis à jour image après image. Ces modèles souffrent de deux limites : le traitement est intrinsèquement

séquentiel (l'état à l'instant t dépend de l'instant $t-1$), ce qui empêche la parallélisation ; et les dépendances à longue portée s'estompent (problème du gradient qui s'évanouit), car l'information doit transiter par tous les états intermédiaires. Les réseaux convolutifs atténuent la première limite (traitement parallèle) mais ne relient que des positions *voisines* par couche. Le Transformer résout les deux à la fois : toute paire de positions est reliée en une seule opération (chemin de longueur $\mathcal{O}(1)$), et l'ensemble de la séquence est traité en parallèle (tableau 2.1). C'est cette capacité à modéliser des dépendances globales qui en a fait l'architecture dominante, y compris pour le mouvement.

2.3.2 Le mécanisme d'attention

Soit une séquence de N vecteurs d'entrée rassemblés dans une matrice $X \in \mathbb{R}^{N\times d}$. Trois projections linéaires produisent les *requêtes*, *clés* et *valeurs* :

$$Q = XW_Q, \qquad K = XW_K, \qquad V = XW_V, \tag{2.4}$$

avec $W_Q, W_K, W_V \in \mathbb{R}^{d\times d_k}$. L'attention à produit scalaire normalisé calcule alors

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V. \tag{2.5}$$

Le produit $QK^\top \in \mathbb{R}^{N\times N}$ mesure la similarité entre chaque paire de positions ; la normalisation par $\sqrt{d_k}$ stabilise les gradients, et le softmax transforme chaque ligne en une distribution de poids. Chaque position de sortie est ainsi une moyenne pondérée des valeurs de *toutes* les positions d'entrée (figure 2.2).

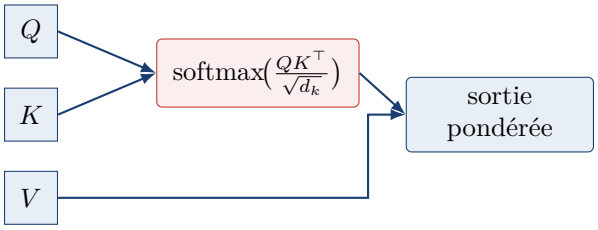


Figure 2.2. Le mécanisme d'attention de l'équation (2.5) : les similarités requête–clé, normalisées par un softmax, pondèrent les valeurs pour produire chaque vecteur de sortie.

2.3.3 Normalisation par $\sqrt{d_k}$ et propriétés du softmax

Le facteur de normalisation $1/\sqrt{d_k}$ de l'équation (2.5) n'est pas cosmétique. Si les composantes de q et k sont des variables aléatoires indépendantes de moyenne nulle et de variance unité, leur produit scalaire $q\cdot k = \sum_{i=1}^{d_k} q_i k_i$ a une variance de d_k. Sans normalisation, les logits passés au softmax croissent donc comme $\sqrt{d_k}$; pour d_k grand, le softmax sature (une entrée domine, les autres s'annulent) et son gradient devient négligeable. Diviser par $\sqrt{d_k}$ ramène la variance des logits à l'unité et préserve des gradients exploitables. Rappelons que le softmax transforme un vecteur de logits s en une distribution $\text{softmax}(s)_i = e^{s_i}/\sum_j e^{s_j}$, dont la jacobienne $\partial\,\text{softmax}(s)_i/\partial s_j = p_i(\delta_{ij}-p_j)$ tend vers zéro lorsque la distribution p est saturée : d'où l'importance de la normalisation.

2.3.4 Attention multi-têtes

En pratique, on emploie l'*attention multi-têtes* : au lieu d'une unique fonction d'attention, on en calcule h en parallèle, chacune sur une projection distincte de dimension $d_k = d/h$:

$$\mathrm{MultiHead}(X) = \Big[\,\mathrm{tête}_1; \ldots; \mathrm{tête}_h\,\Big]\, W_O, \qquad \mathrm{tête}_i = \mathrm{Attention}(XW_Q^{(i)}, XW_K^{(i)}, XW_V^{(i)}), \tag{2.6}$$

où $[\,\cdot\,;\,\cdot\,]$ désigne la concaténation et $W_O \in \mathbb{R}^{d\times d}$ une projection de sortie. Chaque tête peut ainsi se spécialiser dans un type de dépendance (proximité temporelle, symétrie gauche/droite du corps, coordination de membres), et leur concaténation combine ces vues.

2.3.5 Encodage de position

L'opération d'attention étant *invariante par permutation* des positions, un *encodage de position* est ajouté aux entrées pour réintroduire l'ordre temporel. L'encodage sinusoïdal d'origine [12] s'écrit, pour la position t et la dimension $2i$ (resp. $2i+1$) :

$$PE_{(t,2i)} = \sin\!\Big(t/10000^{\,2i/d}\Big), \qquad PE_{(t,2i+1)} = \cos\!\Big(t/10000^{\,2i/d}\Big). \tag{2.7}$$

Ce choix fournit, pour chaque paire de positions, un décalage de phase constant qui permet au modèle d'exprimer des dépendances relatives et de généraliser à des longueurs non vues à l'entraînement.

2.3.6 Bloc Transformer, encodeur et décodeur

Un *bloc* Transformer enchaîne une sous-couche d'attention multi-têtes et une sous-couche *feed-forward* par position (deux transformations linéaires séparées par une activation GELU), chacune entourée d'une connexion résiduelle et d'une normalisation de couche (figure 2.3) :

$$X' = \mathrm{LayerNorm}\Big(X + \mathrm{MultiHead}(X)\Big), \tag{2.8}$$

$$X'' = \mathrm{LayerNorm}\Big(X' + \mathrm{FFN}(X')\Big), \quad \mathrm{FFN}(x) = \mathrm{GELU}(xW_1 + b_1)W_2 + b_2. \tag{2.9}$$

Un encodeur empile plusieurs de ces blocs ; un décodeur fait de même en y ajoutant une sous-couche d'attention croisée vers la sortie de l'encodeur. MotionCLIP utilise un encodeur–décodeur de **8 couches** avec activations GELU.

2.3.7 Complexité et motivation des latents séquentiels

Le coût dominant est celui de l'attention : le produit $QK^\top \in \mathbb{R}^{N\times N}$ a une complexité en temps et en mémoire de $\mathcal{O}(N^2 d)$, *quadratique* en la longueur de séquence N (tableau 2.1). Pour des clips de 60 images, ce coût reste modeste ; il devient en revanche déterminant pour les séquences longues. Ce fait, conjugué à l'analyse du goulot latent de la section 2.10, motive les architectures à *tokens discrets* vers lesquelles pointe le chapitre 6.

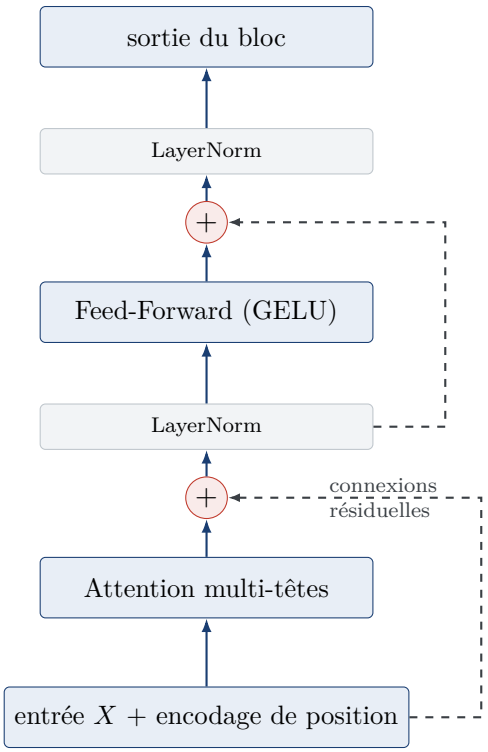


Figure 2.3. Structure d'un bloc Transformer : chaque sous-couche (attention multi-têtes, puis réseau feed-forward) est suivie d'une addition résiduelle (+, l'entrée de la sous-couche est réinjectée) et d'une normalisation de couche.

Tableau 2.1. Complexité par couche selon le type de réseau séquentiel (N : longueur de séquence, d : dimension du modèle).

Type de couche	Complexité par couche	Opérations séquentielles	Chemin max.
Récurrente (RNN)	$\mathcal{O}(Nd^2)$	$\mathcal{O}(N)$	$\mathcal{O}(N)$
Convolutive	$\mathcal{O}(kNd^2)$	$\mathcal{O}(1)$	$\mathcal{O}(\log_k N)$
Auto-attention	$\mathcal{O}(N^2 d)$	$\mathcal{O}(1)$	$\mathcal{O}(1)$

2.4 Autoencodeurs et autoencodeurs variationnels

2.4.1 Autoencodeur déterministe

Un **autoencodeur** (AE) est constitué d'un encodeur E qui compresse une entrée x en un code latent $z = E(x)$, et d'un décodeur D qui reconstruit $\hat{x} = D(z)$. L'apprentissage minimise une erreur de reconstruction, le plus souvent quadratique :

$$\mathcal{L}_{\text{AE}} = \|D(E(x)) - x\|^2. \tag{2.10}$$

Dans MotionCLIP, l'encodeur lit un clip de 60 images et, via un jeton de requête appris, le compresse en un **unique vecteur latent de dimension 512** ; le décodeur reconstruit les 60 images à partir de ce seul vecteur. Il s'agit d'une compression 30× à travers un point unique, fait structurant sur lequel reposera une grande partie de l'analyse.

2.4.2 Autoencodeur variationnel (VAE)

Un **autoencodeur variationnel** [13] remplace le code ponctuel par une *distribution*. L'encodeur produit les paramètres d'une gaussienne $q_\phi(z \mid x) = \mathcal{N}(\mu, \sigma^2)$, et le latent est *échantillonné* à partir de cette distribution. L'objectif est de maximiser la borne inférieure de la vraisemblance (*Evidence Lower Bound*, ELBO) :

$$\log p_\theta(x) \;\geq\; \underbrace{\mathbb{E}_{q_\phi(z|x)}\Big[\log p_\theta(x \mid z)\Big]}_{\text{reconstruction}} \;-\; \underbrace{\mathrm{KL}\Big(q_\phi(z \mid x) \,\|\, p(z)\Big)}_{\text{régularisation}}, \tag{2.11}$$

où $p(z) = \mathcal{N}(0, I)$ est une loi *a priori* unitaire. Le premier terme pousse le décodeur à bien reconstruire ; le second rapproche la distribution encodée de la loi a priori, ce qui *lisse* l'espace latent et le rend génératif. Pour une gaussienne diagonale, la divergence KL admet une forme close :

$$\mathrm{KL}\Big(\mathcal{N}(\mu, \sigma^2) \,\|\, \mathcal{N}(0, I)\Big) = -\tfrac{1}{2} \sum_i \Big(1 + \log \sigma_i^2 - \mu_i^2 - \sigma_i^2\Big). \tag{2.12}$$

2.4.3 Dérivation de la borne ELBO

La borne de l'équation (2.11) n'est pas postulée : elle découle de l'introduction d'une distribution d'approximation $q_\phi(z \mid x)$ et de l'inégalité de Jensen. En partant de la log-vraisemblance marginale et en y insérant q_ϕ :

$$\log p_\theta(x) = \log \int p_\theta(x, z)\, \mathrm{d}z = \log\, \mathbb{E}_{q_\phi(z|x)}\left[\frac{p_\theta(x, z)}{q_\phi(z \mid x)}\right] \tag{2.13}$$

$$\geq \mathbb{E}_{q_\phi(z|x)}\left[\log \frac{p_\theta(x, z)}{q_\phi(z \mid x)}\right] = \underbrace{\mathbb{E}_{q_\phi}\Big[\log p_\theta(x \mid z)\Big]}_{\text{reconstruction}} - \underbrace{\mathrm{KL}\Big(q_\phi(z \mid x) \,\|\, p(z)\Big)}_{\text{régularisation}}, \tag{2.14}$$

le passage à la deuxième ligne utilisant la concavité du logarithme (Jensen). L'écart exact entre $\log p_\theta(x)$ et l'ELBO est précisément $\mathrm{KL}(q_\phi(z \mid x) \,\|\, p_\theta(z \mid x)) \geq 0$; maximiser l'ELBO revient donc à la fois à expliquer les données et à rapprocher la postérieure approchée q_ϕ de la vraie postérieure $p_\theta(z \mid x)$. Dans notre cadre, le terme de reconstruction est l'erreur quadratique rc (hypothèse gaussienne sur $p_\theta(x \mid z)$) et le terme de régularisation est la forme close (2.12).

2.4.4 L'astuce de reparamétrisation

L'échantillonnage $z \sim \mathcal{N}(\mu, \sigma^2)$ n'est pas directement différentiable. L'*astuce de reparamétrisation* contourne ce problème en écrivant

$$z = \mu + \sigma \odot \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, I), \tag{2.15}$$

où $\odot$ est le produit terme à terme. Le bruit ε est externe et indépendant des paramètres ; le gradient peut donc remonter à travers μ et σ (figure 2.4). C'est précisément cette étape d'échantillonnage qui rend l'espace latent lisse et générateur, et c'est aussi, comme le montre la section 2.10, ce qu'un décodeur de mouvement à latent unique ne peut pas tolérer.

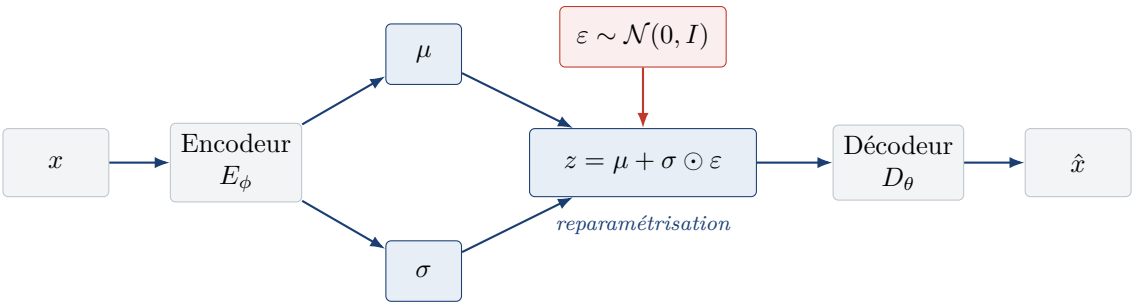


Figure 2.4. Autoencodeur variationnel avec reparamétrisation (équation (2.15)) : l'encodeur produit (μ, σ), le latent est tiré en injectant un bruit externe ε, puis décodé en $\hat{x}$.

2.4.5 Pondération de la régularisation : le β-VAE

En pratique, on pondère souvent le terme KL par un coefficient β, donnant l'objectif du β-VAE :

$$\mathcal{L}_\beta = \mathbb{E}_{q_\phi(z|x)}\Big[\log p_\theta(x \mid z)\Big] - \beta\, \mathrm{KL}\Big(q_\phi(z \mid x) \,\|\, p(z)\Big). \tag{2.16}$$

Pour $\beta = 1$ on retrouve l'ELBO. Augmenter β renforce la contrainte sur le latent (espace plus lisse et plus « démêlé », mais reconstruction dégradée) ; le diminuer privilégie la reconstruction au détriment du caractère génératif. C'est exactement ce paramètre que fait varier la *série KL* de la section 5.3, où l'on montre, de façon contre-intuitive, que son réglage ne change presque rien : dans un décodeur à latent unique, c'est la présence même de l'*échantillonnage*, et non le poids $\beta = \lambda_{\mathrm{KL}}$, qui gouverne la reconstruction.

2.4.6 Effondrement postérieur et précédent ACTOR

Lorsque le décodeur est suffisamment puissant, le VAE peut « ignorer » le latent et satisfaire la contrainte KL en rapprochant $q_\phi(z \mid x)$ de la loi a priori : c'est l'*effondrement postérieur* (*posterior collapse*). À l'inverse, un latent trop sollicité devient sensible au bruit d'échantillonnage. **ACTOR** [14] est le précédent d'un VAE transformeur qui, lui, *survit* à l'échantillonnage ; la section 2.10 expliquera cette différence par la quantité bien moindre d'information qu'ACTOR fait transiter par le même goulot (il est conditionné par une classe d'action discrète, et non par un clip complet).

2.5 Quantification vectorielle : VQ-VAE et RVQ

Entre l'autoencodeur déterministe et le VAE continu se situe une troisième voie, centrale pour la proposition prospective de ce rapport (chapitre 6) : la *quantification vectorielle*. Plutôt que de représenter le latent par un point continu ou par une distribution gaussienne, le VQ-VAE le contraint à appartenir à un *dictionnaire* fini de vecteurs appris.

2.5.1 Le VQ-VAE

Un **VQ-VAE** [15] maintient un *codebook* $\mathcal{C} = \{e_1, \ldots, e_K\}$ de K vecteurs. L'encodeur produit une représentation continue $z_e(x)$, qui est *quantifiée* vers le vecteur le plus proche du dictionnaire :

$$z_q(x) = e_k, \qquad k = \arg\min_j \|z_e(x) - e_j\|_2. \tag{2.17}$$

Le décodeur reconstruit à partir de $z_q(x)$. L'opérateur arg min n'étant pas différentiable, le gradient est transmis par l'*estimateur à gradient recopié* (*straight-through estimator*) : lors de la rétropropagation, on copie le gradient de z_q vers z_e comme si la quantification était l'identité. La perte comprend trois termes :

$$\mathcal{L}_{\text{VQ}} = \underbrace{\|x - D(z_q)\|^2}_{\text{reconstruction}} + \underbrace{\|\text{sg}[z_e] - e_k\|^2}_{\text{codebook}} + \beta \underbrace{\|z_e - \text{sg}[e_k]\|^2}_{\text{engagement}}, \tag{2.18}$$

où sg[·] est l'opérateur « stop-gradient ». Le terme de *codebook* rapproche les vecteurs du dictionnaire des sorties de l'encodeur ; le terme d'*engagement* empêche la représentation de l'encodeur de croître sans borne.

2.5.2 Pourquoi la quantification change tout pour le mouvement

La propriété décisive est la suivante : un code discret ne peut pas « régresser vers une moyenne ». Alors qu'un décodeur entraîné par MSE sur un latent continu converge vers la moyenne conditionnelle (une pose quasi statique, section 5.9), un décodeur alimenté par des *tokens discrets* doit choisir une entrée précise du dictionnaire : il n'existe pas de pose « moyenne » intermédiaire vers laquelle s'effondrer. C'est l'argument central de la feuille de route du chapitre 6.

2.5.3 Quantification résiduelle (RVQ)

Un codebook unique de taille raisonnable sature vite en capacité. La **quantification vectorielle résiduelle** (RVQ), employée par MoMask [3], applique plusieurs niveaux de quantification en cascade : le premier niveau quantifie z_e, le second quantifie le *résidu* $z_e - z_q^{(1)}$, et ainsi de suite (figure 2.5) :

$$z_q = \sum_{\ell=1}^{L} q^{(\ell)}\Big(r^{(\ell-1)}\Big), \qquad r^{(0)} = z_e, \quad r^{(\ell)} = r^{(\ell-1)} - q^{(\ell)}\Big(r^{(\ell-1)}\Big). \tag{2.19}$$

Chaque niveau affine l'approximation, de sorte qu'avec L niveaux de K codes on obtient un pouvoir d'expression effectif de l'ordre de K^L combinaisons. Un mouvement devient alors une *grille de tokens* de taille $(T' \times L)$, qu'un transformeur masqué génère de façon itérative. Cette représentation est précisément le « conteneur » séquentiel et discret dont l'absence explique, selon nous, les défaillances observées sur MotionCLIP.

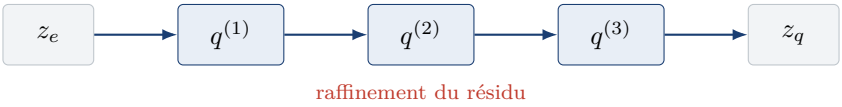


Figure 2.5. Quantification résiduelle (RVQ) : chaque niveau $q^{(\ell)}$ quantifie le résidu laissé par le niveau précédent, affinant progressivement l'approximation du vecteur continu z_e.

2.6 Apprentissage contrastif et alignement vision–langage

2.6.1 CLIP et l'objectif contrastif

CLIP [5] (*Contrastive Language–Image Pre-training*) aligne images et textes dans un espace commun au moyen d'un objectif *contrastif*. À partir d'un lot de B paires (image, légende), on calcule les embeddings normalisés et la matrice de similarités $S_{ij} = \langle e_i^{\text{img}}, e_j^{\text{txt}} \rangle$. L'objectif, de type InfoNCE [16], maximise la similarité des paires *appariées* (diagonale) relativement à toutes les paires *non appariées* de la même ligne et de la même colonne :

$$\mathcal{L}_{\text{CE}} = -\frac{1}{B} \sum_{i=1}^{B} \log \frac{\exp(S_{ii}/\tau)}{\sum_{j=1}^{B} \exp(S_{ij}/\tau)}, \tag{2.20}$$

où τ est une *température* (ou son inverse, le *logit scale*). La propriété essentielle de cet objectif, et celle qui le distingue de la simple similarité cosinus, est la présence de *négatifs* : il ne se contente pas de rapprocher les paires correctes, il les contraint à être *mieux classées* que les paires incorrectes (figure 2.6).

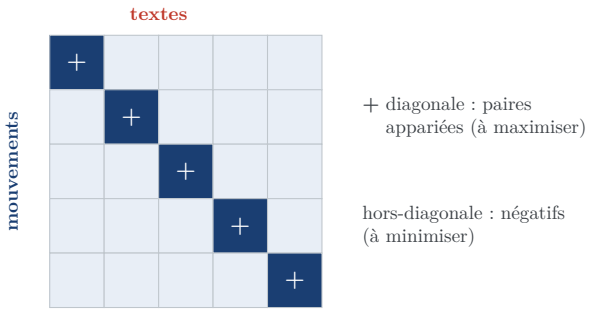


Figure 2.6. Matrice de similarités d'un lot contrastif. L'objectif InfoNCE (équation (2.20)) élève la diagonale (paires appariées) au-dessus du reste de chaque ligne et de chaque colonne. Les *négatifs* hors-diagonale sont le mécanisme absent de la simple similarité cosinus.

2.6.2 Interprétation : information mutuelle, température et géométrie

L'objectif InfoNCE n'est pas qu'une heuristique de classement : il constitue une *borne inférieure de l'information mutuelle* $I(e^{\text{mouv}}; e^{\text{texte}})$ entre les deux modalités [16]. Minimiser l'équation (2.20) revient donc à maximiser l'information partagée entre le latent de mouvement et l'embedding de texte. La température τ contrôle la netteté de la distribution : une petite valeur accentue la pénalisation des négatifs les plus proches (les « négatifs durs »), tandis qu'une grande valeur lisse le gradient. Dans l'implémentation, τ est paramétrée par son inverse, le *logit scale*, dont l'absence faisait planter le chemin contrastif (section 4.7).

Géométriquement, sur des embeddings normalisés (donc sur l'hypersphère unité), l'objectif contrastif réalise un compromis entre deux forces : l'*alignement* (rapprocher les paires appariées) et l'*uniformité* [17] (étaler les représentations sur la sphère pour préserver l'information). C'est précisément cette seconde force, absente du terme cosinus, qui empêche l'effondrement de toutes les représentations vers une direction unique.

2.6.3 Cosinus contre contrastif : le rôle des négatifs

MotionCLIP, dans sa formulation d'origine, aligne le latent de mouvement et l'embedding de texte au moyen d'un terme de *similarité cosinus* portant sur les *paires appariées uniquement* :

$$\mathcal{L}_{\cos} = \text{moyenne}\Big(1 - \cos(e_{\text{texte}}, \mu)\Big). \tag{2.21}$$

Ce terme ne contient *aucun négatif* : il rapproche les paires correctes sans jamais éloigner les paires incorrectes. On montrera au chapitre 5 que cette absence est décisive : placer tous les μ_i sur la direction textuelle *moyenne* constitue un optimum global de l'équation (2.21), de sorte que la perte diminue sans qu'aucun alignement *par échantillon* ne soit appris. Aucun poids ne corrige un terme manquant : seul l'ajout de négatifs, via l'objectif contrastif (2.20), produit un alignement réel.

Proposition 2.1 (Optimum trivial du terme cosinus)**.** *Si l'encodeur de mouvement peut produire une valeur de μ arbitraire, alors l'objectif cosinus de l'équation* (2.21) *est minimisé en posant, pour* tout *échantillon i, $\mu_i = \bar{e}$ pour n'importe quel vecteur unitaire $\bar{e}$ aligné avec la moyenne des directions textuelles. Cette solution rend identiques les similarités appariées et non appariées, de sorte que l'écart d'alignement par échantillon est nul.*

Esquisse. La perte $\sum_i \big(1-\cos(e_i, \mu_i)\big)$ se décompose en une somme de termes indépendants, un par échantillon, chacun minimisé lorsque μ_i est colinéaire à e_i. Cependant, si les embeddings textuels e_i sont très concentrés (ce qui est le cas de M-CLIP, dont la similarité inter-légendes dépasse 0,97, section 5.6), placer tous les μ_i sur leur direction commune $\bar{e}$ atteint une valeur de perte quasi minimale *tout en* rendant $\cos(e_i, \mu_j) \approx \cos(e_i, \mu_i)$ pour tout j. L'écart apparié moins non apparié est alors nul, sans que la perte ne le pénalise. □

La proposition 2.1 explique pourquoi augmenter le poids du terme cosinus *aggrave* l'alignement observé (section 5.6) : cela renforce la concentration vers $\bar{e}$, donc l'effondrement.

2.7 Représentations multilingues

2.7.1 XLM-R et M-CLIP

Pour conditionner le modèle sur plusieurs langues, on remplace la tour de texte anglaise de CLIP par un encodeur multilingue. **XLM-RoBERTa** (XLM-R) [7] est un modèle de langage masqué pré-entraîné sur une centaine de langues, qui produit des représentations textuelles inter-lingues. **M-CLIP** [18] exploite XLM-R comme tour de texte et l'entraîne, par distillation, de sorte que la *traduction* d'une légende se projette au voisinage de l'embedding CLIP anglais original. En d'autres termes, M-CLIP est aligné multilingue « dès la sortie de boîte » : des phrases de même sens, dans des langues différentes, y reçoivent des embeddings proches.

Dans notre pipeline, M-CLIP (XLM-RoBERTa-Large / ViT-B-32) est gardé *gelé*, et seule une projection linéaire entraînable $768 \to 512$ relie son espace à l'espace latent de mouvement. Cette conception minimise le nombre de paramètres entraînables et isole l'effet du conditionnement multilingue. XLM-R est pré-entraîné par *modélisation de langage masquée* sur un corpus de 2,5 téraoctets couvrant une centaine de langues ; M-CLIP, lui, est entraîné par *distillation* de sorte que l'embedding d'une traduction se

rapproche de l'embedding CLIP anglais de la phrase originale, selon une perte du type $\|f_{\text{M-CLIP}}(t_{\text{trad}}) - f_{\text{CLIP}}(t_{\text{en}})\|^2$. C'est ce pré-alignement, acquis *avant* tout entraînement sur le mouvement, qui explique le transfert inter-lingue observé en section 5.11 sur des langues jamais vues pendant notre entraînement.

2.7.2 Tokenisation en sous-mots

Un modèle multilingue ne peut maintenir un vocabulaire distinct pour chaque mot de chaque langue. XLM-R emploie donc une *tokenisation en sous-mots* de type SentencePiece : le texte brut est segmenté en unités fréquentes (morphèmes, radicaux, suffixes) partagées entre langues. Un mot rare ou composé est décomposé en plusieurs sous-mots, ce qui garantit une couverture complète sans vocabulaire infini et favorise le partage de représentations entre langues apparentées (par exemple les radicaux latins communs au français, à l'espagnol et au portugais). Cette propriété est l'un des mécanismes par lesquels un modèle multilingue peut transférer des connaissances d'une langue à une autre ; elle a aussi une conséquence possible dans notre étude : les langues à écriture non latine (chinois, arabe, russe) sont segmentées très différemment de l'anglais. Nous formulons l'*hypothèse* que cette distance, conjuguée à la qualité de la traduction automatique, contribue à l'ordre inter-lingue stable observé en section 5.7, où le chinois est systématiquement le moins bien aligné. Ce travail ne permet pas de séparer ces deux causes ; c'est un point à tester.

2.7.3 Pourquoi le multilinguisme pourrait aider : la typologie

L'intuition selon laquelle plusieurs langues pourraient *enrichir* la représentation du mouvement s'appuie sur la *typologie linguistique*. Selon la classification de Talmy [19], les langues diffèrent dans la façon dont elles répartissent l'information d'un événement de mouvement entre le verbe et ses satellites. Les langues dites *à cadre verbal* (comme l'espagnol) encodent volontiers la *trajectoire* dans le verbe (*entrar*, *subir*), reléguant la *manière* à un complément facultatif ; les langues *à cadre satellitaire* (comme l'anglais ou l'allemand) encodent la manière dans le verbe (*to stride*, *to limp*) et la trajectoire dans une particule (*in*, *up*). Trois dimensions sont ainsi diversement saillantes selon la langue : la **manière** (comment le mouvement est exécuté), la **trajectoire** (son parcours spatial) et l'**aspect** (sa structure temporelle, ponctuelle ou durative).

Si un modèle multilingue savait fusionner ces éclairages complémentaires, il pourrait en principe apprendre une représentation du mouvement *plus riche* que son homologue monolingue : c'est l'hypothèse de la supervision enrichie. La comparaison contrôlée de la section 5.11 teste directement cette promesse, et conclut que, dans le cadre d'un latent unique et de légendes traduites automatiquement, elle ne se matérialise pas : les langues se partagent un budget plutôt qu'elles ne l'enrichissent.

2.7.4 Génération du corpus multilingue par traduction automatique

HumanML3D n'existant qu'en anglais, les légendes sont traduites automatiquement vers six langues cibles (français, espagnol, portugais, russe, chinois, arabe) au moyen de **NLLB** [20] (*No Language Left Behind*), un modèle de traduction massivement multilingue. On obtient ainsi sept langues au total. Au cours de l'entraînement, chaque clip est présenté

dans une langue *échantillonnée par clip et par époque* ; à nombre de pas de gradient fixé, un clip donné est donc vu dans une langue déterminée environ $1/N$ du temps sous un régime à N langues. Ce déséquilibre d'exposition est un facteur de confusion sur lequel on reviendra (chapitre 6).

> **Propriété opératoire.** Un objectif contrastif contraint des *paires appariées à être mieux classées que des paires non appariées*, alors qu'un objectif cosinus se contente de les rendre *similaires*. C'est la présence ou l'absence de négatifs qui constitue la différence décisive entre les deux, et non la valeur de leurs poids respectifs.

2.8 Apprentissage par transfert et modèles gelés

Un choix de conception transversal mérite un traitement théorique : l'emploi d'encodeurs de texte *gelés*. Cette décision relève de l'*apprentissage par transfert*.

2.8.1 Principe du transfert

L'apprentissage par transfert consiste à réutiliser les représentations d'un modèle pré-entraîné sur une tâche source (ici, l'alignement texte–image de CLIP, ou la modélisation de langage de XLM-R) pour une tâche cible (l'alignement texte–mouvement). L'hypothèse sous-jacente est que les représentations apprises sur de vastes corpus capturent une sémantique *générale*, transférable. Deux régimes existent : le *réglage fin* (*fine-tuning*), où les poids pré-entraînés sont mis à jour, et l'*extraction de caractéristiques*, où ils sont *gelés* et seule une tête légère est entraînée par-dessus.

2.8.2 Pourquoi geler l'encodeur de texte

Dans ce travail, l'encodeur de texte est gelé et seule une projection $768 \to 512$ est entraînée. Ce choix répond à trois objectifs. *(1) Isolation causale* : en figeant le texte, toute différence de performance ne peut provenir que du latent de mouvement entraîné, ce qui est indispensable à une étude contrôlée. *(2) Économie* : côté texte, seuls $\approx 0{,}39$ M paramètres sont entraînés (une projection $768 \to 512$ pour M-CLIP), et $\approx 2{,}76$ M pour le banc de sept projections, ce qui rend chaque expérience rapide et reproductible. *(3) Préservation de l'alignement multilingue* : M-CLIP est déjà aligné entre langues ; un réglage fin risquerait de détruire cet alignement en le spécialisant sur le corpus de mouvement, majoritairement anglais.

2.8.3 Conséquence : le transfert inter-lingue « gratuit »

Une conséquence directe du gel apparaît en section 5.11 : un modèle entraîné uniquement sur les langues latines atteint néanmoins une R@1 de 0,100 en chinois, cinquante fois le hasard, sans avoir jamais vu une légende chinoise. Cette capacité provient entièrement du pré-alignement multilingue de M-CLIP, qui transparaît à travers l'encodeur gelé. Le gel n'est donc pas qu'une commodité : c'est lui qui confère au système un transfert inter-lingue que l'entraînement sur le mouvement, à lui seul, ne produirait pas.

2.9 Métriques d'évaluation génératives

L'évaluation d'un modèle génératif de mouvement repose sur plusieurs métriques complémentaires, calculées à partir d'un *extracteur de caractéristiques* pré-entraîné qui plonge mouvements et textes dans un espace commun.

Distance de Fréchet (FID). La **FID** [21] mesure l'écart entre la distribution des caractéristiques des mouvements *générés* et celle des mouvements *réels*. En modélisant chacune par une gaussienne de moyenne et covariance (μ_r, Σ_r) et (μ_g, Σ_g), elle s'écrit

$$\mathrm{FID} = \|\mu_r - \mu_g\|^2 + \mathrm{Tr}\Big(\Sigma_r + \Sigma_g - 2(\Sigma_r\Sigma_g)^{1/2}\Big). \tag{2.22}$$

Une FID *faible* indique que les mouvements générés sont statistiquement proches des mouvements réels ; c'est la métrique de qualité principale.

L'équation (2.22) est la *distance de Fréchet* (ou distance de Wasserstein-2) entre deux lois gaussiennes multivariées. Elle se décompose en deux contributions : $\|\mu_r - \mu_g\|^2$ pénalise un décalage de la *moyenne* des caractéristiques (les mouvements générés sont, en moyenne, différents des réels), tandis que le terme en trace pénalise une différence de *covariance* (la dispersion et les corrélations diffèrent). Le terme $(\Sigma_r\Sigma_g)^{1/2}$ est la racine matricielle du produit des covariances ; lorsque $\Sigma_r = \Sigma_g$, la trace s'annule et seule subsiste la distance des moyennes. En pratique, les caractéristiques $\phi(\cdot)$ ne sont pas les clips bruts mais leur projection par un *extracteur pré-entraîné* (un réseau de type Guo *et al.* entraîné à plonger mouvements et textes dans un espace commun) : c'est ce réseau qui définit « ce qui compte » comme ressemblance, et c'est la raison pour laquelle deux extracteurs distincts (Évaluateurs A et B) produisent des FID non comparables.

R-précision et MM-Dist. La **R-précision** (R@1/2/3/10) mesure la capacité à *récupérer* la bonne légende parmi un ensemble de candidats : pour un mouvement généré, on vérifie si sa légende d'origine figure parmi les k plus proches dans l'espace de caractéristiques. La **MM-Dist** (distance multimodale) mesure la distance entre un texte et le mouvement qu'il engendre (plus faible est meilleure). Un caveat important doit être énoncé d'emblée : la R-précision est **anglophone par construction**, car la tour de texte de l'évaluateur est un GloVe BiGRU entraîné sur des légendes anglaises. La qualité par langue est donc évaluée par la FID seule.

Diversité et amplitude. La **diversité** mesure la variabilité des mouvements générés. Formellement, en tirant deux sous-ensembles aléatoires de caractéristiques $\{v_i\}$ et $\{v'_i\}$ parmi les mouvements générés, elle s'estime par $\mathrm{Div} = \frac{1}{S}\sum_{i=1}^{S}\|v_i - v'_i\|$: une diversité proche de zéro signale que le modèle produit toujours le même mouvement (effondrement de mode), tandis qu'une valeur proche de celle du mouvement réel ($\sim$9,5) indique une génération variée. On introduit en outre un diagnostic propre à ce travail : l'**amplitude**, définie comme la différence absolue moyenne entre images consécutives d'un mouvement généré, $\frac{1}{T-1}\sum_t \|x_{t+1} - x_t\|_1$ (une mesure de la quantité globale de mouvement), ainsi que la différence entre mouvements générés pour des *prompts* différents (une mesure de la force du conditionnement textuel).

Réplications et incertitude. La génération étant stochastique, chaque métrique est moyennée sur **20 réplications** indépendantes, ce qui réduit la variance d'estimation et permet de distinguer un écart réel d'une fluctuation. Pour certaines quantités (le gain de reconstruction de la branche de robustesse au bruit, section 5.5), on rapporte en outre un *intervalle de confiance bootstrap* à 95 % : on ré-échantillonne avec remise l'ensemble des clips, on recalcule la statistique sur chaque ré-échantillon, et l'on prend les quantiles empiriques 2,5 % et 97,5 %. Un intervalle ne contenant pas zéro indique un effet statistiquement significatif. Cette discipline statistique est ce qui permet d'affirmer qu'un gain auxiliaire est *réel* tout en montrant qu'il ne se *transfère* pas à la génération.

> **Attention à la nature des caractéristiques.** Toutes ces métriques sont calculées dans l'espace d'un *extracteur pré-entraîné* (un réseau de type Guo *et al.*). Deux extracteurs différents produisent des échelles de FID non comparables : c'est la raison pour laquelle les Évaluateurs A et B du chapitre 3 ne doivent jamais être mêlés.

2.10 Analyse du goulot d'étranglement latent

Cette section fournit l'argument théorique central du rapport : pourquoi un *latent unique* ne peut pas absorber le bruit d'échantillonnage d'un VAE. L'argument procède par développement au premier ordre de l'erreur de reconstruction.

Proposition 2.2 (Coût du bruit dans un décodeur à latent unique)**.** *Soit $z = \mu + \varepsilon$ avec $\varepsilon \sim \mathcal{N}(0, \Sigma)$, et soit $\hat{x} = D(z) = (\hat{x}_1, \dots, \hat{x}_T)$ la sortie du décodeur, de jacobiens par image $J_t = \partial \hat{x}_t / \partial z$. Au premier ordre autour de μ, l'erreur de reconstruction espérée se décompose en*

$$\mathbb{E}_\varepsilon \, \|\hat{x} - x\|^2 \;\approx\; \underbrace{\|\hat{x}(\mu) - x\|^2}_{\text{erreur déterministe}} \;+\; \underbrace{\sum_{t=1}^{T} \operatorname{Tr}\!\left(J_t \, \Sigma \, J_t^\top\right)}_{\text{terme de dégradation}} . \tag{2.23}$$

Esquisse. On développe $\hat{x}_t(z) = \hat{x}_t(\mu + \varepsilon)$ au premier ordre en ε : $\hat{x}_t \approx \hat{x}_t(\mu) + J_t \varepsilon$. L'erreur par image devient $\|\hat{x}_t(\mu) + J_t\varepsilon - x_t\|^2$. En prenant l'espérance sur $\varepsilon \sim \mathcal{N}(0, \Sigma)$ et en utilisant $\mathbb{E}[\varepsilon] = 0$ ainsi que $\mathbb{E}[\varepsilon\varepsilon^\top] = \Sigma$, le terme croisé s'annule et il reste $\|\hat{x}_t(\mu) - x_t\|^2 + \mathbb{E}[\varepsilon^\top J_t^\top J_t \varepsilon] = \|\hat{x}_t(\mu) - x_t\|^2 + \operatorname{Tr}(J_t \Sigma J_t^\top)$. La sommation sur les T images donne l'équation (2.23). □

Le point crucial est que le terme de dégradation *somme sur les $T = 60$ images*, car tous les J_t dépendent du *même* vecteur z. Il n'existe aucun endroit où le bruit puisse « se cacher » : un unique vecteur alimente le clip entier (figure 2.7). À l'inverse, avec K latents couvrant chacun un sous-ensemble disjoint d'images, la plupart des dérivées $\partial \hat{x}_t / \partial z_k$ s'annulent ; la somme devient *bloc-diagonale* et la pénalité par latent chute d'un facteur de l'ordre de K.

Cette analyse explique aussi pourquoi ACTOR [14] survit à l'échantillonnage là où MotionCLIP échoue : ACTOR est conditionné par une classe d'action discrète et fait donc transiter beaucoup moins d'information par le même goulot, avec un décodeur de plus faible gain, des J_t plus petits, donc un terme de dégradation plus faible. La proposition 2.2 est le socle théorique des résultats expérimentaux des sections 5.3–5.4, et elle fonde la proposition architecturale du chapitre 6.

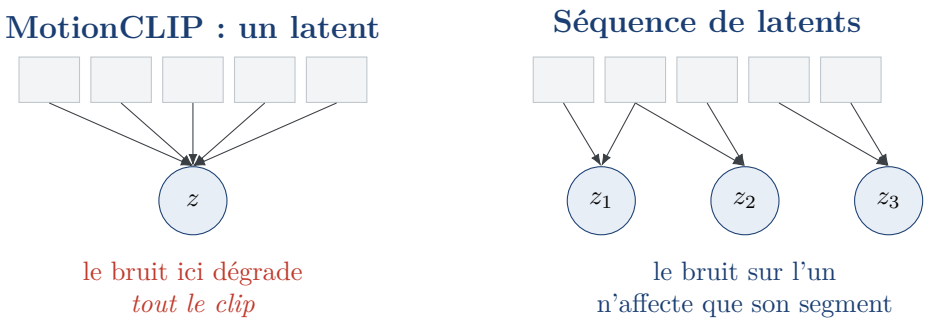


Figure 2.7. Pourquoi un latent unique ne peut absorber le bruit d'échantillonnage. À gauche, les 60 images dépendent d'un seul z : le bruit injecté dégrade le clip entier (la somme de l'équation (2.23) porte sur toutes les images). À droite, avec un latent par segment, la plupart des blocs jacobiens s'annulent et la pénalité par latent chute d'un facteur $\approx K$.

Chapitre 3

Conception et modélisation de l'architecture

Ce chapitre décrit la conception du système étudié. Il présente l'architecture globale héritée de MotionCLIP (section 3.1), le pipeline multilingue mis en place (section 3.3), la formulation variationnelle et la fonction de coût (section 3.4), les deux objectifs d'alignement (section 3.5) et, de façon critique, le protocole d'évaluation et ses deux évaluateurs non comparables (section 3.7).

3.1 Architecture globale

Le système repose sur un autoencodeur transformeur (8 couches, activations GELU). L'encodeur lit un clip de 60 images et, via un jeton de requête appris, le compresse en un *unique* latent de dimension 512 ; le décodeur reconstruit les 60 images à partir de ce seul vecteur. En parallèle, un encodeur de texte multilingue *gelé* (M-CLIP, ou un banc d'encodeurs monolingues) produit un embedding e_{texte}, qui est *aligné* sur le latent de mouvement μ pendant l'entraînement. La figure 3.1 schématise l'ensemble.

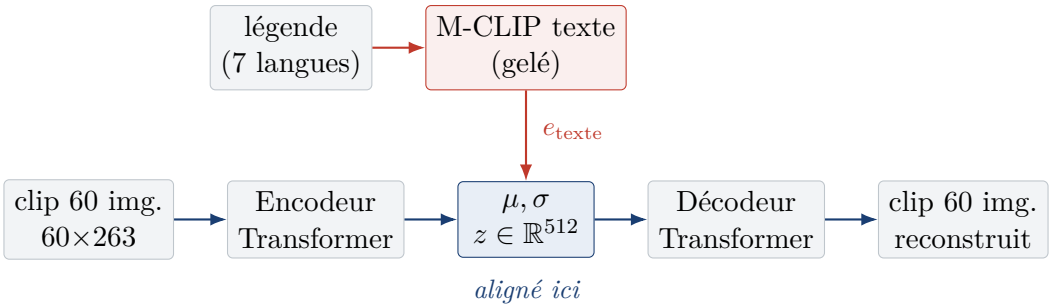


Figure 3.1. Architecture du système. Un clip de 60 images est compressé par l'encodeur en un latent unique de dimension 512, puis reconstruit par le décodeur. Un encodeur de texte multilingue gelé produit e_{texte}, aligné sur le latent μ. **À la génération**, le décodeur reçoit e_{texte} à la place de μ : une substitution que la perte de base n'optimise jamais (section 5.10).

Cette conception place le latent unique au centre du dispositif. Il doit, à lui seul, porter l'intégralité d'un clip : tout bruit injecté en ce point endommage la séquence entière (section 2.10), et tout objectif qui le sous-contraint fait s'effondrer la génération (sections 5.8–5.9).

3.1.1 Le jeton de requête et la compression

La compression d'une séquence de 60 vecteurs en un seul s'opère via un mécanisme de *jeton de requête* (*query token*). Un vecteur appris $q \in \mathbb{R}^{512}$, concaténé à la séquence d'entrée, agrège l'information de toutes les images par attention croisée : sa représentation en sortie de l'encodeur constitue le latent z. Ce choix présente l'avantage de produire une représentation de taille fixe indépendamment de la longueur du clip, mais c'est aussi lui qui crée le *goulot* analysé en section 2.10 : toute l'information temporelle doit transiter par ce point unique. Le tableau 3.1 récapitule les dimensions mises en jeu.

Tableau 3.1. Dimensions principales du modèle.

Grandeur	Valeur	Rôle
Longueur de clip T	60	nombre d'images par mouvement
Dimension de pose	263	vecteur de pose par image
Dimension latente	512	taille du latent unique z
Dimension M-CLIP	768	sortie de l'encodeur de texte gelé
Projection texte	$768 \to 512$	seule couche entraînable du texte
Couches Transformer	8	profondeur de l'encodeur et du décodeur
Taux de compression	$\approx 30\times$	de 60×263 vers 512

3.2 Prétraitement et normalisation des données

Avant d'entrer dans le modèle, les données subissent plusieurs étapes de prétraitement qui conditionnent la stabilité de l'apprentissage.

Mise à longueur fixe. Les mouvements de HumanML3D ont des durées variables ; ils sont ramenés à une longueur fixe de 60 images. Les clips trop courts (966) et trop longs (92) sont écartés, afin d'éviter respectivement un remplissage artificiel et une troncature destructrice. Ce choix d'une longueur fixe est ce qui permet la compression en un latent unique, mais c'est aussi lui qui fige la difficulté analysée dans ce rapport.

Standardisation. Chaque composante du vecteur de 263 dimensions est centrée et réduite à partir des statistiques (moyenne, écart-type) calculées sur le *corpus d'entraînement*. Cette standardisation place toutes les composantes (positions, rotations, vitesses, contacts) sur une échelle comparable, ce qui est indispensable à une perte de reconstruction MSE uniforme : sans elle, les composantes de forte amplitude domineraient le gradient. C'est également pour cette raison qu'une erreur rc $\approx 0{,}08$ correspond à une reconstruction fidèle, tandis que rc $\approx 0{,}5$ traduit un effondrement.

Légendes parallèles. Pour la mesure d'alignement, un sous-ensemble de 500 clips est doté de légendes *parallèles* dans les sept langues : une même légende anglaise est traduite vers les six autres langues, de sorte que le *mouvement* sous-jacent soit strictement identique d'une langue à l'autre. La seule variable est alors le texte, ce qui isole proprement l'effet de la langue sur l'alignement.

3.3 Le pipeline multilingue

3.3.1 Substitution de l'encodeur de texte

La tour de texte CLIP d'origine est remplacée par **M-CLIP** (XLM-RoBERTa-Large / ViT-B-32), gardée *gelée*, avec une unique projection linéaire entraînable $768 \to 512$ vers l'espace latent de mouvement. Geler l'encodeur garantit que toute différence observée provient du latent entraîné, et non d'une dérive de la tour de texte.

3.3.2 Traduction des légendes

Les légendes de HumanML3D sont traduites par NLLB vers six langues (`fr`, `es`, `pt`, `ru`, `zh`, `ar`), soit sept au total avec l'anglais. Durant l'entraînement, chaque clip est présenté dans une langue échantillonnée par clip et par époque.

3.3.3 Banc d'encodeurs par langue

En variante de la tour M-CLIP partagée, on assemble un **banc de sept encodeurs monolingues gelés**, chacun muni de sa propre projection $768 \to 512$: `bert-base-uncased` [22], `camembert-base` [23], BETO pour l'espagnol [24], BERTimbau pour le portugais [25], RuBERT pour le russe [26], `bert-base-chinese`, et AraBERT pour l'arabe [27]. Cela représente **854 M** paramètres gelés et seulement **2,76 M** paramètres de projection entraînables. La question des encadrants, ces projections entraînées *indépendamment* atterrissent-elles dans un espace commun ? C'est ce qui motive directement cette conception.

La figure 3.2 résume la chaîne complète, depuis les légendes anglaises jusqu'au signal d'entraînement multilingue.

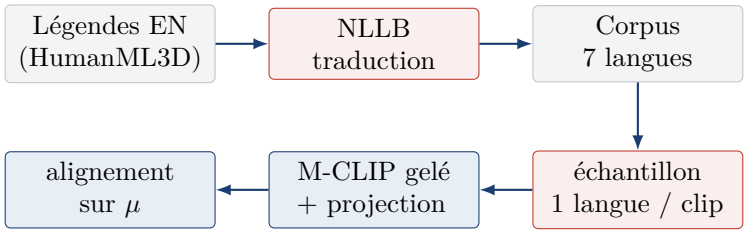


Figure 3.2. Chaîne de traitement multilingue : les légendes anglaises sont traduites par NLLB en six langues, une langue est échantillonnée par clip et par époque, encodée par M-CLIP gelé puis projetée, et enfin alignée sur le latent de mouvement.

3.4 Formulation variationnelle et fonction de coût

La fonction de coût d'entraînement est une somme pondérée de cinq termes :

$$\mathcal{L} \;=\; 100 \cdot \mathrm{rc} \;+\; 100 \cdot \mathrm{vel} \;+\; \lambda_{\cos} \cdot \cos \;+\; \lambda_{\mathrm{CE}} \cdot \mathrm{CE} \;+\; \lambda_{\mathrm{KL}} \cdot \mathrm{KL}. \tag{3.1}$$

Le tableau 3.2 récapitule ces termes. La pondération 100:1 de la reconstruction par rapport au cosinus est *héritée* de MotionCLIP [4] et n'est *pas* ajustée dans ce travail ; on l'indique

explicitement, car la section 5.6 montre que le terme cosinus est le mauvais objectif, quel que soit son poids.

Tableau 3.2. Termes de la fonction de coût de l'équation (3.1). Poids par défaut : $\lambda_{\text{rc}} = \lambda_{\text{vel}} = 100$, $\lambda_{\text{KL}} = 10^{-3}$; λ_{cos} et λ_{CE} varient selon l'expérience.

Terme	Symbole	Définition
Reconstruction	rc	MSE positionnelle, $\|\hat{x} - x\|^2$
Vitesse	vel	MSE sur les différences image-à-image ; supprime le tremblement
Cosinus	cos	moyenne $(1 - \cos(e_{\text{texte}}, \mu))$, paires appariées seulement
Contrastif	CE	InfoNCE sur les négatifs intra-lot
KL	KL	$-\frac{1}{2}\sum(1 + \log\sigma^2 - \mu^2 - \sigma^2)$

3.4.1 Justification des poids de la perte

L'équilibre entre ces cinq termes détermine le comportement du modèle. On en détaille ici la logique.

Reconstruction et vitesse ($\times 100$). Les termes rc et vel sont pondérés fortement (poids 100) car ce sont eux qui garantissent qu'un clip est fidèlement reconstruit. Le terme de vitesse, en pénalisant les différences image-à-image, supprime le tremblement haute fréquence qu'une perte positionnelle seule laisserait passer ; il agit comme un lissage temporel. Le rapport 100:1 vis-à-vis du cosinus est *hérité* de MotionCLIP et n'a pas été ré-optimisé : ce choix est explicitement assumé, car la section 5.6 montre que le terme cosinus est le mauvais objectif, quel que soit son poids.

KL (10^{-3}). Le poids KL est volontairement faible. Un KL trop fort provoquerait un effondrement postérieur (section 2.4) ; trop faible, il ne régulariserait pas l'espace latent. La valeur 10^{-3} est un compromis usuel ; la série KL (section 5.3) montre toutefois que, dans ce modèle à latent unique, le résultat est largement *insensible* à ce poids, l'échantillonnage dominant.

Cosinus et contrastif (variables). Les poids λ_{cos} et λ_{CE} varient selon l'expérience, car ce sont précisément les objets de l'étude sur l'alignement. On y fait notamment varier λ_{cos} d'un facteur 100 (section 5.6) et l'on active ou non le terme contrastif, afin d'isoler l'effet de la présence de négatifs.

Une leçon transversale. Le réglage des poids illustre un fil conducteur du rapport : un hyperparamètre peut sembler déterminant (le poids KL, le poids cosinus) tout en étant, à l'analyse, dominé par une autre variable structurelle (l'échantillonnage, l'absence de négatifs). D'où l'importance de tester chaque hypothèse plutôt que de supposer qu'un poids élevé implique un effet fort.

3.5 Les deux objectifs d'alignement

3.5.1 Similarité cosinus

Le terme cosinus (équation (2.21)) rapproche chaque embedding de texte apparié de son latent de mouvement. Il porte sur les *paires appariées uniquement* : il ne contient aucun négatif et n'éloigne donc jamais les paires non appariées.

3.5.2 Entropie croisée contrastive

Le terme contrastif est l'InfoNCE (équation (2.20)) sur les négatifs intra-lot : pour chaque mouvement, il élève la similarité de sa propre légende au-dessus de celle de toutes les autres légendes du lot. La présence ou l'absence de négatifs est la différence opératoire entre les deux objectifs, et la section 5.6 montre qu'elle est décisive.

3.6 Justification des choix de conception

Plusieurs décisions de conception structurent ce travail. Le tableau 3.3 les récapitule, avec leur justification et le compromis associé. Un principe directeur les relie toutes : *isoler une variable à la fois*. Geler l'encodeur de texte isole l'effet du latent ; apparier la capacité et le calcul isole l'effet du multilinguisme ; évaluer sur un jeu de test commun rend les chiffres comparables. C'est ce souci de contrôle, davantage que la quête d'un FID record, qui définit la méthodologie du rapport.

Tableau 3.3. Principaux choix de conception, justification et compromis.

Choix	Justification	Compromis
Base MotionCLIP	simplicité et transparence, idéale pour une étude contrôlée	générateur faible (FID élevé)
Encodeur de texte gelé	isole l'effet du latent entraîné	pas d'adaptation du texte au mouvement
Projection 768→512 seule entraînable	très peu de paramètres, effet du multilinguisme isolé	capacité d'alignement limitée
Latent unique de 512	taille fixe, hérité de MotionCLIP	goulot (section 2.10)
Traduction NLLB	obtention rapide d'un corpus 7 langues	artefacts de traduction (section 6.2)
Capacité et pas appariés	comparaison EN vs multilingue équitable	exposition par langue non appariée

3.7 Protocole d'évaluation

Deux évaluateurs sont utilisés et leurs chiffres ne sont jamais comparables. L'**Évaluateur A** est l'évaluateur de Guo/MoMask sur le *split officiel* de HumanML3D ; il rapporte une FID ≈ 16 et n'est utilisé que pour le tableau baseline M-CLIP (section 5.1). L'**Évaluateur B** s'exécute sur le pool de validation de 1 400 clips et rapporte une FID ≈ 56–120 ; il est utilisé pour toutes les comparaisons de VAE. Un chiffre de A et un chiffre de B ne doivent jamais apparaître dans la même comparaison.

Tableau 3.4. Les deux évaluateurs et leurs domaines d'emploi. Leurs FID ne sont pas comparables car ils reposent sur des jeux de test et des extracteurs distincts.

	Évaluateur A	**Évaluateur B**
Jeu de test	split officiel HumanML3D	pool de validation (1 400 clips)
Plage de FID	≈ 16	≈ 56–120
Usage	baseline M-CLIP (§5.1)	toutes les comparaisons de VAE
Réplications	20	20

3.7.1 Métriques de génération

Les deux évaluateurs rapportent la **FID** [21] (plus faible est meilleure), la **R-précision** (R@1/2/3/10), la **MM-Dist** (plus faible est meilleure) et la **diversité**, chacune sur **20 réplications**. Rappel : la R-précision est *anglophone par construction* (tour de texte GloVe BiGRU) ; la qualité par langue est donc jugée par la FID seule.

3.7.2 Mesure de l'alignement latent

Pour déterminer si texte et mouvement sont alignés *par échantillon*, on calcule la similarité cosinus des paires **appariées** contre **non appariées**, sur 500 clips disposant de légendes parallèles dans les sept langues, et l'on rapporte l'**écart** (*gap*) entre les deux. Comme le montre la section 5.6, la moyenne cosinus des paires appariées, prise seule, est activement trompeuse : elle peut avoisiner 1,0 tandis que l'écart, la quantité qui reflète réellement l'alignement, est nul.

3.7.3 Amplitude du mouvement

On emploie enfin le diagnostic d'amplitude défini en section 2.9 : la différence absolue moyenne entre images consécutives (quantité globale de mouvement), ainsi que la différence entre mouvements produits pour des *prompts* distincts (force du conditionnement).

3.8 Principe de la comparaison contrôlée

La contribution centrale du rapport étant une *comparaison* (anglais contre multilingue), sa validité repose entièrement sur la rigueur du protocole. Trois principes méthodologiques

sont appliqués systématiquement :

1. **Appariement de la capacité.** Toutes les conditions comparées utilisent la *même* architecture (8 couches, latent 512) et le même nombre de paramètres entraînables. Une différence de performance ne peut donc être imputée à une capacité différente.
2. **Appariement du calcul.** Toutes les conditions sont entraînées pour le *même* nombre de pas de gradient (même nombre d'époques, même taille de lot). Le multilinguisme n'obtient ainsi aucun « budget de calcul supplémentaire ». Le revers, assumé, est que l'exposition *par langue* n'est pas appariée : sous N langues, chaque clip n'est vu dans une langue donnée qu'environ $1/N$ du temps (section 6.2).
3. **Jeu de test commun.** L'alignement est mesuré sur les *mêmes* 500 clips à légendes parallèles, et la génération sur le *même* évaluateur, de sorte que les chiffres de conditions différentes sont directement comparables.

Ce cadre n'élimine pas tous les facteurs de confusion, mais il garantit que les conclusions qualitatives (le multilinguisme divise le budget, le contrastif aligne, le cosinus n'aligne pas) reposent sur des comparaisons *toutes choses égales par ailleurs*, à la seule exception explicitement identifiée de l'exposition par langue.

Chapitre 4

Implémentation

Ce chapitre détaille la mise en œuvre pratique du système : l'environnement matériel et la configuration d'entraînement (section 4.1), la réalisation du pipeline multilingue (section 4.2), les outils réutilisables développés au cours du stage (section 4.6) et, enfin, les bogues et pièges rencontrés (section 4.7), dont plusieurs se sont révélés décisifs pour l'interprétation des résultats.

4.1 Environnement matériel et configuration d'entraînement

Toutes les expériences ont été menées sur un unique GPU **NVIDIA RTX 5090** (32 Go), partagé. L'entraînement à un lot de taille 128 s'exécute en ∼32 s par époque. Les entraînements longs étaient détachés au moyen de `setsid` (et non de `nohup`+`disown`, qui ne survivait pas aux déconnexions SSH sur cette machine). La configuration par défaut est : lot 128, taux d'apprentissage 10^{-4}, 60 images, latent 512, 8 couches, activations GELU, $\lambda_{\text{rc}} = 100$, $\lambda_{\text{vel}} = 100$, $\lambda_{\text{KL}} = 10^{-3}$.

4.2 Réalisation du pipeline multilingue

Traduction. Le script `translate_nllb.py` traduit les légendes de HumanML3D vers les six langues cibles au moyen de NLLB, en gérant le découpage en lots et la mise en cache des traductions pour éviter de recalculer un corpus volumineux.

Encodeur M-CLIP. L'encodeur M-CLIP est encapsulé dans `mclip_wrapper.py`, qui expose une méthode `encode_text_raw` renvoyant l'embedding 768-d avant projection. Un paramètre `logit_scale` (température apprenable, mais gelée) y est ajouté, sans lequel le chemin contrastif ne peut être calculé.

Banc par langue. Le banc d'encodeurs monolingues est implémenté dans `per_lang_encoder.py`, qui charge les sept modèles gelés et route chaque légende vers l'encodeur correspondant à sa langue, avant d'appliquer la projection propre à cette langue. L'ensemble des modifications apportées au code de base de MotionCLIP (termes du VAE, recuit du KL, substitution M-CLIP, échantillonnage multilingue, banc par langue) est regroupé dans une série de *patches* versionnés (`patch_vae.py`, `patch_anneal.py`, `patch_mclip.py`, `patch_ml.py`, `patch_perlang.py`).

4.3 Chargement et échantillonnage des données

Échantillonnage de la langue. À chaque présentation d'un clip, une langue est tirée uniformément parmi les N langues actives, et la légende correspondante (pré-traduite) est sélectionnée. Ce tirage est effectué *par clip et par époque* : un même clip sera donc vu, au fil de l'entraînement, dans différentes langues. À nombre de pas de gradient fixé, un clip est ainsi exposé à une langue donnée environ $1/N$ du temps. Ce choix, qui apparie le *calcul* mais non l'*exposition*, est le facteur de confusion central de l'étude (section 6.2).

Routage dans le banc par langue. Pour la variante à encodeurs monolingues, chaque légende doit être dirigée vers le bon encodeur. Le module `per_lang_encoder.py` maintient un dictionnaire langue $\rightarrow$ (modèle, tokeniseur, projection) et regroupe, au sein d'un lot, les légendes par langue afin de limiter les changements de contexte et d'exploiter le traitement par lots de chaque encodeur. Les sept encodeurs étant gelés, leurs sorties pourraient en principe être *pré-calculées et mises en cache* ; cette optimisation, non réalisée faute de temps, réduirait sensiblement le coût d'entraînement de la variante par langue.

Contraintes mémoire. Le banc d'encodeurs représente 854 M de paramètres gelés ; les maintenir en mémoire aux côtés de l'autoencodeur de mouvement et des tenseurs d'activation impose une gestion attentive de la mémoire du GPU (32 Go). La tour M-CLIP partagée, à l'inverse, n'a qu'un seul encodeur en mémoire, ce qui la rend plus économe et explique pourquoi la majorité des expériences l'utilisent.

4.4 Boucle d'entraînement

L'algorithme 1 décrit une époque d'entraînement. À chaque lot, une langue est échantillonnée par clip, l'encodeur de mouvement produit (μ, σ), le latent est tiré par reparamétrisation (ou pris égal à μ en mode déterministe), le décodeur reconstruit le clip, et la perte composite de l'équation (3.1) est rétropropagée. L'encodeur de texte reste gelé ; seuls l'autoencodeur de mouvement et la projection de texte reçoivent un gradient.

Deux détails d'implémentation méritent d'être soulignés. D'une part, le mode déterministe ($z = \mu$) n'est pas un cas particulier anodin : c'est lui qui permet de récupérer un modèle fonctionnel (section 5.4). D'autre part, l'échantillonnage de la langue *par clip et par époque* signifie qu'un même clip est vu, au fil des époques, dans des langues différentes ; c'est ce qui donne son sens à l'exposition moyenne de $1/N$ par langue.

4.5 Coût computationnel

L'ensemble des expériences a été mené sur un unique GPU, ce qui impose une discipline sur le coût de chaque entraînement. Le tableau 4.1 donne les ordres de grandeur. Un entraînement de 150 époques représente environ $150 \times 32\,\text{s} \approx 80\,\text{min}$, ce qui a rendu possible le balayage de nombreuses conditions malgré la ressource unique.

Algorithme 1: Une époque d'entraînement du VAE de mouvement multilingue.

Entrées: clips $\{x\}$, légendes multilingues, encodeur texte gelé f_t, poids $(\lambda_{\text{rc}}, \lambda_{\text{vel}}, \lambda_{\cos}, \lambda_{\text{CE}}, \lambda_{\text{KL}})$, indicateur `sampling`

Sortie: paramètres entraînés de l'encodeur/décodeur de mouvement et de la projection

for *chaque lot* $(x, \textit{légendes})$ **do**
  pour chaque clip, échantillonner une langue ℓ et sa légende c_ℓ
  $e_{\text{texte}} \leftarrow \texttt{proj}(f_t(c_\ell))$ `// texte gelé + projection`
  $(\mu, \sigma) \leftarrow E_\phi(x)$ `// encodeur de mouvement`
  if *sampling* **then**
    $z \leftarrow \mu + \sigma \odot \varepsilon,\ \varepsilon \sim \mathcal{N}(0, I)$
  else
    $z \leftarrow \mu$
  end
  $\hat{x} \leftarrow D_\theta(z)$ `// décodeur`
  calculer rc, vel, cos, CE, KL `// termes de la perte`
  $\mathcal{L} \leftarrow 100\,\text{rc} + 100\,\text{vel} + \lambda_{\cos}\cos + \lambda_{\text{CE}}\text{CE} + \lambda_{\text{KL}}\,\text{KL}$
  rétropropager $\mathcal{L}$ et mettre à jour ϕ, θ, `proj`
end

Tableau 4.1. Ordres de grandeur du coût de calcul (GPU RTX 5090, lot 128).

Grandeur	Valeur
Durée par époque	≈ 32 s
Entraînement court (20 ép.)	≈ 11 min
Entraînement standard (150 ép.)	≈ 80 min
Entraînement long (300–330 ép.)	≈ 3 h
Paramètres texte entraînables (M-CLIP)	$\approx 0{,}39$ M
Paramètres texte entraînables (banc de 7)	$\approx 2{,}76$ M
Paramètres gelés (banc BERT)	≈ 854 M
Évaluation (20 réplications)	quelques minutes

4.6 Outils réutilisables développés

Plusieurs outils génériques ont été écrits et laissés au dépôt pour la suite du projet :

— `eval_latent_alignment.py`, calcule l'écart apparié/non apparié et la récupération, pour les sept langues et par point de contrôle.

— `plot_training_curves.py`, analyse le journal `training.log` et produit les figures de convergence.

— `translate_nllb.py`, traduction NLLB des légendes vers les six langues cibles.

— `eval_all.sh`, évalue toutes les conditions `ce150-*` (alignement + génération) ; c'est la source de la comparaison contrôlée de la section 5.11.

4.7 Bogues et pièges connus

Cette section documente des pièges d'implémentation dont certains ont faussé des conclusions intermédiaires, et qu'il est essentiel de connaître pour reproduire ou poursuivre

le travail.

— **`reparameterize()` couple λ_{KL} à l'échantillonnage.** L'échantillonnage s'active dès que $\lambda_{\mathrm{KL}} \neq 0$; en conséquence, chaque entraînement avec recuit du KL s'effectuait avec un *bruit à pleine amplitude dès l'époque 1*, seule la *pénalité* étant progressivement montée. C'est la raison pour laquelle le recuit *semblait* échouer (section 5.4).

— **Les scripts d'évaluation codaient en dur les points de contrôle.** `eval_guo_vae_compare_beta05.py` et `gen_hml.py` acceptent désormais une option `--ckpt` ; `eval_noise_val100.py` ne la respecte *toujours* pas et l'ignore.

— **`gen_hml.py` supposait un CLIP standard** (appel à `clip.tokenize`) ; il a été corrigé pour utiliser `encode_text_raw` avec une option `--text_encoder` qui *doit* correspondre à la manière dont le point de contrôle a été entraîné, sous peine de produire une sortie silencieusement dénuée de sens.

— **`logit_scale` manquait aux deux encodeurs de texte personnalisés** ; il a été ajouté comme paramètre apprenable (gelé) à `mclip_wrapper.py` et `per_lang_encoder.py`, faute de quoi le chemin contrastif plante.

— **Les pertes d'entraînement ne sont pas des preuves.** La perte contrastive est restée proche de ln(taille du lot) alors que l'alignement s'améliorait d'un facteur 100, et la reconstruction semblait saine tandis que le mouvement s'effondrait. Il faut toujours vérifier contre une métrique d'évaluation.

Chapitre 5

Expériences et résultats

Ce chapitre est écrit comme une *séquence* dans laquelle chaque résultat motive le suivant. Il commence par une baseline multilingue qui fonctionne, passe à une variante par langue qui *semble* échouer, puis, à travers la série KL, découvre que l'objectif sous lequel cet échec avait été mesuré est lui-même non informatif. La suite construit la bonne mesure d'alignement, expose le compromis génération–discrimination et l'effondrement de l'amplitude, et se clôt par la comparaison contrôlée qui était la question initiale du stage.

5.1 Baseline multilingue

On établit d'abord que le conditionnement multilingue fonctionne. Le tableau 5.1 rapporte les variantes M-CLIP sous **Évaluateur A** (split officiel, 20 réplications), regroupées par ensemble de langues : *Latines* = {en, fr, es, pt}, *Éloignées* = {en, ru, zh, ar}.

Tableau 5.1. Baseline multilingue. **Évaluateur A**, split officiel HumanML3D, 20 réplications. Meilleure valeur de modèle par colonne en gras.

Modèle	FID↓	Diversité	R@1	R@2	R@3	MM-Dist↓
Vérité terrain	0,010	9,465	0,527	0,714	0,813	2,924
M-CLIP EN	18,013	7,215	0,128	0,235	0,327	6,002
M-CLIP Latines	**16,140**	6,697	**0,136**	**0,244**	**0,344**	**5,757**
M-CLIP Éloignées	18,046	7,002	0,111	0,215	0,304	6,003
M-CLIP Toutes	17,829	7,092	0,119	0,220	0,310	6,057

L'ensemble Latines donne le meilleur FID (16,14) et la meilleure récupération, légèrement devant l'anglais seul. Le conditionnement multilingue n'est pas seulement toléré : sur ce split, il *aide*. C'est le résultat encourageant qui a motivé le reste du stage.

Interprétation. Pourquoi l'ajout de langues latines améliore-t-il légèrement le FID sur ce split ? Deux lectures sont possibles. D'une part, les traductions latines, partageant de nombreux radicaux avec l'anglais, pourraient agir comme une forme d'*augmentation de données* textuelle, régularisant la projection. D'autre part, l'effet est modeste (16,14 contre 18,01) et mesuré sous l'objectif cosinus et l'Évaluateur A ; il ne contredit pas la dégradation observée plus loin (section 5.11), mesurée sous contrastif et Évaluateur B. Il s'agit du *même* phénomène lu avec deux instruments différents : ce rappel, répété tout au long du rapport, est essentiel pour ne pas sur-interpréter un chiffre isolé.

5.2 Encodeurs par langue, première tentative

On a ensuite remplacé la tour M-CLIP partagée par le banc par langue (sous-ensemble Latines, quatre encodeurs gelés). Sous **Évaluateur A**, cela semblait échouer nettement : FID 24,55 contre 16,14, R@1 0,079 contre 0,136, et la diversité chutait à ∼4,0. La reconstruction, elle, était préservée (rc = 0,086 contre 0,083) : le décodeur était donc intact et c'était l'*alignement* qui faisait défaut.

> **Mise en garde, énoncée d'emblée.** Cette comparaison a été mesurée sous l'objectif *cosinus*, dont la section 5.6 montre qu'il ne produit *aucun* alignement par échantillon, dans *aucune* condition. La comparaison est donc non informative sur les encodeurs par langue ; elle est reprise sous un objectif contrastif à la section 5.10, où le verdict s'inverse.

5.3 La série KL : l'échantillonnage, pas la régularisation

En passant à un modèle variationnel, la reconstruction s'est immédiatement effondrée. Le suspect naturel était la pénalité KL. Ce n'en est pas la cause. Le tableau 5.2 fait varier le traitement du KL sur quatre interventions couvrant deux ordres de grandeur de λ_{KL}.

Tableau 5.2. La série KL (échantillonnage actif). Perte de reconstruction sous quatre interventions. Écart total : 0,002.

Configuration	rc ↓
Autoencodeur déterministe (sans échantillonnage)	**0,083**
VAE, $\lambda_{\mathrm{KL}} = 10^{-5}$	0,524
VAE, $\lambda_{\mathrm{KL}} = 10^{-3}$ (100× plus fort)	0,526
VAE, cosinus retiré (façon ACTOR)	0,524
VAE, λ_{KL} recuit sur 30 époques	0,525

L'autoencodeur déterministe reconstruit à 0,083 ; dès que l'échantillonnage est activé, la reconstruction bondit à ∼0,52 et *y reste*, que le poids KL vaille 10^{-5} ou 10^{-3}, que le terme cosinus soit présent ou retiré, et que la pénalité soit recuite ou non. Quatre interventions, écart total **0,002**. **L'échantillonnage est la contrainte liante, pas le poids du KL.** La proposition 2.2 (section 2.10) en donne la raison structurelle : un latent unique alimente les 60 images, et le terme de dégradation somme sur toutes ces images.

Ce que ce résultat change. La conséquence pratique est immédiate : il est inutile de chercher le « bon » poids KL pour sauver la reconstruction, puisque deux ordres de grandeur de ce poids ne déplacent l'erreur que de 0,002. Le levier pertinent est ailleurs : soit retirer le bruit du chemin de reconstruction (ce que fait la section suivante), soit changer d'architecture pour que le bruit ne pèse plus sur tout le clip (chapitre 6). Ce résultat illustre aussi une règle méthodologique du rapport : quand une intervention ne

produit aucun effet sur une large plage, la variable manipulée n'est probablement pas la bonne.

5.4 Reconstruction déterministe et VAE fonctionnel

Si l'échantillonnage est le problème, le correctif est de reconstruire depuis μ tout en conservant le terme KL. Cela ramène la reconstruction de 0,52 à **0,16**. Le banc KL sous **Évaluateur B** (tableau 5.3) montre alors que le KL *aide* réellement la génération, et que le recuit *nuit* dans les deux calendriers essayés.

Tableau 5.3. Banc KL. **Évaluateur B**, pool de validation de 1 400 clips, 20 réplications. Le KL aide ; le recuit nuit.

Modèle	FID↓
$\lambda_{\mathrm{KL}} = 0$	97,633
$\lambda_{\mathrm{KL}} = 10^{-3}$	**55,864**
$\lambda_{\mathrm{KL}} = 10^{-3}$ + recuit sur 30 époques	105,683
$\lambda_{\mathrm{KL}} = 10^{-3}$ + recuit sur 5 époques	100,893

Le recuit n'a jamais eu un test équitable. Dans `reparameterize()`, l'échantillonnage s'active dès que $\lambda_{\mathrm{KL}} \neq 0$; chaque entraînement recuit s'effectuait donc avec un *bruit à pleine amplitude dès l'époque 1*, seule la pénalité étant progressivement montée. En séparant les deux variables, on obtient le tableau 5.4 : entraîner en déterministe jusqu'à convergence, puis activer l'échantillonnage.

Tableau 5.4. Entraînement déterministe-puis-stochastique. L'échantillonnage n'est activé qu'après 300 époques déterministes.

Configuration	Éch.	rc ↓
Échantillonnage dès l'initialisation	actif	$\sim 0,52$
Déterministe, 300 époques	inactif	0,093
+ 10 époques d'affinage	**actif**	**0,086**

Mise en garde à ne pas perdre. Deux variables ont changé entre les deux dernières lignes : l'échantillonnage a été activé *et* 10 époques supplémentaires ont été menées. L'affirmation défendable est que *l'échantillonnage ne détruit plus la reconstruction*, et non qu'il l'améliore. Le contrôle manquant, 10 époques *déterministes* supplémentaires depuis le même point de contrôle, reste un fil ouvert.

5.5 Robustesse au bruit : une branche délibérément fermée

Une manière tentante de rendre le latent tolérant à l'échantillonnage est de l'affiner sous bruit injecté $z = \mu + \beta\varepsilon$. La reconstruction se dégrade régulièrement avec β (tableau 5.5), et un affinage à $\beta = 0{,}10$ a donné une amélioration de reconstruction de **+25,5 %** : **92 %** des clips améliorés, intervalle de confiance bootstrap à 95 % [0,227 ; 0,373]. Statistiquement, le résultat est solide.

Tableau 5.5. Reconstruction sous bruit injecté $z = \mu + \beta\varepsilon$.

β	0	0,1	0,25	0,5	1,0
rc	0,0805	0,0922	0,1621	0,3857	0,6529

En aval, il échoue. Le tableau 5.6 montre l'affinage à $\beta = 0{,}10$ *dégradant* toutes les métriques de génération. La distillation par un modèle enseignant et le gel de l'encodeur ont également été essayés sans succès. La branche a été fermée.

Tableau 5.6. Effet en aval de l'affinage à $\beta = 0{,}10$. **Évaluateur B**. Le gain auxiliaire ne se transfère pas.

	R@1	R@3	FID↓	MM-Dist↓
original	**0,062**	**0,104**	**57,317**	**7,274**
affiné $\beta = 0{,}10$	0,031	0,073	86,774	9,165

Le transfert négatif est précisément le point. Une amélioration sur une métrique auxiliaire (la reconstruction sous bruit) n'atteint pas la génération par défaut ; elle peut même activement lui nuire. La branche est rapportée en entier pour cette raison même.

5.6 L'alignement n'est pas ce que mesure la moyenne cosinus

On revient à la question des encadrants en mesurant l'alignement *correctement*. Le VAE multilingue `vae-multilingual-mclip` (20 époques) s'entraîne proprement : rc = 0,1550, vel = 0,0594, KL = 76,77, cosinus-texte = 0,3127. Sa FID par langue sur le pool multilingue est uniforme (tableau 5.7), et la dérive de génération inter-lingue vis-à-vis de la version anglaise est minuscule (0,010–0,017).

Tableau 5.7. FID par langue, pool multilingue (**Évaluateur B**, pas le split officiel). Uniforme d'une langue à l'autre.

ZH	PT	RU	FR	AR	EN	ES
99,777	106,077	108,627	108,665	112,151	114,813	124,894

L'alignement *dans l'espace textuel* entre les embeddings M-CLIP est très élevé (mean EN↔non-EN **0,9750**, plage 0,963–0,982).

> **Mise en garde.** Cette dernière mesure porte sur *M-CLIP*, un modèle pré-entraîné et gelé. Elle indique que les embeddings de texte sont déjà alignés entre langues ; elle ne dit *rien* de ce que le VAE a appris sur le mouvement.

La mesure qui compte est la similarité appariée contre non appariée sur 500 clips à mouvements identiques et légendes parallèles (tableau 5.8). Le hasard pour R@1 sur 500 candidats est 0,002.

Tableau 5.8. Cosinus apparié contre non apparié, 500 clips, légendes parallèles (anglais). C'est l'écart, et non la moyenne, qui reflète l'alignement.

Objectif	apparié	non apparié	**écart**	R@1
cosinus, $\lambda = 1$	0,7284	0,7282	0,0002	0,008
cosinus, $\lambda = 100$	0,9777	0,9770	0,0007	0,012
contrastif CE	**0,0459**	0,0273	**0,0186**	**0,068**

Sous l'objectif cosinus, l'écart est quasi nul et R@1 reste au niveau du hasard. Augmenter le poids cosinus 100× l'aggrave : l'écart-type par clip *chute* de 0,073 à 0,005, c'est-à-dire que la représentation s'effondre davantage. **Pourquoi :** l'objectif cosinus ne somme que sur les paires appariées ; placer chaque μ_i sur la direction textuelle moyenne est un optimum global, la perte baisse tandis qu'appariées et non appariées restent identiques. Aucun poids ne corrige un terme manquant. On notera que la moyenne cosinus *chute* de 0,978 à 0,046 au cours du correctif, alors que le modèle s'améliore d'un ordre de grandeur en R@1 : **on déconseille donc la moyenne cosinus comme diagnostic** pour cette classe de modèles, et l'on emploie l'écart apparié–non-apparié dans toute la suite.

5.7 Alignement contrastif à travers les langues

L'objectif contrastif produit un écart réel et croissant dans chaque langue. Le tableau 5.9 le suit au cours de l'entraînement ; la figure 5.1 le trace.

Tableau 5.9. Écart d'alignement par langue sous CE contrastif, au cours de l'entraînement. Monotone dans chaque langue ; ordre identique à chaque point de contrôle.

époque	en	fr	es	pt	ru	zh	ar
20	0,0186	0,0175	0,0187	0,0168	0,0154	0,0134	0,0155
40	0,0217	0,0208	0,0217	0,0201	0,0181	0,0158	0,0182
60	0,0240	0,0232	0,0244	0,0225	0,0201	0,0174	0,0203
80	0,0264	0,0259	0,0271	0,0249	0,0221	0,0193	0,0223
100	**0,0286**	0,0282	**0,0296**	0,0273	0,0239	0,0207	0,0241

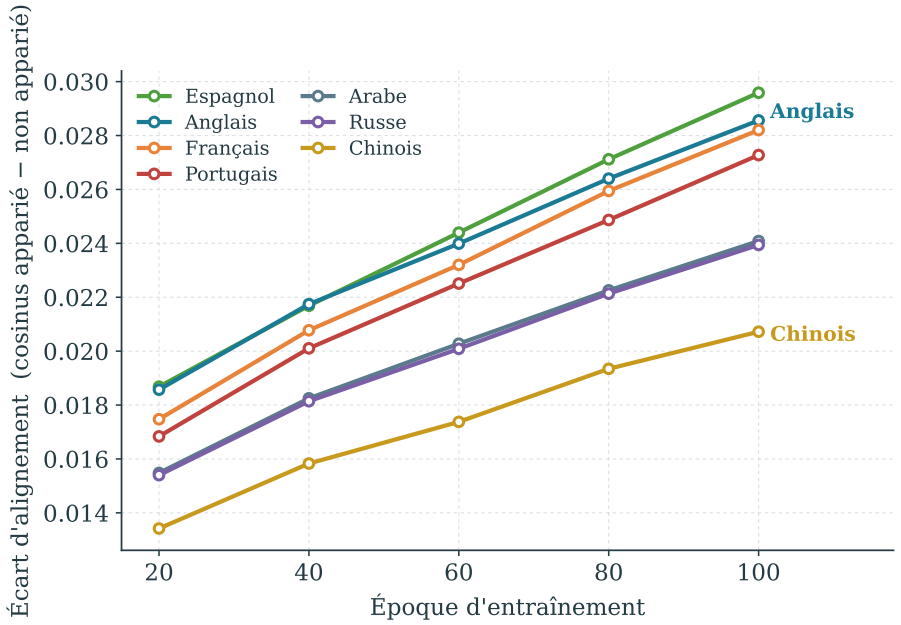


Figure 5.1. Écart d'alignement (cosinus apparié − non apparié) en fonction de l'époque, une courbe par langue, CE contrastif. L'écart croît de façon monotone dans chaque langue, sans plateau. L'ordre es ≈ en > fr > pt > ar ≈ ru > zh est *identique à chaque point de contrôle* : c'est une structure, et non du bruit. Le chinois accuse un retard de 28 % sur l'anglais à l'époque 100.

L'ordre inter-lingue se maintient à chaque point de contrôle, et l'entraînement long (300 époques) ne montre aucun plateau. La récupération à 300 époques (lot 128) atteint R@1 0,068, R@3 0,174, R@10 0,340, contre un hasard de 0,002/0,006/0,020. L'alignement est réel et bien au-dessus du hasard, là où le cosinus n'en produisait aucun.

Interprétation. Deux propriétés de ces courbes méritent d'être soulignées. La *monotonie* : l'écart ne cesse de croître jusqu'à 300 époques, ce qui indique que le budget d'entraînement, et non la capacité du modèle, limitait encore l'alignement. La *stabilité de l'ordre* : les langues ne se croisent jamais, ce qui exclut que les différences soient du bruit d'entraînement. Le fait que l'espagnol rattrape, voire dépasse, l'anglais est cohérent avec la proximité des langues romanes et la qualité de la traduction vers l'espagnol ; le retard du chinois, de son côté, est cohérent avec la distance linguistique et la plus grande difficulté de la traduction automatique vers cette langue.

5.8 Le compromis génération–discrimination

L'objectif contrastif qui répare l'alignement *coûte* de la qualité de génération. Le tableau 5.10 place les deux objectifs côte à côte.

Pourquoi ils se dissocient : l'InfoNCE ne contraint que le *classement* des paires appariées contre non appariées, une propriété sans échelle et purement directionnelle. Il n'exige jamais que le latent conserve assez d'information pour *reconstruire* un mouvement distinct, seulement assez pour être *distinguable*. Une représentation peut donc être très discriminante et mal décodable en même temps. On a par ailleurs vérifié que ce n'est pas

Tableau 5.10. Le compromis génération–discrimination. **Évaluateur B**. Le CE contrastif achète l'alignement et la récupération au prix du FID.

Objectif	écart (en)	R@10	FID↓	Diversité
cosinus	0,0002	0,024	**55,864**	–
contrastif CE, 300 ép.	**0,0286**	**0,340**	72,902	0,922
mouvement réel	–	–	0,000	9,675

une inadéquation d'échelle : renormaliser les embeddings de texte à la norme du latent (20,413 contre 9,232) ne change le FID que de 2,1 (72,902 → 70,786).

Une image pour s'en souvenir. On peut se représenter la différence ainsi : le contrastif apprend au modèle à *reconnaître* un mouvement parmi d'autres, comme on reconnaît un visage dans une foule sans pouvoir le dessiner. La génération, elle, demande de savoir *dessiner*. Les deux compétences sont liées, mais l'une n'implique pas l'autre : c'est exactement ce que mesure le tableau 5.10.

5.9 L'effondrement de l'amplitude du mouvement

L'échec de génération le plus lourd de conséquences est l'effondrement des mouvements vers une pose quasi statique. À l'aide du diagnostic d'amplitude, le tableau 5.11 montre l'amplitude *décroître* à mesure que les modèles s'entraînent plus longtemps et s'améliorent sur toutes les autres métriques.

Tableau 5.11. Amplitude du mouvement (différence absolue moyenne image-à-image) et différence entre *prompts* (marche contre saut). Les modèles mieux entraînés bougent moins.

Modèle	époques	amplitude	marche/saut	ratio
vae-en-mu-kl1e-3 (cosinus)	20	**0,0768**	0,1127	1,5
vel10-test	60	0,0145	0,0526	3,6
ce150-combined	150	0,0108	0,0409	3,8
ce150-all	150	0,0063	–	–
vae-ml-sampled-ft	330	0,0044	0,0204	4,6

Trois explications sont écartées, une à une. **(1) Ce n'est pas un artefact de rendu** : le point de contrôle à 20 époques affiche des poses visiblement différentes selon le *prompt* via le même script. **(2) Ce n'est pas une inadéquation d'échelle des embeddings** : la renormalisation a rendu l'amplitude *pire* (0,01075 → 0,00607). **(3) Ce n'est pas le poids de la vitesse** : à époques appariées, $\lambda_{\text{vel}} = 10$ donne légèrement *moins* d'amplitude que $\lambda_{\text{vel}} = 100$. Ce qu'il *est* : une décroissance monotone au sein d'un même entraînement, tout le reste étant fixé (figure 5.2).

Interprétation. La reconstruction MSE pousse le décodeur vers des moyennes conditionnelles ; moyennée sur un mouvement groupé, cette moyenne est une pose debout quasi statique. Les points de contrôle précoces n'y ont pas encore convergé et produisent donc

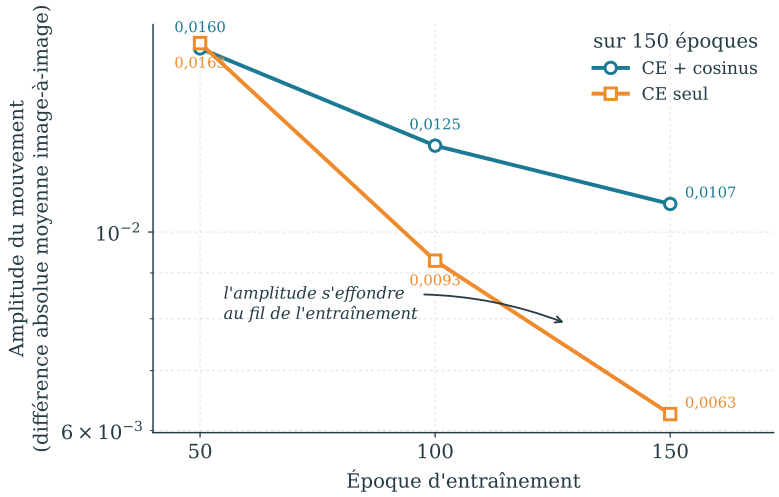


Figure 5.2. Amplitude du mouvement en fonction de l'époque pour deux entraînements (axe y logarithmique). L'amplitude décroît de façon monotone à mesure que l'entraînement progresse. Le modèle « meilleur » à 20 époques du tableau 5.11 est simplement *moins convergé* : sa forte amplitude est de la variance sous-entraînée, non un mouvement supérieur.

encore de la variation. Ceci est directement visible sur les squelettes générés (figure 5.3), qui bougent à peine sur 60 images. On a par ailleurs vérifié que l'*encodeur* est sain : le cosinus mouvement–mouvement sur 200 clips couvre 0,31–0,98 (moyenne 0,61) ; l'effondrement est du côté *décodeur*, et uniquement sur le chemin conditionné par le texte.

Pourquoi la moyenne est une pose immobile. L'argument peut être rendu précis. Pour une perte quadratique, la prédiction optimale d'un décodeur qui ne dispose que d'une information partielle c sur le clip est la *moyenne conditionnelle* $\mathbb{E}[x \mid c]$. Si c ne détermine pas la phase du mouvement (à quel instant le pied gauche se lève, par exemple), cette moyenne fait la moyenne de mouvements *déphasés* : les oscillations s'annulent et il ne reste que la pose centrale. Plus l'entraînement converge vers cet optimum, plus le mouvement généré s'immobilise ; c'est exactement la décroissance monotone observée. Un modèle génératif véritable doit au contraire *échantillonner* une phase particulière, ce que permettent la diffusion ou les tokens discrets, mais pas une régression MSE depuis un latent unique.

5.10 Reconstruction conditionnée par le texte

Le décodeur n'est entraîné que sur les latents de mouvement μ, alors qu'à la génération il reçoit un embedding de *texte* e_{texte} (figure 3.1). Cette substitution n'est jamais optimisée. On ajoute donc un terme qui entraîne exactement le chemin utilisé à la génération :

$$\mathcal{L}_{\text{text-rc}} \;=\; \|D(e_{\text{texte}}) - x\|^2. \tag{5.1}$$

Le tableau 5.12 rapporte des résultats à 150 époques.

Deux constats en découlent. **Le conditionnement textuel a augmenté d'un facteur 6–7** (0,041 → 0,293) : le décodeur répond désormais fortement à la phrase qu'on lui donne. Mais l'amplitude a encore chuté, à 0,003 : le terme récompense la bonne *pose*

Tableau 5.12. Reconstruction conditionnée par le texte et choix de l'encodeur, 150 époques. « marche/saut » est la différence entre *prompts* (force du conditionnement).

Entraînement	text_rc	encodeur	amplitude	marche/saut	ratio
ce150-combined	non	M-CLIP	0,0108	0,0409	3,8
wk-rc20	non	M-CLIP	0,0078	0,0376	4,8
wk-textrc	**oui**	M-CLIP	0,0042	**0,2456**	**58**
wk-textrc-rc20	**oui**	M-CLIP	0,0030	**0,2933**	**99**
wk-perlang	non	par langue	**0,0174**	0,0934	5,4
wk-perlang-comb	non	par langue	**0,0192**	0,0972	5,1

pour un clip, non la *trajectoire*, puisqu'un seul embedding de texte doit expliquer les 60 images. Le correctif naturel, appliquer aussi le terme de vitesse à la sortie conditionnée par le texte, est proposé mais non encore réalisé. Par ailleurs, **le banc d'encodeurs par langue donne 2–3× plus d'amplitude** que M-CLIP à réglages appariés (0,017–0,019 contre 0,006–0,011). Ceci *inverse* le verdict apparent de la section 5.2, obtenu sous l'objectif cosinus défectueux et qui ne mesurait donc jamais ce qu'il semblait mesurer.

5.11 Comparaison contrôlée : EN / Latines / Éloignées / Toutes

On en vient enfin à la question du stage. Toutes les conditions sont entraînées sur 150 époques, lot 128, CE contrastif, $\lambda_{\mathrm{KL}} = 10^{-3}$, encodeur M-CLIP, *identiques en tout point sauf l'ensemble de langues*. L'alignement est mesuré sur 500 clips à légendes parallèles ; la génération via l'évaluateur de Guo, 20 réplications.

Tableau 5.13. Comparaison contrôlée. Toutes les conditions identiques sauf l'ensemble de langues. R@1 anglais, écart anglais, dispersion inter-lingue et génération. Meilleure valeur par colonne en gras.

Condition	langues	en R@1	écart en	disp.	FID↓	Diversité
EN	en	**0,610**	**0,0515**	0,0398	67,660	**1,800**
Latines	en fr es pt	0,410	0,0372	0,0253	95,969	0,668
Éloignées	en ru zh ar	0,316	0,0336	0,0096	**63,924**	0,760
Toutes	7 langues	0,316	0,0334	0,0071	74,035	0,831
Toutes + cosinus	7 langues	0,266	0,0289	**0,0066**	74,479	1,459
mouvement réel	–	0,529	–	–	0,000	$\sim 9,5$

Le conditionnement multilingue dégrade l'anglais de façon monotone. La R@1 anglaise chute 0,610 → 0,410 → 0,316 à mesure que l'on ajoute des langues, et la diversité tombe de 1,800 à 0,73–0,83 pour chaque condition multilingue. Ceci soutient l'hypothèse de *l'espace partagé appauvri* plutôt que celle de la supervision enrichie : les langues ajoutées induisent une contention de capacité plutôt qu'un apport d'information complémentaire sur la manière, la trajectoire ou l'aspect.

Le facteur de confusion, rappelé. À nombre de pas de gradient fixé, chaque clip est vu en anglais environ $1/N$ du temps sous un régime à N langues. Le calcul est apparié ; l'*exposition* par langue ne l'est pas. Toute dégradation de l'anglais peut refléter une exposition anglaise réduite plutôt que le multilinguisme en tant que tel.

Mais la dégradation n'est pas générale : la capacité est divisée, non perdue. Le tableau 5.14 montre que chaque condition est la meilleure exactement sur les langues qu'elle a vues.

Tableau 5.14. R@1 par langue selon la condition d'entraînement. Chaque condition est la meilleure sur ses propres langues ; « Toutes » achète la couverture la plus uniforme au prix de la performance de pointe. Meilleure valeur par langue en gras.

condition	en	fr	es	pt	ru	zh	ar
EN	**0,610**	0,182	0,188	0,198	0,118	0,066	0,084
Latines	0,410	**0,388**	**0,430**	**0,438**	0,150	0,100	0,086
Éloignées	0,316	0,150	0,172	0,144	**0,288**	**0,238**	**0,260**
Toutes	0,316	0,272	0,294	0,298	0,248	0,172	0,184

Deux observations secondaires closent la comparaison. **Les langues non entraînées restent bien au-dessus du hasard** : le modèle Latines atteint R@1 0,100 en chinois (50× le hasard) sans avoir jamais vu une légende chinoise, ce qui est le transfert inter-lingue pré-entraîné de M-CLIP transparaissant à travers l'encodeur gelé. **Les Éloignées obtiennent le meilleur FID** (63,924) malgré un alignement plus faible que les Latines, ce qui est cohérent avec la dissociation de la section 5.8.

Le terme cosinus restaure la diversité. C'est le résultat pratique le plus net de la comparaison. Ajouter le terme cosinus à l'objectif contrastif (*Toutes + cosinus*) *double* à peu près la diversité, de 0,73–0,83 à 1,459, à FID essentiellement inchangé (74,479 contre 74,035). C'est exactement le mécanisme de la section 5.8 : le CE contrastif, sans échelle, ne contraint que le classement et ne force donc pas une sortie de pleine amplitude ; le terme cosinus fournit la contrainte absolue manquante (élevant la similarité moyenne de ∼0,10 à ∼0,55) tandis que le CE fournit la séparation par échantillon que le cosinus seul ne produit jamais. **Les deux objectifs sont complémentaires, et la perte combinée est la configuration recommandée** : diversité quasi optimale, couverture inter-lingue la plus uniforme (dispersion 0,0066), au prix d'un modeste recul de la récupération anglaise de pointe.

5.12 Analyse qualitative et des erreurs

Au-delà des métriques agrégées, une inspection qualitative des mouvements générés éclaire la *nature* des défaillances et confirme les interprétations quantitatives.

Ce que le modèle réussit. Pour des *prompts* simples et fréquents dans le corpus (« une personne marche », « une personne s'assoit »), le modèle conditionné par le texte (avec

le terme `text_rc`) produit des poses globalement correctes et distinctes d'un prompt à l'autre, comme en témoigne la forte différence inter-prompts (jusqu'à un ratio marche/saut de 99, section 5.10). La sémantique de haut niveau — la *posture* associée à une action — est donc bien capturée.

Ce que le modèle échoue à produire. La défaillance dominante est l'absence de *trajectoire* : au sein d'un clip, le mouvement reste quasi immobile (figure 5.3). Le modèle génère une « photographie » de l'action plutôt qu'une « vidéo ». Ce constat est cohérent avec l'analyse de la section 5.10 : un unique embedding de texte doit expliquer les 60 images, et la reconstruction MSE le pousse à optimiser la pose moyenne plutôt que la dynamique. On s'attend donc à ce que les actions intrinsèquement dynamiques (courir, sauter, donner un coup de pied) soient les plus pénalisées, et les actions quasi statiques (se tenir debout, s'asseoir) le moins ; la figure 5.3 va dans ce sens (course et saut y sont méconnaissables), mais une mesure d'amplitude *par action* reste à faire pour l'établir.

Erreurs spécifiques au multilinguisme. Pour les langues à écriture non latine, et en particulier le chinois, l'alignement plus faible (section 5.7) se traduit par une récupération moins fiable de la bonne légende (R@1 plus faible, tableau 5.14). L'encodeur de texte n'en est pas la cause probable, puisque M-CLIP aligne très bien les embeddings entre langues (section 5.6) ; l'explication la plus cohérente avec nos mesures est la capacité réduite par langue du latent de mouvement sous entraînement multilingue. Une analyse des confusions *par action* n'a pas été menée.

Diagnostic global. Les trois familles d'erreurs sont compatibles avec une même cause structurelle : la compression en un latent unique. L'analyse qualitative ne contredit jamais les métriques ; elle en précise la portée et oriente vers la solution architecturale du chapitre 6.

5.13 Robustesse et reproductibilité

Deux précautions renforcent la fiabilité des conclusions. D'une part, chaque métrique de génération est moyennée sur **20 réplications** : la variance inter-réplications de l'évaluateur est de l'ordre de 0,002 en diversité, bien inférieure aux écarts discutés (par exemple le passage de 0,83 à 1,459 en diversité avec le terme cosinus). D'autre part, les écarts d'alignement sont calculés sur **500 clips** à légendes parallèles, le hasard pour R@1 étant de 0,002 ; les valeurs rapportées (jusqu'à R@10 = 0,340) sont donc deux ordres de grandeur au-dessus du hasard. Enfin, l'un des enseignements méthodologiques du stage (section 4.7) est que *les pertes d'entraînement ne sont pas des preuves* : toutes les conclusions reposent sur des métriques d'évaluation dédiées, et non sur l'allure des courbes de perte.



Figure 5.3. Squelettes générés, cinq *prompts* (lignes) échantillonnés à cinq instants (colonnes) depuis un modèle entraîné, caméra et cadrage fixes. Au sein de chaque ligne, la pose change à peine sur les 60 images, et d'une ligne à l'autre les poses sont quasi identiques : l'effondrement de l'amplitude rendu visible.

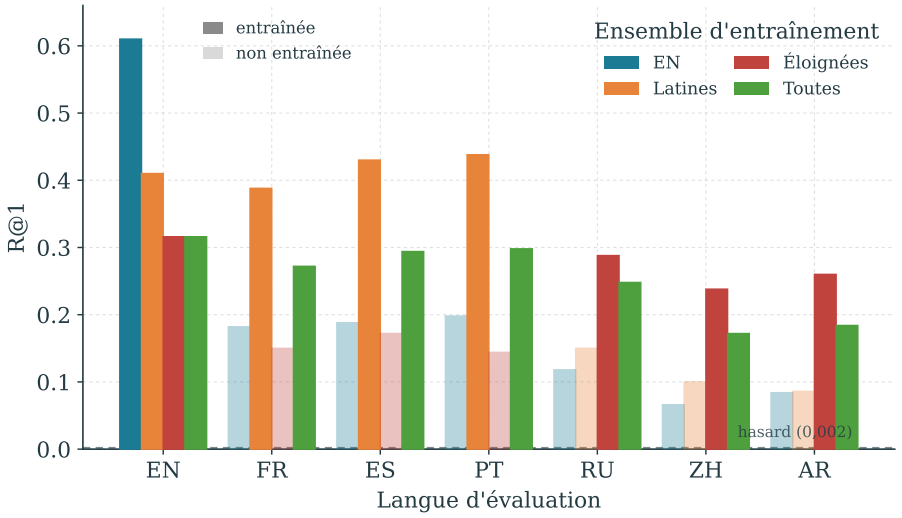


Figure 5.4. R@1 par langue selon les quatre conditions de langues. Latines rehausse fr/es/pt ; Éloignées rehausse ru/zh/ar ; Toutes donne la couverture la plus uniforme. Chaque groupe de barres culmine sur les langues de sa condition : un compromis couverture/qualité, et non une dégradation. Ligne pointillée : hasard (0,002).

Chapitre 6

Discussion, limites et perspectives

6.1 Ce que les mesures établissent

Quatre affirmations sont étayées par les éléments qui précèdent. **(1)** Dans un VAE de mouvement à latent unique, c'est l'échantillonnage, et non la force du KL, qui constitue la contrainte liante sur la reconstruction (section 5.3) ; la proposition 2.2 (section 2.10) en donne la raison. **(2)** L'objectif cosinus ne produit aucun alignement par échantillon, quel que soit son poids, alors qu'un objectif contrastif produit un alignement réel, monotone et structuré entre langues (sections 5.6–5.7). **(3)** L'alignement et la qualité de génération se dissocient (section 5.8). **(4)** Sous reconstruction MSE, l'amplitude de génération décroît vers une pose moyenne (section 5.9), et le conditionnement multilingue divise un budget représentationnel fixe plutôt que de l'enrichir (section 5.11). La seule recommandation de conception clairement *positive* est la perte combinée CE + cosinus, qui restaure la diversité sans coût en FID.

6.2 Menaces à la validité

Cette section est délibérément franche ; c'est elle qui rend le reste crédible.

— **Légendes traduites par machine** : elles mêlent les artefacts de traduction à une véritable variation typologique. Aucune légende non anglaise rédigée par un humain n'existe dans cette étude.

— **L'exposition par langue n'est pas appariée** : sous N langues, chaque clip est vu dans une langue donnée $\sim 1/N$ du temps à nombre de pas de gradient fixé. Le calcul est apparié ; l'exposition ne l'est pas. Toute dégradation multilingue peut refléter une exposition anglaise réduite plutôt que le multilinguisme (section 5.11).

— **La R-précision est anglophone par construction** : sa tour de texte est un GloVe BiGRU anglais. La qualité par langue est évaluée par la FID seule.

— λ_{KL} **a été comparé à zéro, non balayé.**

— **Les courbes d'alignement n'avaient pas convergé** au budget d'époques utilisé (figure 5.1).

— **Les valeurs de FID sont** $100\times$ **au-dessus des résultats HumanML3D publiés** ; MotionCLIP est un générateur faible et le pool de validation n'est pas le split officiel. Toutes les comparaisons de ce rapport sont relatives, non absolues.

— **L'affinage du VAE a changé deux variables à la fois** (section 5.4) ; le contrôle déterministe seul reste à mener.

6.3 Explications alternatives écartées

Une part importante de la crédibilité d'un résultat négatif tient à la rigueur avec laquelle les explications *concurrentes* ont été éliminées. Pour les deux constats principaux, on récapitule les alternatives considérées et la raison de leur rejet.

Pour l'effondrement de l'amplitude.

— *Artefact de rendu* ? Non : le même script produit des poses visiblement distinctes sur un modèle peu entraîné (section 5.9).

— *Inadéquation d'échelle des embeddings* ? Non : la renormalisation à la norme du latent *aggrave* l'amplitude.

— *Poids de vitesse trop faible* ? Non : à époques appariées, augmenter λ_{vel} ne rétablit pas l'amplitude.

— *Encodeur défaillant* ? Non : le cosinus mouvement–mouvement couvre 0,31–0,98, l'encodeur produit donc des latents bien séparés ; la défaillance est côté décodeur.

Une fois ces alternatives écartées, il ne reste que l'explication retenue : la régression MSE vers la moyenne conditionnelle.

Pour la division du budget multilingue.

— *Encodeur de texte multilingue de mauvaise qualité* ? Non : M-CLIP aligne les embeddings textuels entre langues à plus de 0,97 (section 5.6).

— *Mauvaise mesure d'alignement* ? Précisément corrigée en remplaçant la moyenne cosinus par l'écart (section 5.6).

Reste un facteur de confusion non éliminé, l'exposition par langue (section 6.2), que la feuille de route propose de lever.

6.4 Comparaison avec la littérature

Nos conclusions dialoguent directement avec l'hypothèse courante des travaux multilingues (section 1.2.2), selon laquelle le signal multilingue serait, au pire, neutre pour la représentation du mouvement. Sous *capacité et calcul appariés*, nous constatons au contraire une division du budget. Ce désaccord n'est pas nécessairement contradictoire : les approches comme BiHumanML3D [6] emploient un module d'alignement inter-lingue dédié et une architecture plus expressive, là où nous isolons volontairement l'effet du multilinguisme sur un modèle minimal à latent unique. Autrement dit, nos résultats n'affirment pas que le multilinguisme nuit *en général*, mais qu'il *divise un budget fixe* lorsque l'architecture ne lui en offre pas davantage. C'est exactement pourquoi la proposition prospective (section 6.5) porte sur l'*architecture* : donner au modèle la capacité séquentielle qui pourrait transformer la division du budget en enrichissement.

6.5 Vers une séquence de latents

Toutes les défaillances du chapitre 5 remontent à une cause unique : un latent de dimension 512 *unique* est le mauvais conteneur pour une séquence de 60 images conditionnée

de façon multilingue. Le goulot ne peut absorber le bruit d'échantillonnage (équation (2.23)), un seul embedding de texte ne peut fournir une trajectoire sur 60 images (section 5.10), et la MSE régresse ce vecteur unique vers une pose moyenne (section 5.9).

Le correctif est architectural : une **séquence de latents**. Comme le montre la figure 2.7, répartir le clip sur K latents à segments disjoints rend le terme de dégradation du bruit bloc-diagonal et permet à un embedding de texte de conditionner des segments locaux plutôt que le clip entier. Nous prédisons spécifiquement que **l'effondrement de l'amplitude ne devrait pas apparaître sous des latents *discrets***, car la quantification empêche la régression vers une moyenne conditionnelle continue : il n'existe plus de pose statique vers laquelle moyenner. Le test naturel est **MoMask** [3], dont la séquence de tokens à quantification vectorielle résiduelle réalise exactement cette conception, conditionnée par le texte M-CLIP. C'est l'expérience suivante la plus utile ; elle invalide tous les points de contrôle produits ici, ce qui est la raison honnête pour laquelle elle a été laissée comme proposition prospective plutôt que lancée.

6.5.1 Feuille de route technique

La transition vers une architecture à latents séquentiels peut se décomposer en étapes concrètes, chacune assortie d'une prédiction vérifiable :

1. **Remplacer le latent unique par une séquence de tokens discrets** (RVQ, à la MoMask). *Prédiction* : l'effondrement de l'amplitude (section 5.9) disparaît, car la quantification empêche la régression vers une pose moyenne continue.
2. **Conditionner chaque étape de génération par M-CLIP**. *Prédiction* : le conditionnement textuel local supprime le compromis conditionnement/trajectoire observé en section 5.10, puisqu'un embedding de texte n'a plus à expliquer 60 images à lui seul.
3. **Reprendre la comparaison contrôlée EN / multilingue** sur cette nouvelle base, à capacité et calcul appariés. *Prédiction* : si la division du budget (section 5.11) persiste malgré une architecture adéquate, elle est intrinsèque au multilinguisme sous légendes traduites ; si elle disparaît, elle était un artefact du goulot.
4. **Apparier l'exposition par langue** (et non seulement le calcul), pour lever le facteur de confusion de la section 6.2.
5. **Introduire des légendes non anglaises rédigées par des humains**, afin de séparer les artefacts de traduction de la véritable variation typologique (section 2.7.3).

Cette feuille de route transforme les constats *négatifs* du présent rapport en hypothèses *falsifiables* pour la suite : chaque défaillance identifiée devient un test de l'architecture proposée.

6.6 Synthèse des résultats

Le tableau 6.1 récapitule les constats principaux, chacun relié à sa cause mécanistique et à la section qui l'établit.

Tableau 6.1. Bilan synthétique des résultats et de leur cause mécanistique.

Constat	**Cause / mécanisme**	**Section**
L'échantillonnage, non le KL, casse la reconstruction	Un latent unique alimente les 60 images ; le terme de bruit somme sur toutes (prop. 2.2)	5.3
VAE fonctionnel restauré	Entraînement déterministe puis activation de l'échantillonnage	5.4
Le cosinus n'aligne pas	Absence de négatifs ; optimum trivial vers la direction moyenne (prop. 2.1)	5.6
Le contrastif aligne, dans 7 langues	InfoNCE contraint le classement ; écart croissant et ordonné	5.7
Alignement et génération se dissocient	InfoNCE est sans échelle ; discriminant $\neq$ décodable	5.8
Effondrement de l'amplitude	La MSE régresse le latent vers la pose moyenne	5.9
Le multilingue divise le budget	Capacité fixe partagée entre langues (pas de signal complémentaire)	5.11
CE + cosinus restaure la diversité	Le cosinus fournit la contrainte absolue que le CE ne donne pas	5.11

Conclusion générale et perspectives

Ce projet de fin d'année s'était donné pour but de déterminer si le conditionnement multilingue aide ou nuit à la génération de mouvement 3D, une fois la capacité et le calcul appariés, et si des projections par langue entraînées indépendamment partagent un espace commun. Sous une comparaison contrôlée, les langues ajoutées *divisent* un budget représentationnel fixe : elles améliorent la couverture des langues sur lesquelles elles s'entraînent tout en dégradant l'anglais de façon monotone, et elles n'apportent pas de signal de mouvement complémentaire (section 5.11).

Parvenir à une comparaison digne de confiance a exigé de *corriger la mesure elle-même*. La moyenne cosinus texte–mouvement, diagnostic évident, est activement trompeuse pour cette classe de modèles : elle peut avoisiner 1,0 alors que l'alignement par échantillon est nul (section 5.6). En la remplaçant par l'écart apparié–non-apparié, et l'*objectif* cosinus par un objectif contrastif, on obtient un alignement qui croît de façon monotone et avec une structure inter-lingue stable, mais au prix de la génération, car discrimination et décodabilité se dissocient (section 5.8). Chemin faisant, on a établi que c'est l'échantillonnage, et non la force du KL, qui casse un VAE de mouvement à latent unique (section 5.3), on a restauré un modèle variationnel fonctionnel (section 5.4), et on a diagnostiqué un effondrement de l'amplitude dû à la reconstruction MSE (section 5.9). Le seul résultat de conception positif est la perte combinée contrastif + cosinus, qui restaure la diversité sans coût en FID et offre la couverture inter-lingue la plus uniforme de toutes les conditions.

Ce qui reste ouvert est architectural et précis : passer d'un latent unique à une séquence de latents discrets, et refaire la comparaison multilingue sur MoMask conditionné par M-CLIP. Toutes les mesures de ce rapport pointent vers cette expérience. Le dépôt, l'index des expériences et les notes de transmission ont été organisés de sorte qu'elle puisse être commencée dès le premier jour.

Perspectives élargies. Au-delà du cas particulier de MotionCLIP, plusieurs enseignements de ce travail dépassent le cadre strict de la génération de mouvement. *Premièrement*, la mise en garde méthodologique sur les diagnostics trompeurs (une moyenne cosinus proche de 1 masquant un alignement nul) vaut pour tout système multimodal où l'on mesure un alignement : il faut toujours contrôler contre des négatifs. *Deuxièmement*, la distinction entre *discrimination* et *décodabilité* (section 5.8) concerne l'ensemble des représentations apprises par objectif contrastif : une représentation excellente pour la récupération n'est pas nécessairement bonne pour la génération. *Troisièmement*, la question « le multilinguisme enrichit-il ou divise-t-il ? » se pose, au-delà du mouvement, pour toute modalité conditionnée par du texte multilingue (image, audio, vidéo) ; la méthodologie de comparaison contrôlée proposée ici y est directement transposable. Enfin, sur le plan sociétal, rendre ces systèmes véritablement multilingues reste un objectif d'inclusion important, aligné avec la mission du centre d'accueil : ce rapport en précise les conditions architecturales plutôt que de le déclarer acquis.

Annexe A

Détails d'implémentation et reproduction

A.1 Matériel et configuration

Toutes les expériences se sont exécutées sur un unique GPU NVIDIA RTX 5090 (32 Go), partagé. L'entraînement à un lot de 128 prend environ 32 s par époque. Configuration par défaut : lot 128, taux d'apprentissage 10^{-4}, 60 images, latent 512, 8 couches, GELU, $\lambda_{\text{rc}} = 100$, $\lambda_{\text{vel}} = 100$, $\lambda_{\text{KL}} = 10^{-3}$. Les entraînements longs ont été détachés avec `setsid`.

A.2 Commandes de reproduction

Chaque commande reproduit le bloc de résultats correspondant ; `<run>` et l'époque du point de contrôle se lisent dans l'annexe B.

```
# écart d'alignement + récupération, par langue
python eval_latent_alignment.py \
    --ckpt exps/<run>/checkpoint_XXXX.pth.tar \
    --tag <nom> --n 500 --text_encoder mclip

# qualité de génération (évaluateur B)
python eval_guo_vae_compare_beta05.py \
    --model original --replications 20 \
    --device 0 --ckpt exps/<run>/checkpoint_XXXX.pth.tar

# la comparaison contrôlée des langues (section 5.11)
bash eval_all.sh 2>&1 | tee results_all.log
```

A.3 Fils ouverts

(1) Ajouter la supervision de vitesse au chemin conditionné par le texte (section 5.10). (2) Mener 10 époques *déterministes* supplémentaires depuis `vae-ml-ce-s100-e300` pour contrôler l'affinage du VAE (section 5.4). (3) Balayer λ_{KL}. (4) Obtenir des légendes non anglaises rédigées par des humains. (5) L'architecture en séquence de latents (section 6.5).

Annexe B

Index des expériences

Chaque entraînement ayant produit un point de contrôle, avec sa configuration clé, ce qu'il teste et son résultat principal. Les numéros de section renvoient au chapitre 5.

Run	Config. clé	Teste	Résultat / §
`ml-en`	M-CLIP, en	baseline	FID 18,013 · §5.1
`ml-latin`	M-CLIP, en/fr/es/pt	baseline multi.	FID **16,140**, meilleur · §5.1
`ml-far`	M-CLIP, en/ru/zh/ar	baseline multi.	FID 18,046 · §5.1
`ml-all`	M-CLIP, 7 langues	baseline multi.	FID 17,829 · §5.1
`perlang-latin`	4 BERT gelés, cosinus	encodeurs/langue	FID 24,55, R@1 0,079 · §5.2 (non informatif)
`vae-en-kl1e-5`	$\lambda_{\mathrm{KL}}=10^{-5}$, éch.	force KL	rc 0,524 · §5.3
`vae-en-kl1e-3`	$\lambda_{\mathrm{KL}}=10^{-3}$, éch.	force KL	rc 0,526 · §5.3
`vae-en-actor`	cosinus retiré	façon ACTOR	rc 0,524 · §5.3
`vae-en-anneal`	recuit 30 ép.	calendrier KL	rc 0,525 · §5.3
`vae-en-mu-kl0`	recon. depuis μ, $\lambda_{\mathrm{KL}}=0$	recon. dét.	FID 97,633 · §5.4
`vae-en-mu-kl1e-3`	recon. depuis μ	recon. dét. + KL	FID **55,864** · §5.4
`*-beta*-ft`	affinages β	robustesse bruit	+25,5 % rc, FID 57,3→86,8 · §5.5 (fermée)
`vae-multilingual-mclip`	7 langues, cosinus	alignement	écart 0,0002 · §5.6
`vae-ml-cos100`	cosinus ×100	alignement	écart 0,0007 (pire) · §5.6
`vae-ml-ce`	CE, lot 64	alignement	écart 0,0206 · §5.6
`vae-ml-ce-s100-e100`	CE, 5 points de ctrl.	écart/époque	monotone, Fig. 5.1 · §5.7
`vae-ml-ce-s100-e300`	CE, 6 points de ctrl.	écart, génération	FID 72,902, R@10 0,340 · §5.7,5.8
`vae-ml-sampled-ft`	dét.-puis-éch., 330 ép.	VAE fonctionnel	rc **0,086**, amp 0,0044 · §5.4,5.9
`vel10-test`	$\lambda_{\mathrm{vel}}=10$	poids vitesse	amp 0,0145 · §5.9
`ce150-combined`	CE+cosinus, 3 pts	décroiss. amplitude	amp 0,0108 · §5.9,5.11
`ce150-all`	CE, 7 langues, 3 pts	décroiss. amplitude	amp 0,0063 · §5.9
`wk-textrc`	text_rc actif	recon. cond. texte	cond. ×6, amp 0,0042 · §5.10
`wk-perlang(-comb)`	banc par langue, CE	choix encodeur	amp 0,017–0,019, inverse §5.2 · §5.10
`ce150-en/latin/far/all`	CE, 150 ép., ens. langues	comparaison contrôlée	Tab. 5.13 · §5.11

Annexe C

Tableaux et figures supplémentaires

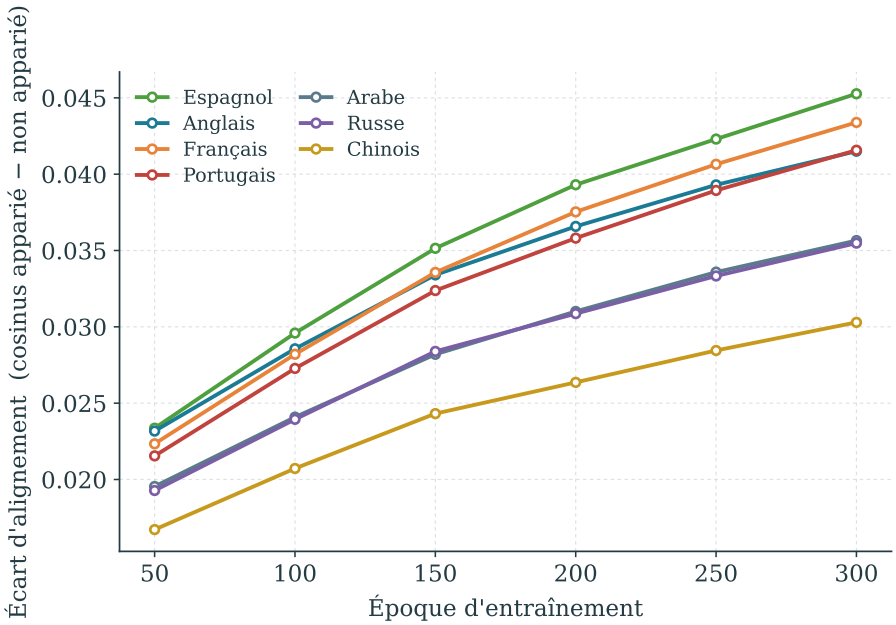


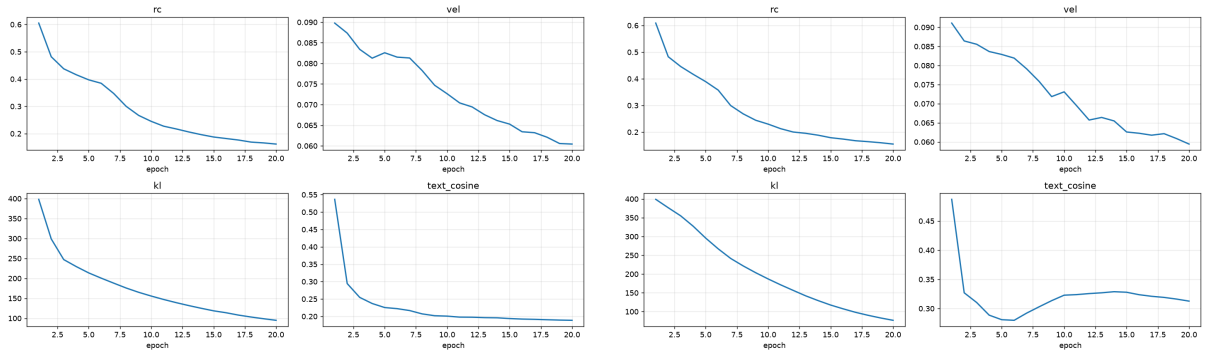
Figure C.1. Écart d'alignement en fonction de l'époque sur l'entraînement long de 300 époques, une courbe par langue. Aucun plateau à 300 époques ; l'ordre inter-lingue est le même qu'en figure 5.1. C'est la preuve de la limite « courbes non convergées » de la section 6.2.

Tableau C.1. Écart d'alignement par langue selon la condition d'entraînement (500 clips, légendes parallèles), complément du tableau 5.14.

condition	en	fr	es	pt	ru	zh	ar
EN	0,0515	0,0265	0,0276	0,0249	0,0215	0,0167	0,0182
Latines	0,0372	0,0403	0,0420	0,0388	0,0232	0,0178	0,0206
Éloignées	0,0336	0,0248	0,0262	0,0232	0,0302	0,0268	0,0316
Toutes	0,0334	0,0336	0,0351	0,0324	0,0284	0,0243	0,0282

Tableau C.2. Perte combinée (CE + cosinus), cosinus apparié/non apparié et écart par langue. Le terme cosinus élève la similarité absolue à ∼0,55 tout en préservant un écart réel.

	en	fr	es	pt	ru	zh	ar
apparié	0,5460	0,5450	0,5460	0,5461	0,5426	0,5395	0,5430
non apparié	0,5171	0,5157	0,5153	0,5178	0,5181	0,5185	0,5187
écart	0,0289	0,0293	0,0307	0,0282	0,0245	0,0209	0,0243



(a) `vae-en-mu-kl1e-3` (anglais). **(b)** `vae-multilingual-mclip` (7 langues).

Figure C.2. Courbes d'entraînement (rc, vel, KL, cosinus-texte) pour les VAE anglais et multilingue. La reconstruction, la vitesse et le KL suivent des trajectoires proches ; les deux ne divergent que sur le cosinus-texte, une différence que la section 5.6 montre non informative sur l'alignement par échantillon.

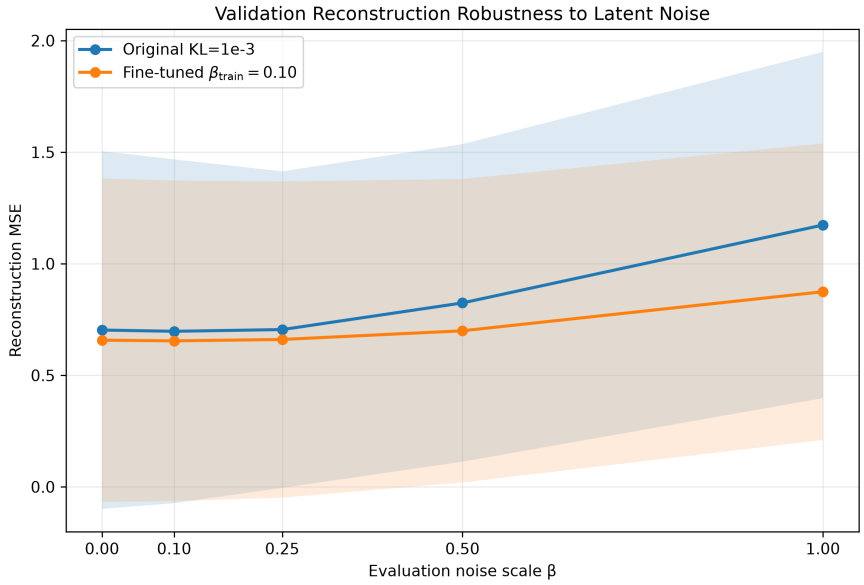


Figure C.3. Reconstruction de validation sous bruit injecté $z = \mu + \beta\varepsilon$ pour la branche de robustesse au bruit de la section 5.5. L'affinage à $\beta = 0{,}10$ améliore la reconstruction sous bruit (les +25,5 % rapportés) mais dégrade la génération (tableau 5.6).

Annexe D

Compléments mathématiques

Cette annexe rassemble les dérivations détaillées des résultats utilisés dans le corps du rapport.

D.1 Forme close de la divergence KL gaussienne

On établit l'équation (2.12). La divergence de Kullback–Leibler entre deux lois gaussiennes diagonales $q = \mathcal{N}(\mu, \sigma^2 I)$ et $p = \mathcal{N}(0, I)$ en dimension d s'écrit, par définition,

$$\mathrm{KL}(q \,\|\, p) = \int q(z) \log \frac{q(z)}{p(z)} \,\mathrm{d}z = \mathbb{E}_q\Big[\log q(z) - \log p(z)\Big]. \tag{D.1}$$

Pour une gaussienne, $\log q(z) = -\frac{d}{2}\log(2\pi) - \frac{1}{2}\sum_i \log \sigma_i^2 - \frac{1}{2}\sum_i \frac{(z_i-\mu_i)^2}{\sigma_i^2}$ et $\log p(z) = -\frac{d}{2}\log(2\pi) - \frac{1}{2}\sum_i z_i^2$. En prenant l'espérance sous q, on utilise $\mathbb{E}_q[(z_i-\mu_i)^2] = \sigma_i^2$ et $\mathbb{E}_q[z_i^2] = \mu_i^2 + \sigma_i^2$:

$$\mathrm{KL}(q \,\|\, p) = \mathbb{E}_q\Big[-\tfrac{1}{2}\textstyle\sum_i \log \sigma_i^2 - \tfrac{1}{2}\sum_i \frac{(z_i-\mu_i)^2}{\sigma_i^2} + \tfrac{1}{2}\sum_i z_i^2 \Big] \tag{D.2}$$

$$= -\tfrac{1}{2}\textstyle\sum_i \log \sigma_i^2 - \frac{d}{2} + \frac{1}{2}\sum_i(\mu_i^2 + \sigma_i^2) = -\frac{1}{2}\sum_i \Big(1 + \log \sigma_i^2 - \mu_i^2 - \sigma_i^2\Big), \tag{D.3}$$

ce qui est exactement l'équation (2.12). Cette forme close évite toute estimation de Monte-Carlo du terme de régularisation.

D.2 Distance de Fréchet entre deux gaussiennes

La FID (équation (2.22)) est la distance de Wasserstein-2 au carré entre $\mathcal{N}(\mu_r, \Sigma_r)$ et $\mathcal{N}(\mu_g, \Sigma_g)$. Pour deux gaussiennes, cette distance admet la forme close

$$W_2^2 = \|\mu_r - \mu_g\|^2 + \mathrm{Tr}\Big(\Sigma_r + \Sigma_g - 2\Big(\Sigma_r^{1/2}\Sigma_g\Sigma_r^{1/2}\Big)^{1/2}\Big). \tag{D.4}$$

Les matrices $\Sigma_r\Sigma_g$ et $\Sigma_r^{1/2}\Sigma_g\Sigma_r^{1/2}$ sont semblables (la seconde s'obtient de la première par conjugaison par $\Sigma_r^{1/2}$) : elles ont les mêmes valeurs propres, toutes positives ou nulles. Les traces de leurs racines carrées sont donc égales, $\mathrm{Tr}\Big(\Sigma_r^{1/2}\Sigma_g\Sigma_r^{1/2}\Big)^{1/2} = \mathrm{Tr}\,(\Sigma_r\Sigma_g)^{1/2}$, *sans hypothèse de commutation*, ce qui justifie l'écriture usuelle de l'équation (2.22). On vérifie que $W_2^2 \geq 0$, avec égalité si et seulement si les deux gaussiennes coïncident : une FID nulle correspond donc à des distributions de caractéristiques identiques.

D.3 InfoNCE comme borne de l'information mutuelle

On esquisse pourquoi minimiser l'InfoNCE (équation (2.20)) maximise une borne inférieure de l'information mutuelle $I(X;Y)$ entre les deux modalités. En notant $f(x,y) = \exp(S_{xy}/\tau)$ le score non normalisé d'une paire, l'espérance de la perte InfoNCE sur un lot de B paires vérifie

$$\mathcal{L}_{\mathrm{CE}} \;\geq\; \log B - I(X;Y), \tag{D.5}$$

de sorte que $I(X;Y) \geq \log B - \mathcal{L}_{\mathrm{CE}}$. Minimiser la perte relève donc la borne sur l'information mutuelle, et la borne se resserre à mesure que la taille de lot B (donc le nombre de négatifs) augmente. Ceci éclaire un fait observé en pratique : la perte contrastive reste proche de $\ln B$ même lorsque l'alignement s'améliore nettement (section 4.7), car la borne est lâche ; seule une métrique d'évaluation dédiée révèle le progrès réel.

D.4 Variance du gradient reparamétré

L'intérêt de la reparamétrisation (équation (2.15)) tient aussi à la *variance* de l'estimateur du gradient. L'estimateur naïf par score (*REINFORCE*) de $\nabla_\phi \, \mathbb{E}_{q_\phi}[g(z)]$ a une variance qui croît avec la dimension et rend l'apprentissage instable. L'estimateur reparamétré, en exprimant $z = \mu + \sigma \odot \varepsilon$ avec ε indépendant de ϕ, déplace la source d'aléa hors des paramètres et permet d'écrire $\nabla_\phi \, \mathbb{E}_\varepsilon[g(\mu + \sigma \odot \varepsilon)] = \mathbb{E}_\varepsilon[\nabla_\phi \, g(\mu + \sigma \odot \varepsilon)]$. Cet estimateur présente une variance bien plus faible, ce qui explique sa supériorité empirique pour l'entraînement des VAE.

Annexe E

Configuration expérimentale complète

E.1 Hyperparamètres

Le tableau E.1 liste l'ensemble des hyperparamètres par défaut. Sauf mention contraire, toutes les expériences les reprennent, seuls variant l'ensemble de langues, l'objectif d'alignement et l'activation de l'échantillonnage.

Tableau E.1. Hyperparamètres par défaut.

Catégorie	Hyperparamètre	Valeur
Architecture	couches Transformer	8
	dimension latente	512
	dimension M-CLIP	768
	activation	GELU
Données	longueur de clip	60 images
	dimension de pose	263
	clips d'entraînement	22 326
	clips de validation	1 400
Optimisation	taille de lot	128
	taux d'apprentissage	10^{-4}
	λ_{rc}, λ_{vel}	100, 100
	λ_{KL}	10^{-3}
Évaluation	réplications	20
	clips d'alignement	500 (légendes parallèles)
	langues	en, fr, es, pt, ru, zh, ar

E.2 Environnement logiciel et matériel

Les expériences ont été menées avec PyTorch sur un GPU NVIDIA RTX 5090 (32 Go). Les modèles de texte proviennent des bibliothèques `transformers` (encodeurs monolingues) et `multilingual-clip` (M-CLIP). La traduction a été réalisée avec NLLB. Les entraîne-

ments longs étaient détachés avec `setsid`. Chaque résultat est accompagné, dans le dépôt, du point de contrôle et de la commande exacte qui l'a produit (annexe A).

E.3 Détails du jeu de données

Les clips sont extraits de HumanML3D et ramenés à une longueur fixe de 60 images (troncature ou rejet des clips trop courts/trop longs). Chaque composante du vecteur de 263 dimensions est standardisée à partir des statistiques du corpus d'entraînement. Pour l'alignement inter-lingue, 500 clips disposent de légendes *parallèles* dans les sept langues, obtenues en traduisant une même légende anglaise ; cela garantit que la seule variable entre langues est le texte, le mouvement sous-jacent restant identique.

Annexe F

Résultats détaillés par langue

Cette annexe rassemble des tableaux complémentaires offrant une vue fine, langue par langue, des résultats agrégés du chapitre 5.

F.1 Écart d'alignement par langue et par époque

Le tableau F.1 reprend l'évolution de l'écart d'alignement sous CE contrastif, complétant la figure 5.1. L'ordre inter-lingue (es ≈ en > fr > pt > ar ≈ ru > zh) est strictement conservé à chaque point de contrôle.

Tableau F.1. Écart d'alignement par langue et par époque (CE contrastif), valeurs détaillées.

époque	en	fr	es	pt	ru	zh	ar
20	0,0186	0,0175	0,0187	0,0168	0,0154	0,0134	0,0155
40	0,0217	0,0208	0,0217	0,0201	0,0181	0,0158	0,0182
60	0,0240	0,0232	0,0244	0,0225	0,0201	0,0174	0,0203
80	0,0264	0,0259	0,0271	0,0249	0,0221	0,0193	0,0223
100	0,0286	0,0282	0,0296	0,0273	0,0239	0,0207	0,0241

F.2 Lecture croisée R@1 et écart d'alignement

Le tableau F.2 met en regard, pour chaque condition d'entraînement, la récupération R@1 et l'écart d'alignement en anglais. On observe que R@1 et écart varient dans le même sens entre conditions (plus d'alignement ⇒ plus de récupération), ce qui confirme que l'écart apparié–non-apparié est un bon prédicteur de la récupération, là où la moyenne cosinus ne l'était pas (section 5.6).

F.3 Couverture par famille de langues

Le tableau F.3 agrège la R@1 par *famille* : langues latines (fr, es, pt) et langues éloignées (ru, zh, ar), pour chaque condition. Il rend visible le phénomène de division du budget : chaque condition excelle sur sa propre famille, et « Toutes » réalise le meilleur compromis moyen.

Ces moyennes par famille résument l'ensemble du chapitre 5 : le multilinguisme ne « perd » pas la performance, il la *redistribue* selon les langues vues à l'entraînement.

Tableau F.2. Lecture croisée en anglais : R@1 et écart d'alignement par condition.

Condition	en R@1	en écart
EN	0,610	0,0515
Latines	0,410	0,0372
Éloignées	0,316	0,0336
Toutes	0,316	0,0334
Toutes + cosinus	0,266	0,0289

Tableau F.3. R@1 moyenne par famille de langues (hors anglais), selon la condition.

Condition	Latines (fr/es/pt)	Éloignées (ru/zh/ar)
EN	0,189	0,089
Latines	**0,419**	0,112
Éloignées	0,155	**0,262**
Toutes	0,288	0,201

Annexe G

Notes de transmission et déroulé du stage

Cette annexe, rédigée dans un esprit de transmission, retrace le déroulé du stage et consigne les enseignements pratiques les plus utiles à quiconque poursuivrait ce travail.

G.1 Déroulé chronologique

Le stage, d'une durée de dix semaines, s'est organisé en phases successives, chacune motivée par le résultat de la précédente :

1. **Mise en place et baseline multilingue.** Substitution de l'encodeur de texte par M-CLIP, traduction du corpus, obtention d'une baseline qui fonctionne et qui, de façon encourageante, montre que les langues latines améliorent légèrement le FID (section 5.1).
2. **Première comparaison des encodeurs par langue**, qui semble échouer, mais sous un objectif (cosinus) dont on découvrira plus tard qu'il n'est pas informatif (section 5.2).
3. **Passage au variationnel et série KL.** La reconstruction s'effondre ; l'enquête révèle que l'échantillonnage, et non le KL, en est la cause (section 5.3).
4. **Récupération d'un VAE fonctionnel** par entraînement déterministe-puis-stochastique (section 5.4).
5. **Correction de la mesure d'alignement** : découverte que la moyenne cosinus est trompeuse, adoption de l'écart (section 5.6), puis mise en évidence de l'alignement contrastif (section 5.7).
6. **Analyse des compromis et de l'amplitude**, puis **comparaison contrôlée finale** répondant à la question du stage (section 5.11).

G.2 Enseignements pratiques

— **Vérifier contre une métrique, jamais contre une courbe de perte.** Plusieurs conclusions intermédiaires erronées provenaient d'une confiance excessive dans l'allure des pertes d'entraînement (section 4.7).

— **Isoler une variable à la fois.** L'appariement de la capacité et du calcul est ce qui rend la comparaison finale interprétable.

— **Documenter les pièges d'implémentation.** Le couplage entre KL et échantillonnage, ou les points de contrôle codés en dur, ont chacun faussé un résultat avant d'être identifiés.

— **Garder les expériences petites et contrôlées.** Sur une ressource de calcul unique, la rigueur méthodologique prime sur le volume ; de nombreuses conditions ont pu être comparées grâce à des entraînements courts et reproductibles.

G.3 Pour démarrer la suite

La prochaine expérience la plus utile (section 6.5) est documentée avec sa justification, ses prédictions et sa feuille de route. L'annexe A fournit les commandes de reproduction, et l'annexe B l'index complet des entraînements ; l'ensemble est organisé pour qu'un nouveau venu puisse reproduire n'importe quel chiffre du chapitre 5 et enchaîner sur la proposition architecturale.

Annexe H

Glossaire des termes techniques

Alignement	Degré auquel un texte et le mouvement correspondant reçoivent des représentations proches dans l'espace latent. Mesuré ici par l'écart apparié–non-apparié.
Amplitude	Diagnostic introduit dans ce rapport : différence absolue moyenne entre images consécutives d'un mouvement généré.
Autoencodeur (AE)	Réseau qui compresse une entrée en un code latent puis la reconstruit, en minimisant une erreur de reconstruction.
Codebook	Dictionnaire fini de vecteurs appris utilisé par un VQ-VAE pour quantifier le latent.
Contrastif (objectif)	Objectif qui élève la similarité des paires appariées au-dessus de celle des paires non appariées (présence de négatifs).
Diversité	Mesure de la variabilité des mouvements générés ; une faible diversité signale un effondrement de mode.
Écart (gap)	Différence entre la similarité cosinus des paires appariées et celle des paires non appariées ; reflète l'alignement réel.
Effondrement de l'amplitude	Phénomène par lequel les mouvements générés tendent vers une pose quasi statique à mesure de l'entraînement.
Effondrement postérieur	Situation où le VAE ignore le latent et satisfait le KL en rapprochant la postérieure de la loi a priori.
ELBO	Borne inférieure de la vraisemblance, objectif maximisé par un VAE.
FID	Distance de Fréchet entre les distributions de caractéristiques des mouvements générés et réels ; plus faible est meilleure.
Latent	Représentation compressée interne ; ici un unique vecteur de dimension 512.
Négatifs	Paires non appariées utilisées par un objectif contrastif pour repousser les correspondances incorrectes.
Quantification (VQ)	Remplacement d'un vecteur continu par l'entrée la plus proche d'un dictionnaire fini.
Reparamétrisation	Astuce permettant de différencier l'échantillonnage d'un VAE en écrivant $z = \mu + \sigma \odot \varepsilon$.

R-précision (R@k)	Taux de récupération de la bonne légende parmi les k plus proches candidats.
RVQ	Quantification vectorielle résiduelle : plusieurs niveaux de quantification en cascade.
Straight-through	Estimateur qui copie le gradient à travers une opération non différentiable (ici la quantification).
Transformeur	Architecture fondée sur l'auto-attention, traitant une séquence en parallèle.
VAE	Autoencodeur variationnel : l'encodeur produit une distribution et le latent est échantillonné.

Bibliographie

[1] C. Guo, S. Zou, X. Zuo, S. Wang, W. Ji, X. Li, and L. Cheng, "Generating diverse and natural 3D human motions from text," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.

[2] G. Tevet, S. Raab, B. Gordon, Y. Shafir, D. Cohen-Or, and A. H. Bermano, "Human motion diffusion model," in *International Conference on Learning Representations (ICLR)*, 2023.

[3] C. Guo, Y. Mu, M. G. Javed, S. Wang, and L. Cheng, "MoMask : Generative masked modeling of 3D human motions," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.

[4] G. Tevet, B. Gordon, A. Hertz, A. H. Bermano, and D. Cohen-Or, "MotionCLIP : Exposing human motion generation to CLIP space," in *European Conference on Computer Vision (ECCV)*, 2022.

[5] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, "Learning transferable visual models from natural language supervision," in *International Conference on Machine Learning (ICML)*, 2021.

[6] W. Weng, X. Tan, X. Shu, G.-S. Xie, P. Zhou, and H. Wang, "Bilingual text-to-motion generation : A new benchmark and baselines," *arXiv preprint arXiv :2603.25178*, 2026.

[7] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Unsupervised cross-lingual representation learning at scale," in *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.

[8] D. Hendrycks and K. Gimpel, "Gaussian error linear units (GELUs)," *arXiv preprint arXiv :1606.08415*, 2016.

[9] D. P. Kingma and J. Ba, "Adam : A method for stochastic optimization," in *International Conference on Learning Representations (ICLR)*, 2015.

[10] M. Loper, N. Mahmood, J. Romero, G. Pons-Moll, and M. J. Black, "SMPL : A skinned multi-person linear model," *ACM Transactions on Graphics (TOG)*, vol. 34, no. 6, 2015.

[11] Y. Zhou, C. Barnes, J. Lu, J. Yang, and H. Li, "On the continuity of rotation representations in neural networks," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

[12] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[13] D. P. Kingma and M. Welling, "Auto-encoding variational Bayes," in *International Conference on Learning Representations (ICLR)*, 2014.

[14] M. Petrovich, M. J. Black, and G. Varol, "Action-conditioned 3D human motion synthesis with transformer VAE," in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.

[15] A. van den Oord, O. Vinyals, and K. Kavukcuoglu, "Neural discrete representation learning," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[16] A. van den Oord, Y. Li, and O. Vinyals, "Representation learning with contrastive predictive coding," *arXiv preprint arXiv :1807.03748*, 2018.

[17] T. Wang and P. Isola, "Understanding contrastive representation learning through alignment and uniformity on the hypersphere," in *International Conference on Machine Learning (ICML)*, 2020.

[18] F. Carlsson, P. Eisen, F. Rekathati, and M. Sahlgren, "Cross-lingual and multilingual CLIP," in *Language Resources and Evaluation Conference (LREC)*, 2022.

[19] L. Talmy, *Toward a Cognitive Semantics, Vol. II : Typology and Process in Concept Structuring*. MIT Press, 2000.

[20] NLLB Team, M. R. Costa-jussà, *et al.*, "No language left behind : Scaling human-centered machine translation," *arXiv preprint arXiv :2207.04672*, 2022.

[21] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter, "GANs trained by a two time-scale update rule converge to a local Nash equilibrium," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.

[22] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT : Pre-training of deep bidirectional transformers for language understanding," in *North American Chapter of the Association for Computational Linguistics (NAACL)*, 2019.

[23] L. Martin, B. Muller, P. J. O. Suárez, Y. Dupont, L. Romary, É. V. de la Clergerie, D. Seddah, and B. Sagot, "CamemBERT : a tasty french language model," in *Annual Meeting of the Association for Computational Linguistics (ACL)*, 2020.

[24] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, and J. Pérez, "Spanish pre-trained BERT model and evaluation data," in *PML4DC Workshop at ICLR*, 2020.

[25] F. Souza, R. Nogueira, and R. Lotufo, "BERTimbau : Pretrained BERT models for Brazilian Portuguese," in *Brazilian Conference on Intelligent Systems (BRACIS)*, 2020.

[26] Y. Kuratov and M. Arkhipov, "Adaptation of deep bidirectional multilingual transformers for Russian language," *arXiv preprint arXiv :1905.07213*, 2019.

[27] W. Antoun, F. Baly, and H. Hajj, "AraBERT : Transformer-based model for Arabic language understanding," in *LREC Workshop on Open-Source Arabic Corpora and Processing Tools*, 2020.